



1/112

数值线性代数与算法

第一章 数值线性代数理论基础



Back

Close



本章介绍后面章节中需要用到的一些矩阵代数基础知识: 首先介绍一些基本概念和几种常用的矩阵分解; 其次介绍作为数值误差分析度量工具的向量和矩阵范数及其性质; 接着介绍矩阵的广义逆以及几种特殊的矩阵类型; 最后介绍数值代数中常用的模型问题.

§1.1 一些概念和记号

本书引用下列记号. 用 \mathbb{C}^n (\mathbb{R}^n) 表示 n 维复 (实) 向量空间, $\mathbb{C}^{m \times n}$ ($\mathbb{R}^{m \times n}$) 表示 $m \times n$ 阶复 (实) 矩阵空间, $\mathbb{C}_r^{m \times n}$ ($\mathbb{R}_r^{m \times n}$) 表示秩为 r 的 $m \times n$ 阶复 (实) 矩阵集合. 对于任意的矩阵 $A \in \mathbb{C}^{n \times n}$, A^T, A^H, A^{-1} 分别表示矩阵 A 的转置矩阵、共轭转置矩阵和逆矩阵. 对于任意的向量 $x, y \in \mathbb{C}^n$, 用 $(x, y) := y^H x$ 表示 x 和 y 的欧几里得内积.



Back

Close



定义 1.1 设 $A \in \mathbb{C}^{n \times n}$. 若存在数 $\lambda \in \mathbb{C}$ 和非零向量 $x \in \mathbb{C}^n$ 使得 $Ax = \lambda x$, 则称 λ 为 A 的特征值, x 为 A 属于 λ 的特征向量.

由定义 1.1 可知, λ 是 A 的特征值当且仅当 $\det(\lambda I - A) = 0$. 称 $p(\lambda) = \det(\lambda I - A)$ 为 A 的特征多项式.

注意到 $\det(\lambda I - A^T) = \det(\lambda I - A)$, 此即 A 和 A^T 具有相同的特征值. 故存在非零向量 $y \in \mathbb{C}^n$ 满足 $A^T y = \lambda y$, 即 $y^T A = \lambda y^T$, 称 y 为 A 属于 λ 的左特征向量. 相应地, 将 x 称为 A 属于 λ 的右特征向量. 一般来说, 左右特征向量不相等.

如果 A 有 r 个互不相同的特征值 $\lambda_1, \lambda_2, \dots, \lambda_r$, 则 A 的特征多项式可表示为

$$\det(\lambda I - A) = (\lambda - \lambda_1)^{n_1} (\lambda - \lambda_2)^{n_2} \cdots (\lambda - \lambda_r)^{n_r},$$

称 n_i 为 λ_i 的代数重数. 记 $\gamma_i = n - \text{rank}(\lambda_i I - A)$, 称 γ_i 为





λ_i 的几何重数, 它表示属于 λ_i 的线性无关特征向量的个数, 满足 $1 \leq \gamma_i \leq n_i$. 若 $n_i = 1$, 则称 λ_i 为 A 的简单特征值. 若 $\gamma_i = n_i$, 则称 λ_i 为 A 的半简单特征值. 显然, 简单特征值必为半简单特征值. 满足 $p(A) = O$ 的首项系数为 1 且次数最低的多项式 p 称为 A 的最小多项式. 可以证明, A 的最小多项式具有下列形式, 即

$$p(\lambda) = (\lambda - \lambda_1)^{l_1} (\lambda - \lambda_2)^{l_2} \cdots (\lambda - \lambda_r)^{l_r}, \quad 1 \leq l_i \leq n_i, \quad i = 1, 2, \cdots, r.$$

定义 1.2 设 $A \in \mathbb{C}^{n \times n}$. 若 $A^H A = I$, 则称 A 为酉矩阵. 实的酉矩阵称为正交矩阵, 即 A 满足 $A^T A = I$.

由定义 1.2 显然有, 酉矩阵 A 的逆矩阵为 $A^{-1} = A^H$, 正交矩阵 A 的逆矩阵为 $A^{-1} = A^T$.

由酉矩阵的定义, 容易证明酉矩阵还具有下列性质.





性质 1.1 设 $U, V \in \mathbb{C}^{n \times n}$ 是酉矩阵, 则 $|\det(U)| = 1$, 且 U^{-1} 和 UV 也是酉矩阵.

性质 1.2 $U \in \mathbb{C}^{n \times n}$ 是酉矩阵的充分必要条件是 U 的列向量是两两正交的单位向量.

定义 1.3 设 $A, B \in \mathbb{C}^{n \times n}$. 若存在非奇异矩阵 P 使得 $A = P^{-1}BP$, 则称 A 与 B 相似. 若 P 为酉矩阵, 则称为酉相似. 若 P 为正交矩阵, 则称为正交相似.

显然, 相似矩阵有相同的特征多项式, 因而有相同的特征值.

定义 1.4 设 $A \in \mathbb{C}^{n \times n}$. 若 $A^H A = A A^H$, 则称 A 为正规矩阵. 若 $A^H = A$, 则称 A 为 Hermite 矩阵. 实的 Hermite 矩阵称为实对称矩阵, 即 A 满足 $A^T = A$. 若 A 满足 $A^H = -A$, 则称 A 为反 Hermite 矩阵. 实的反 Hermite 矩阵称为反对称矩阵, 即 A 满足 $A^T = -A$.



Back

Close



容易验证, 酉矩阵、正交矩阵、Hermite 矩阵、反 Hermite 矩阵、实对称矩阵、反对称矩阵都是正规矩阵.

根据反对称矩阵的定义容易证明反对称矩阵的下列性质.

性质 1.3 设 $A = (a_{ij}) \in \mathbb{R}^{n \times n}$ 是反对称矩阵, 即满足 $A^T = -A$. 则

- (1) $a_{ii} = 0, i = 1, 2, \dots, n$.
- (2) 不存在奇数阶非奇异反对称矩阵.
- (3) A 的特征值只能是 0 或纯虚数.

注 1.1 若 $A \in \mathbb{C}^{n \times n}$ 为 Hermite 矩阵, 则其对角元为 0 或纯虚数, 其特征值也只能是 0 或纯虚数.

定义 1.5 设 $A \in \mathbb{R}^{n \times n}$. 若对任意的非零向量 $x \in \mathbb{R}^n$ 有 $(Ax, x) > 0$ (≥ 0), 则称 A 为 (实) 正定矩阵 (半正定矩阵). 若 A 还是对称的, 则称为 (实) 对称正定矩阵 (对称半正定矩阵).



Back

Close



由定义 1.5 不难推得, 对称矩阵的特征值均为实数. 对称正定矩阵 (对称半正定矩阵) 的特征值均为正数 (非负数). 此外, 若记

$$\mathbf{H} = \frac{1}{2}(\mathbf{A} + \mathbf{A}^T), \quad \mathbf{S} = \frac{1}{2}(\mathbf{A} - \mathbf{A}^T),$$

分别称为 \mathbf{A} 的对称部分和反对称部分, 则显然对任意的矩阵 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 都可唯一地分裂为

$$\mathbf{A} = \mathbf{H} + \mathbf{S},$$

称为矩阵 \mathbf{A} 的对称-反对称分裂.

性质 1.4 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 正定 (或半正定) 的充分必要条件是 its 对称部分 \mathbf{H} 对称正定 (或对称半正定).

定义 1.6 设 i_1, i_2, \dots, i_n 是 $1, 2, \dots, n$ 的一个排列, 以 n 阶单位矩阵 \mathbf{I}_n 的 n 个列向量

$$\mathbf{e}_1 = (1, 0, \dots, 0)^T, \mathbf{e}_2 = (0, 1, \dots, 0)^T, \dots, \mathbf{e}_n = (0, 0, \dots, 1)^T$$





为列构成的 n 阶矩阵 $\boldsymbol{P} = [\boldsymbol{e}_{i_1}, \boldsymbol{e}_{i_2}, \dots, \boldsymbol{e}_{i_n}]$, 称为置换矩阵或排列矩阵.

例如

$$\boldsymbol{P} = [\boldsymbol{e}_3, \boldsymbol{e}_1, \boldsymbol{e}_2] = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix}$$

是一个 3 阶置换矩阵.

性质 1.5 置换矩阵具有如下性质:

- (1) 置换矩阵的转置仍是置换矩阵.
- (2) 置换矩阵是正交矩阵.

(3) 设 $\boldsymbol{A} \in \mathbb{C}^{n \times n}$, $\boldsymbol{P} = [\boldsymbol{e}_{i_1}, \boldsymbol{e}_{i_2}, \dots, \boldsymbol{e}_{i_n}]$, 则 $\boldsymbol{P}^T \boldsymbol{A}$ 是将 \boldsymbol{A} 按 i_1, i_2, \dots, i_n 行重新排列所得到的矩阵, $\boldsymbol{A} \boldsymbol{P}$ 是将 \boldsymbol{A} 按 i_1, i_2, \dots, i_n 列重新排列得到的矩阵.



Back

Close



定义 1.7 设 $A, B \in \mathbb{C}^{n \times n}$. 如果存在 n 阶非奇异矩阵 C , 使得

(1) $B = C^T A C$, 则称 A 与 B 为 T-合同.

(2) $B = C^H A C$, 则称 A 与 B 为 H-合同.

显然, 这两个合同概念具有密切的联系. 当 C 是实矩阵时, T-合同和 H-合同是一致的. 此外, 容易证明, T-合同和 H-合同都是等价关系.

利用合同的定义还可以得到:

(1) 如果 A 是 Hermite 矩阵, 则 $C^H A C$ 也是 Hermite 矩阵 (即使 C 是奇异矩阵).

(2) 如果 A 是对称矩阵 (不一定是实矩阵), 则 $C^T A C$ 也是对称矩阵.

(3) 如果 A 是 Hermite 正定 (半正定) 矩阵, 则 $C^H A C$ 也是



Back

Close



Hermite 正定 (半正定) 矩阵.

(4) 如果 \mathbf{A} 是对称正定 (半正定) 矩阵, 则 $\mathbf{C}^T \mathbf{A} \mathbf{C}$ 也是对称正定 (半正定) 矩阵.

定义 1.8 对于 2×2 分块矩阵

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}, \quad (1.1)$$

当 \mathbf{A}_{11} 可逆时, 称 $\mathbf{A}_{22} - \mathbf{A}_{21} \mathbf{A}_{11}^{-1} \mathbf{A}_{12}$ 为 \mathbf{A} 关于 \mathbf{A}_{11} 的 Schur 补, 记为 $\mathbf{A}/\mathbf{A}_{11}$. 当 \mathbf{A}_{22} 可逆时, 称 $\mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$ 为 \mathbf{A} 关于 \mathbf{A}_{22} 的 Schur 补, 记为 $\mathbf{A}/\mathbf{A}_{22}$.

定理 1.1 设 \mathbf{A} 具有式 (1.1) 的分块形式, 且 \mathbf{A}_{11} 可逆. 则

(1) $\det(\mathbf{A}) = \det(\mathbf{A}_{11}) \det(\mathbf{A}/\mathbf{A}_{11})$.

(2) $\text{rank}(\mathbf{A}) = \text{rank}(\mathbf{A}_{11}) + \text{rank}(\mathbf{A}/\mathbf{A}_{11})$.



Back

Close



证明 注意到

$$\begin{aligned} B &= \begin{bmatrix} I & O \\ -A_{21}A_{11}^{-1} & I \end{bmatrix} \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \begin{bmatrix} I & -A_{11}^{-1}A_{12} \\ O & I \end{bmatrix} \\ &= \begin{bmatrix} A_{11} & O \\ O & A_{22} - A_{21}A_{11}^{-1}A_{12} \end{bmatrix} = \begin{bmatrix} A_{11} & O \\ O & A/A_{11} \end{bmatrix}. \end{aligned}$$

由此立即可得定理的结论. 证毕. \square

由定理 1.1 立即可得下面的结论.

推论 1.1 设 A 具有式 (1.1) 的分块形式, 且 A_{22} 可逆. 则

- (1) $\det(A) = \det(A_{22}) \det(A/A_{22})$.
- (2) $\text{rank}(A) = \text{rank}(A_{22}) + \text{rank}(A/A_{22})$.



Back

Close



推论 1.2 设

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

是 Hermite 矩阵, \mathbf{A} 关于 \mathbf{A}_{11} 的 Schur 补 $\mathbf{A}/\mathbf{A}_{11} = \mathbf{A}_{22} - \mathbf{A}_{21}\mathbf{A}_{11}^{-1}\mathbf{A}_{12}$.
则

- (1) \mathbf{A} 正定当且仅当 \mathbf{A}_{11} 及 $\mathbf{A}/\mathbf{A}_{11}$ 均正定.
- (2) 若 \mathbf{A}_{11} 正定, 则 \mathbf{A} 正定当且仅当 $\mathbf{A}/\mathbf{A}_{11}$ 正定.

[Back](#)[Close](#)



§1.2 几种常用的矩阵分解

所谓矩阵分解, 就是将一个矩阵分解为 (从某种意义上讲) 比较简单或对其性质比较熟悉的若干个矩阵的乘积. 下面介绍几种常用的矩阵分解.

§1.2.1 矩阵的特征分解

特征分解, 又称谱分解, 是将矩阵分解为由其特征值和特征向量表示的矩阵之积的方法. 注意: 只有对可对角化矩阵才可以实施特征分解.

设 $A \in \mathbb{C}^{n \times n}$ 有 n 个线性无关的特征向量 \mathbf{q}_i ($i = 1, 2, \dots, n$). 则 A 可以被分解为

$$A = Q\Lambda Q^{-1}, \quad (1.2)$$



Back

Close



式中: $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$, λ_i ($i = 1, 2, \dots, n$) 为 A 的特征值; Q 为 n 阶方阵, 且其第 i 列为 A 的特征向量 q_i .

一般来说, 特征向量 q_i ($i = 1, 2, \dots, n$) 通常被正交单位化 (但这不是必须的). 未被正交单位化的特征向量组 v_i ($i = 1, 2, \dots, n$) 也可以作为 Q 的列向量.

通常可以通过特征分解来求矩阵的逆. 若矩阵 A 可被特征分解并特征值中不含零, 则矩阵 A 为非奇异矩阵, 且其逆矩阵可以由下式给出:

$$A^{-1} = Q\Lambda^{-1}Q^{-1} = Q\Lambda^{-1}Q^T, \quad (1.3)$$

此处假设 Q 的列向量被正交单位化. 因为 Λ 为对角矩阵, 其逆矩阵容易计算出:

$$\Lambda^{-1} = \text{diag}(\lambda_1^{-1}, \lambda_2^{-1}, \dots, \lambda_n^{-1}).$$

由于任意的 n 阶实对称矩阵 A 都有 n 个线性无关的特征向





量, 并且这些特征向量都可以正交单位化而得到一组正交且模为 1 的向量. 故实对称矩阵 A 可被分解成

$$A = Q\Lambda Q^T,$$

式中: Q 为正交矩阵; Λ 为实对角矩阵.

类似地, 设 $A \in \mathbb{C}^{n \times n}$ 为正规矩阵, 由于正规矩阵是可对角化的 (见定理 1.5), 故其具有一组标准正交特征向量基, 因此可被分解成

$$A = U\Lambda U^H,$$

式中: U 为酉矩阵. 进一步地, 若 A 是 Hermite 矩阵, 那么对角矩阵 Λ 的对角元全为实数. 若 A 是酉矩阵, 则 Λ 的所有对角元在复平面的单位圆上取得.

下面再给出矩阵特征分解的一个应用.



Back

Close



定理 1.2 设 $\mathbf{A} \in \mathbb{C}^{n \times n}$ 为 Hermite 正定 (半正定) 矩阵, 则存在唯一的 Hermite 正定 (半正定) 矩阵 \mathbf{B} 使得

$$\mathbf{A} = \mathbf{B}^2. \quad (1.4)$$

称这样定义的矩阵 \mathbf{B} 为矩阵 \mathbf{A} 的平方根矩阵, 常记为 $\mathbf{A}^{1/2}$.

证明 只证明正定的情形. 存在性. 由于 \mathbf{A} 是 Hermite 正定矩阵, 故存在酉矩阵 \mathbf{P} 使得

$$\mathbf{A} = \mathbf{P} \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n) \mathbf{P}^H,$$

式中: $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n > 0$ 为 \mathbf{A} 的特征值. 令

$$\mathbf{B} = \mathbf{P} \text{diag}(\lambda_1^{1/2}, \lambda_2^{1/2}, \dots, \lambda_n^{1/2}) \mathbf{P}^H,$$

则显然 \mathbf{B} 为 Hermite 正定矩阵, 且 $\mathbf{B}^2 = \mathbf{A}$.





唯一性. 假设另有 Hermite 正定矩阵 C 满足 $A = C^2$. 则存在酉矩阵 Q 使得

$$C = Q \operatorname{diag}(\mu_1, \mu_2, \cdots, \mu_n) Q^H,$$

式中: $\mu_1 \geq \mu_2 \geq \cdots \geq \mu_n > 0$ 为 C 的特征值. 由于

$$C^2 = Q \operatorname{diag}(\mu_1^2, \mu_2^2, \cdots, \mu_n^2) Q^H = A,$$

故 $\mu_i^2 = \lambda_i$ ($i = 1, 2, \cdots, n$), 即 $\mu_i = \lambda_i^{1/2}$. 于是

$$C = Q \operatorname{diag}(\lambda_1^{1/2}, \lambda_2^{1/2}, \cdots, \lambda_n^{1/2}) Q^H.$$

再由 $A = B^2 = C^2$, 得

$$P \operatorname{diag}(\lambda_1, \lambda_2, \cdots, \lambda_n) P^H = Q \operatorname{diag}(\lambda_1, \lambda_2, \cdots, \lambda_n) Q^H,$$

或等价地, 有

$$Q^H P \operatorname{diag}(\lambda_1, \lambda_2, \cdots, \lambda_n) = \operatorname{diag}(\lambda_1, \lambda_2, \cdots, \lambda_n) Q^H P.$$



Back

Close



记 $Q^H P = (t_{ij})$, 则有

$$t_{ij}\lambda_j = \lambda_i t_{ij}, \quad i, j = 1, 2, \dots, n.$$

因此, 当 $\lambda_i \neq \lambda_j$ 时, 必有 $t_{ij} = 0$. 故无论 λ_i 与 λ_j 是否相等, 都有

$$t_{ij}\lambda_j^{1/2} = t_{ij}\lambda_i^{1/2}, \quad i, j = 1, 2, \dots, n.$$

即

$$Q^H P \operatorname{diag}(\lambda_1^{1/2}, \lambda_2^{1/2}, \dots, \lambda_n^{1/2}) = \operatorname{diag}(\lambda_1^{1/2}, \lambda_2^{1/2}, \dots, \lambda_n^{1/2}) Q^H P,$$

或者等价地, 有

$$P \operatorname{diag}(\lambda_1^{1/2}, \lambda_2^{1/2}, \dots, \lambda_n^{1/2}) P^H = Q \operatorname{diag}(\lambda_1^{1/2}, \lambda_2^{1/2}, \dots, \lambda_n^{1/2}) Q^H,$$

即 $B = C$. 证毕. □



Back

Close

§1.2.2 矩阵的 Schur 分解

矩阵的 Schur 分解在理论上十分重要, 它是许多重要定理证明的出发点. 如矩阵论中极为重要的 Hamilton–Cayley (哈密顿–凯莱) 定理, 就可以利用矩阵的 Schur 分解定理进行简洁而优美的证明.

定理 1.3 (Schur 分解定理) 设 $A \in \mathbb{C}^{n \times n}$, 则存在酉矩阵 $P \in \mathbb{C}^{n \times n}$ 使得

$$P^H A P = T,$$

式中: T 为上三角矩阵, 其对角元素是 A 的特征值, 而且可以选取 P 使得 T 的对角元可以任意排列.

证明 对矩阵的阶数 n 用数学归纳法. 当 $n = 1$ 时, 结论显然成立. 假设结论对 $n - 1$ 阶矩阵成立, 下证对 n 阶矩阵成立.

设 A 的特征值为 $\lambda_1, \lambda_2, \dots, \lambda_n$, x_1 为对应于特征值 λ_1 的





单位特征向量. 将 x_1 扩充为向量空间 \mathbb{C}^n 的一组标准正交基 x_1, z_2, \dots, z_n . 定义酉矩阵 $P_0 = [x_1, z_2, \dots, z_n]$, 则

$$P_0^H A P_0 = \begin{bmatrix} \lambda_1 & * \\ 0 & A_1 \end{bmatrix},$$

式中: A_1 为 $n-1$ 阶方阵, 其特征值为 $\lambda_2, \dots, \lambda_n$.

由归纳法假设, 存在 $n-1$ 阶酉矩阵 P_1 使得

$$P_1^H A_1 P_1 = T_1,$$

式中: T_1 为 $n-1$ 阶上三角矩阵, 其对角元为 A_1 的特征值 $\lambda_2, \dots, \lambda_n$.

令

$$P = P_0 \begin{bmatrix} 1 & 0 \\ 0 & P_1 \end{bmatrix}, \quad T = \begin{bmatrix} \lambda_1 & * \\ 0 & T_1 \end{bmatrix}.$$



则有

$$\begin{aligned} P^H A P &= \begin{bmatrix} 1 & \mathbf{0} \\ \mathbf{0} & P_1^H \end{bmatrix} P_0^H A P_0 \begin{bmatrix} 1 & \mathbf{0} \\ \mathbf{0} & P_1 \end{bmatrix} \\ &= \begin{bmatrix} 1 & \mathbf{0} \\ \mathbf{0} & P_1^H \end{bmatrix} \begin{bmatrix} \lambda_1 & * \\ \mathbf{0} & A_1 \end{bmatrix} \begin{bmatrix} 1 & \mathbf{0} \\ \mathbf{0} & P_1 \end{bmatrix} \\ &= \begin{bmatrix} \lambda_1 & * \\ \mathbf{0} & P_1^H A_1 P_1 \end{bmatrix} = \begin{bmatrix} \lambda_1 & * \\ \mathbf{0} & T_1 \end{bmatrix} = T. \end{aligned}$$

由归纳法假设, T_1 的对角元可以任意排列, 故 T 的对角元也可以任意排列. 证毕. \square

推论 1.3 设 $A \in \mathbb{R}^{n \times n}$ 的特征值都是实数, 则 A 正交相似于上三角矩阵.



21/112



Back

Close

设多项式

$$f(\lambda) = b_0\lambda^m + b_1\lambda^{m-1} + \cdots + b_{m-1}\lambda + b_m,$$

对于 n 阶矩阵 \mathbf{A} , 定义矩阵多项式

$$f(\mathbf{A}) = b_0\mathbf{A}^m + b_1\mathbf{A}^{m-1} + \cdots + b_{m-1}\mathbf{A} + b_m\mathbf{I},$$

式中: \mathbf{I} 为单位矩阵. 如果 $f(\mathbf{A}) = \mathbf{O}$, 那么称 \mathbf{A} 为 $f(\lambda)$ 的矩阵根.

下面利用矩阵的 Schur 分解来证明著名的 Hamilton–Cayley 定理.

定理 1.4 (Hamilton–Cayley 定理) 设 $\mathbf{A} \in \mathbb{C}^{n \times n}$, $p(\lambda) = \det(\lambda\mathbf{I} - \mathbf{A})$, 则 $p(\mathbf{A}) = \mathbf{O}$. 即矩阵 \mathbf{A} 的特征多项式是它的零化多项式.





证明 设 n 阶矩阵 A 的特征多项式为

$$p(\lambda) = \det(\lambda \mathbf{I} - \mathbf{A}) = \lambda^n + a_1 \lambda^{n-1} + \cdots + a_{n-1} \lambda + a_n,$$

记 A 的 n 个特征值为 $\lambda_1, \lambda_2, \cdots, \lambda_n$, 则有

$$p(\lambda) = (\lambda - \lambda_1)(\lambda - \lambda_2) \cdots (\lambda - \lambda_n),$$

由定理 1.3 可知, 存在酉矩阵 U , 使得

$$U^H A U = \begin{bmatrix} \lambda_1 & * & \cdots & * \\ & \lambda_2 & \ddots & \vdots \\ & & \ddots & * \\ & & & \lambda_n \end{bmatrix},$$



Back

Close

于是,

$$p(U^H AU) = (U^H AU - \lambda_1 I)(U^H AU - \lambda_2 I) \cdots (U^H AU - \lambda_n I)$$

$$= \begin{bmatrix} 0 & * & \cdots & * \\ & \lambda_2 - \lambda_1 & \ddots & \vdots \\ & & \ddots & * \\ & & & \lambda_n - \lambda_1 \end{bmatrix} \times \begin{bmatrix} \lambda_1 - \lambda_2 & * & \cdots & * \\ & 0 & \ddots & \vdots \\ & & \ddots & * \\ & & & \lambda_n - \lambda_2 \end{bmatrix}$$

$$\times \begin{bmatrix} \lambda_1 - \lambda_3 & * & * & \cdots & * \\ & \lambda_2 - \lambda_3 & * & \cdots & * \\ & & 0 & \ddots & \vdots \\ & & & \ddots & * \\ & & & & \lambda_n - \lambda_3 \end{bmatrix} \times \cdots \times \begin{bmatrix} \lambda_1 - \lambda_n & * & * & \cdots & * \\ & \lambda_2 - \lambda_n & * & \cdots & * \\ & & \ddots & \ddots & \vdots \\ & & & \ddots & * \\ & & & & \lambda_{n-1} - \lambda_n \\ & & & & & 0 \end{bmatrix}$$





$$\begin{aligned}
 &= \begin{bmatrix} 0 & 0 & * & \cdots & * \\ 0 & 0 & * & \cdots & * \\ 0 & 0 & * & \cdots & * \\ 0 & 0 & & \ddots & \vdots \\ 0 & 0 & & & * \end{bmatrix} \times \begin{bmatrix} \lambda_1 - \lambda_3 & * & * & \cdots & * \\ & \lambda_2 - \lambda_3 & * & \cdots & * \\ & & 0 & \ddots & \vdots \\ & & & \ddots & * \\ & & & & \lambda_n - \lambda_3 \end{bmatrix} \\
 &\quad \times \cdots \times \begin{bmatrix} \lambda_1 - \lambda_n & * & * & \cdots & * \\ & \lambda_2 - \lambda_n & * & \cdots & * \\ & & \ddots & \ddots & \vdots \\ & & & \lambda_{n-1} - \lambda_n & * \\ & & & & 0 \end{bmatrix} = \mathbf{O},
 \end{aligned}$$

即 $U^H p(\mathbf{A}) U = \mathbf{O}$, 也就是 $p(\mathbf{A}) = \mathbf{O}$. 证毕.

□



Back

Close



在计算数学领域, 人们颇为关心的是, 通过相似变换可以把一个矩阵变换成何种最简单的形状. 利用定理 1.3 和推论 1.3, 可以导出矩阵酉 (正交) 相似于对角矩阵的充要条件.

定理 1.5 矩阵 $A \in \mathbb{C}^{n \times n}$ 酉相似于对角矩阵当且仅当 A 是正规矩阵, 即 $A^H A = A A^H$. 换言之, 正规矩阵一定可对角化.

证明 必要性. 设酉矩阵 U , 使得 $U^H A U = \Lambda$, 其中 Λ 为对角矩阵, 则有

$$\begin{aligned} A &= U \Lambda U^H, \quad A^H = U \bar{\Lambda} U^H, \\ A^H A &= U \bar{\Lambda} U^H U \Lambda U^H = U \bar{\Lambda} \Lambda U^H = U \Lambda \bar{\Lambda} U^H \\ &= U \Lambda U^H U \bar{\Lambda} U^H = A A^H. \end{aligned}$$





充分性. 由 Schur 分解定理可知, 存在酉矩阵 U , 使得

$$U^H A U = \begin{bmatrix} t_{11} & t_{12} & \cdots & t_{1n} \\ & t_{22} & \cdots & t_{2n} \\ & & \ddots & \vdots \\ & & & t_{nn} \end{bmatrix} := T.$$

利用条件 $A^H A = A A^H$, 得

$$\begin{aligned} T^H T &= U^H A^H U U^H A U = U^H A^H A U \\ &= U^H A A^H U = U^H A U U^H A^H U = T T^H. \end{aligned}$$

比较上式两端矩阵的对应元素, 可得 $t_{ij} = 0$ ($i < j$), 也就是 $T = \text{diag}(t_{11}, t_{22}, \cdots, t_{nn})$, 即 A 酉相似于对角矩阵. 证毕. \square

推论 1.4 设 $A \in \mathbb{R}^{n \times n}$ 的 n 个特征值都是实数, 则 A 正交相似于对角矩阵的充要条件是 $A^T A = A A^T$.



Back

Close



推论 1.5 设 $A \in \mathbb{C}^{n \times n}$ 为正规矩阵, λ 是 A 的特征值, x 是对应的特征向量. 则 $\bar{\lambda}$ 是 A^H 的特征值, $\bar{\lambda}$ 对应的特征向量仍然是 x .

证明 由定理 1.5, 存在 n 阶酉矩阵 U 使得

$$U^H A U = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n).$$

于是有 $U^H A^H U = \text{diag}(\bar{\lambda}_1, \bar{\lambda}_2, \dots, \bar{\lambda}_n)$. 设 $U = [u_1, u_2, \dots, u_n]$, 则上面两式可写为

$$A u_i = \lambda_i u_i, \quad A^H u_i = \bar{\lambda}_i u_i, \quad i = 1, 2, \dots, n.$$

由此可见, 若 λ_i 是 A 的特征值且 u_i 是相应的特征向量时, $\bar{\lambda}_i$ 是 A^H 的特征值且相应的特征向量仍是 u_i . 证毕. \square

推论 1.6 设 $A \in \mathbb{C}^{n \times n}$ 为正规矩阵, λ, μ 是 A 的特征值, x, y 是对应的特征向量. 如果 $\lambda \neq \mu$, 则 x 与 y 正交, 即 $y^H x = 0$.





证明 因为 $Ax = \lambda x$, $Ay = \mu y$. 由推论 1.5 得 $A^H x = \bar{\lambda} x$. 故

$$\bar{\mu} y^H x = (\mu y)^H x = (Ay)^H x = y^H A^H x = \bar{\lambda} y^H x,$$

即 $\overline{(\lambda - \mu)} y^H x = 0$. 由题设 $\lambda \neq \mu$, 故必有 $y^H x = 0$. 证毕. \square

推论 1.7 设 $A \in \mathbb{C}^{n \times n}$, 则 A 酉相似于实对角矩阵的充要条件是 A 为 Hermite 矩阵.

证明 必要性. 设存在 n 阶酉矩阵 U 使得

$$U^H A U = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n) = \Lambda,$$

式中: $\lambda_i (i = 1, 2, \dots, n)$ 为实数, 则有

$$A^H = (U \Lambda U^H)^H = U \Lambda^H U^H = U \Lambda U^H = A,$$

即 A 是 Hermite 矩阵.



Back

Close



充分性. 若 A 是 Hermite 矩阵, 则 A 为正规矩阵, 于是存在酉矩阵 U 使得

$$U^H A U = \text{diag}(\lambda_1, \lambda_2, \cdots, \lambda_n) = \Lambda,$$

故

$$A^H = (U^H A U)^H = U^H A^H U = U^H A U = A.$$

从而 $\bar{\lambda}_i = \lambda_i$ ($i = 1, 2, \cdots, n$), 即 λ_i 都是实数. 证毕. □

推论 1.8 设 $A \in \mathbb{C}^{n \times n}$ 是反 Hermite 矩阵, 则存在 n 阶酉矩阵 U 使得

$$U^H A U = \text{diag}(ib_1, ib_2, \cdots, ib_n),$$

式中: b_i ($i = 1, 2, \cdots, n$) 为实数.

证明 由于反 Hermite 矩阵是正规矩阵且其特征值为 0 或纯虚数, 由定理 1.5 即得结论. 证毕. □



Back

Close



下面介绍两个 n 阶实对称矩阵“同时”相似于对角矩阵的问题.

定理 1.6 设 A 和 B 都是 n 阶实对称矩阵, 则存在正交矩阵 P , 使得 P^TAP 和 P^TBP 都是对角矩阵的充要条件是 $AB = BA$.

证明 必要性. 设 n 阶正交矩阵 P 使得

$$P^TAP = \Lambda, \quad P^TBP = \Sigma,$$

式中: Λ 和 Σ 为对角矩阵. 则有

$$\begin{aligned} AB &= P\Lambda P^T P\Sigma P^T = P\Lambda\Sigma P^T \\ &= P\Sigma\Lambda P^T = P\Sigma P^T P\Lambda P^T = BA. \end{aligned}$$

充分性. 设 A 的全体互异特征值为 $\lambda_1, \lambda_2, \dots, \lambda_r$, 相应的重数为 n_1, n_2, \dots, n_r ($n_1 + n_2 + \dots + n_r = n$). 由 A 实对称知, 存在



Back

Close

正交矩阵 Q 使得

$$Q^T A Q = \begin{bmatrix} \lambda_1 \mathbf{I}_{n_1} & & & \\ & \lambda_2 \mathbf{I}_{n_2} & & \\ & & \ddots & \\ & & & \lambda_r \mathbf{I}_{n_r} \end{bmatrix},$$

将矩阵 $Q^T B Q$ 划分为如下分块形式

$$Q^T B Q = \begin{bmatrix} B_{11} & B_{12} & \cdots & B_{1r} \\ B_{21} & B_{22} & \cdots & B_{2r} \\ \vdots & \vdots & \ddots & \vdots \\ B_{r1} & B_{r2} & \cdots & B_{rr} \end{bmatrix},$$

式中: B_{ij} 为 $n_i \times n_j$ 阶矩阵 ($i, j = 1, 2, \cdots, r$).

由 $AB = BA$ 及 $Q^T Q = I$, 得

$$(Q^T A Q)(Q^T B Q) = (Q^T B Q)(Q^T A Q),$$



即

$$\begin{bmatrix} \lambda_1 \mathbf{B}_{11} & \lambda_1 \mathbf{B}_{12} & \cdots & \lambda_1 \mathbf{B}_{1r} \\ \lambda_2 \mathbf{B}_{21} & \lambda_2 \mathbf{B}_{22} & \cdots & \lambda_2 \mathbf{B}_{2r} \\ \vdots & \vdots & \ddots & \vdots \\ \lambda_r \mathbf{B}_{r1} & \lambda_r \mathbf{B}_{r2} & \cdots & \lambda_r \mathbf{B}_{rr} \end{bmatrix} = \begin{bmatrix} \lambda_1 \mathbf{B}_{11} & \lambda_2 \mathbf{B}_{12} & \cdots & \lambda_r \mathbf{B}_{1r} \\ \lambda_1 \mathbf{B}_{21} & \lambda_2 \mathbf{B}_{22} & \cdots & \lambda_r \mathbf{B}_{2r} \\ \vdots & \vdots & \ddots & \vdots \\ \lambda_1 \mathbf{B}_{r1} & \lambda_2 \mathbf{B}_{r2} & \cdots & \lambda_r \mathbf{B}_{rr} \end{bmatrix},$$

也就是

$$\lambda_i \mathbf{B}_{ij} = \lambda_j \mathbf{B}_{ij} \quad (i, j = 1, 2, \cdots, r).$$

当 $i \neq j$ 时, 由 $\lambda_i \neq \lambda_j$ 可得 $\mathbf{B}_{ij} = \mathbf{O}$ ($i \neq j; i, j = 1, 2, \cdots, r$). 于是

$$\mathbf{Q}^T \mathbf{B} \mathbf{Q} = \text{diag}(\mathbf{B}_{11}, \mathbf{B}_{22}, \cdots, \mathbf{B}_{rr}),$$

因为 $\mathbf{Q}^T \mathbf{B} \mathbf{Q}$ 实对称, 所以 \mathbf{B}_{ii} ($i = 1, 2, \cdots, r$) 实对称, 那么存在正交矩阵 \mathbf{U}_i , 使得 $\mathbf{U}_i^T \mathbf{B}_{ii} \mathbf{U}_i = \boldsymbol{\Sigma}_i$ ($i = 1, 2, \cdots, r$), 其中 $\boldsymbol{\Sigma}_i$ 为对角矩阵. 令 $\mathbf{U} = \text{diag}(\mathbf{U}_1, \mathbf{U}_2, \cdots, \mathbf{U}_r)$, 则 \mathbf{U} 为正交矩阵, 从而



$P = QU$ 也为正交矩阵, 且有

$$P^T B P = U^T (Q^T B Q) U = \text{diag}(\Sigma_1, \Sigma_2, \cdots, \Sigma_r),$$

$$P^T A P = U^T (Q^T A Q) U = \text{diag}(\lambda_1 I_{n_1}, \lambda_2 I_{n_2}, \cdots, \lambda_r I_{n_r}).$$

证毕.

□

定理 1.6 给出了两个实对称矩阵“同时”正交相似于对角矩阵的充要条件, 下面再给出两个 Hermite 矩阵“同时”合同于对角矩阵的充分条件.

定理 1.7 设 A 和 B 都是 n 阶 Hermite 矩阵, 且 B 为正定矩阵, 则存在可逆矩阵 P , 使得 $P^H A P$ 和 $P^H B P$ 都是对角矩阵.





证明 由 B 正定知, 存在酉矩阵 Q_1 , 使得

$$Q_1^H B Q_1 = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix} = \Lambda_1, \quad (\lambda_i > 0),$$

令

$$Q_2 = Q_1 \begin{bmatrix} 1/\sqrt{\lambda_1} & & \\ & \ddots & \\ & & 1/\sqrt{\lambda_n} \end{bmatrix},$$

则 Q_2 可逆, 且有 $Q_2^H B Q_2 = I$. 对于 Hermite 矩阵 $Q_2^H A Q_2$, 存在酉矩阵 Q_3 , 使得

$$Q_3^H (Q_2^H A Q_2) Q_3 = \begin{bmatrix} \mu_1 & & \\ & \ddots & \\ & & \mu_n \end{bmatrix} = \Lambda_2.$$



Back

Close



令 $P = Q_2 Q_3$, 则 P 可逆, 且有

$$P^H A P = \Lambda_2, \quad P^H B P = I,$$

式中: Λ_2 和 I 为对角矩阵. 证毕. □

§1.2.3 矩阵的奇异值分解

矩阵的奇异值分解在理论上和实际应用中都十分重要. 特别地, 它已成为信息处理、多元统计分析等工程技术领域中不可缺少的工具. 由 1.2.2 节的 Schur 分解定理可知, 任一方阵用酉相似变换只能约化为上三角矩阵, 不能约化为对角矩阵. 而奇异值分解定理表明: 用两个酉矩阵乘到一个矩阵 A 的两边就可以变为对角矩阵. 奇异值分解常用于奇异的或数值上非常接近奇异的矩阵计算. 它不仅能判断矩阵是否接近奇异, 而且也用于数值求解.



Back

Close



对于任意的 $A \in \mathbb{C}^{m \times n}$, 容易验证:

- (1) $A^H A$ 是 Hermite (半) 正定矩阵.
- (2) 齐次线性方程组 $Ax = 0$ 与 $A^H Ax = 0$ 同解.
- (3) $\text{rank}(A^H A) = \text{rank}(A)$.
- (4) $A^H A = O \iff A = O$.

定义 1.9 设 $A \in \mathbb{C}_r^{m \times n} (r \geq 1)$, 记 Hermite 矩阵 $A^H A$ 的 n 个特征值为 $\lambda_1 \geq \lambda_2 \geq \cdots \lambda_r > \lambda_{r+1} = \cdots = \lambda_n = 0$, 则称

$$\sigma_i = \sqrt{\lambda_i}, \quad i = 1, 2, \cdots, n$$

为 A 的奇异值.

容易看出, A 的奇异值的个数与 A 的列数相同, A 的正奇异值的个数与 A 的秩相同.





定理 1.8 (奇异值分解定理) 设 $\mathbf{A} \in \mathbb{C}_r^{m \times n}$ 的正奇异值为 $\sigma_1, \sigma_2, \dots, \sigma_r$. 则存在 m 阶酉矩阵 \mathbf{U} 和 n 阶酉矩阵 \mathbf{V} , 使得

$$\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^{\mathrm{H}}, \quad (1.5)$$

式中: $\mathbf{\Sigma}$ 为 $m \times n$ 阶对角矩阵, 且

$$\mathbf{\Sigma} = \begin{bmatrix} \mathbf{\Sigma}_r & \mathbf{O} \\ \mathbf{O} & \mathbf{O} \end{bmatrix} \begin{matrix} r \\ m-r \end{matrix}, \quad (1.6)$$

$r \quad n-r$

这里 $\mathbf{\Sigma}_r = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$, $\sigma_i > 0$, $1 \leq i \leq r$, $r \leq \min\{m, n\}$.

证明 对任意的 $\mathbf{A} \in \mathbb{C}_r^{m \times n}$, $\mathbf{A}^{\mathrm{H}} \mathbf{A}$ 是 n 阶 Hermite 半正定矩阵, 它的 n 个非负特征值记为 $\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2$. 不妨设 $\sigma_1^2 \geq \sigma_2^2 \geq \dots \geq \sigma_r^2 > 0$, $\sigma_{r+1}^2 = \sigma_{r+2}^2 = \dots = \sigma_n^2 = 0$, 这里 $r \leq \min\{m, n\}$. $\mathbf{A}^{\mathrm{H}} \mathbf{A}$ 的



Back

Close

特征分解为

$$\mathbf{V}^H(\mathbf{A}^H\mathbf{A})\mathbf{V} = \text{diag}(\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2), \quad (1.7)$$

式中: $\mathbf{V} = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n]$ 为 n 阶酉矩阵.

划分 $\mathbf{V} = [\mathbf{V}_1, \mathbf{V}_2]$, 其中 $\mathbf{V}_1 = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r]$, $\mathbf{V}_2 = [\mathbf{v}_{r+1}, \mathbf{v}_{r+2}, \dots, \mathbf{v}_n]$, 令 $\Sigma_r = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$, 则有

$$\begin{aligned} \mathbf{V}^H(\mathbf{A}^H\mathbf{A})\mathbf{V} &= \begin{bmatrix} \mathbf{V}_1^H \\ \mathbf{V}_2^H \end{bmatrix} (\mathbf{A}^H\mathbf{A}) [\mathbf{V}_1, \mathbf{V}_2] \\ &= \begin{bmatrix} \mathbf{V}_1^H\mathbf{A}^H\mathbf{A}\mathbf{V}_1 & \mathbf{V}_1^H\mathbf{A}^H\mathbf{A}\mathbf{V}_2 \\ \mathbf{V}_2^H\mathbf{A}^H\mathbf{A}\mathbf{V}_1 & \mathbf{V}_2^H\mathbf{A}^H\mathbf{A}\mathbf{V}_2 \end{bmatrix}. \end{aligned} \quad (1.8)$$

对比式 (1.7) 和式 (1.8), 得





$$\begin{aligned} V_1^H A^H A V_1 &= \Sigma_r^2, & V_2^H A^H A V_2 &= O, \\ V_1^H A^H A V_2 &= O, & V_2^H A^H A V_1 &= O. \end{aligned} \quad (1.9)$$

由式 (1.9) 的第 1, 2 个等式可知 AV_1 的列互相正交, AV_2 的列为零向量. 取 $m \times r$ 阶矩阵

$$U_1 = AV_1 \Sigma_r^{-1}, \quad (1.10)$$

则 $U_1^H U_1 = I_r$. 再取 $U_2 \in \mathbb{C}^{m \times (n-r)}$, 使得 $U = [U_1, U_2]$ 为酉矩阵. 则由 $AV_2 = O$ 及 $U_2^H AV_1 = U_2^H (U_1 \Sigma_r) = (U_2^H U_1) \Sigma_r = O$, 立即推得

$$U^H AV = \begin{bmatrix} U_1^H AV_1 & U_1^H AV_2 \\ U_2^H AV_1 & U_2^H AV_2 \end{bmatrix} = \begin{bmatrix} \Sigma_r & O \\ O & O \end{bmatrix} = \Sigma.$$

证毕. □



Back

Close



在奇异值分解式 (1.5) 中, U 的第 i 列是 A 的对应于奇异值 σ_i 的左奇异向量, V 的第 i 列是 A 的对应于奇异值 σ_i 的右奇异向量. 从定理的证明过程不难看出, A 的奇异值由 A 唯一确定, 但对应于每个奇异值的奇异向量一般不是唯一的.

注 1.2 若 $A \in \mathbb{R}_r^{m \times n}$, 则定理 1.8 中的 U, V 都可以取为实矩阵, 即 U 和 V 分别为 m 阶和 n 阶的正交矩阵.

两个与矩阵 $A \in \mathbb{C}^{m \times n}$ 有关的重要子空间是其列空间和零空间.

定义 1.10 设矩阵 $A \in \mathbb{C}^{m \times n}$, 分别称

$$\mathcal{R}(A) = \{y : y = Ax, x \in \mathbb{C}^n\} \subset \mathbb{C}^m,$$

$$\mathcal{N}(A) = \{x : Ax = 0, x \in \mathbb{C}^n\} \subset \mathbb{C}^n$$

为 A 的列空间 (值域) 和零空间 (核).



Back

Close



容易验证: 若将 A 按列划分为 $A = [\mathbf{a}_1, \mathbf{a}_2, \cdots, \mathbf{a}_n]$, 则

$$\mathcal{R}(A) = \text{span}\{\mathbf{a}_1, \mathbf{a}_2, \cdots, \mathbf{a}_n\}.$$

给定两个向量子空间 \mathcal{S}_1 和 \mathcal{S}_2 , 它们的和 \mathcal{S} 是一个子空间, 其每一个向量都是 \mathcal{S}_1 的一个向量与 \mathcal{S}_2 的一个向量之和. 两个子空间的交也是一个子空间. 如果 \mathcal{S}_1 和 \mathcal{S}_2 的交退化为 $\{0\}$, 则 \mathcal{S}_1 和 \mathcal{S}_2 之和称为直和, 表示为 $\mathcal{S} = \mathcal{S}_1 \oplus \mathcal{S}_2$. 当 \mathcal{S} 等于 \mathbb{C}^n 时, 则 \mathbb{C}^n 的每一个向量 \mathbf{x} 可被唯一地写成 $\mathbf{x} = \mathbf{x}_1 + \mathbf{x}_2$, 其中 $\mathbf{x}_1 \in \mathcal{S}_1, \mathbf{x}_2 \in \mathcal{S}_2$.

关于矩阵 $A \in \mathbb{C}^{m \times n}$ 的列空间和零空间有下面的正交分解:

$$\mathcal{R}(A) \oplus \mathcal{N}(A^H) = \mathbb{C}^m, \quad \mathcal{N}(A) \oplus \mathcal{R}(A^H) = \mathbb{C}^n.$$

此外, 当 $A\mathcal{S} \subset \mathcal{S}$ 时, 称子空间 \mathcal{S} 在矩阵 A 之下是不变的. 易见, 矩阵 $A \in \mathbb{C}^{n \times n}$ 的列空间 $\mathcal{R}(A)$ 和零空间 $\mathcal{N}(A)$ 都是 A 的不变子空间. 特别地, 对 A 的任意特征值 λ , 子空间 $\mathcal{N}(A - \lambda I)$ 在 A 下





不变. 子空间 $\mathcal{N}(\mathbf{A} - \lambda \mathbf{I})$ 称为相应于 λ 的特征子空间, 它包含零向量及 \mathbf{A} 的所有相应于 λ 的特征向量.

定理 1.9 在 \mathbf{A} 的奇异值分解式 (1.5) 中, 记 \mathbf{U} 和 \mathbf{V} 的列向量分别为 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_m$ 和 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$, 则

(1) \mathbf{A} 的秩等于其非零奇异值的个数.

(2) $\|\mathbf{A}\|_2 = \max_{1 \leq i \leq n} \sigma_i$. 设 σ_1 为最大奇异值, 其对应的右奇异向量为 \mathbf{v}_1 , 则 $\|\mathbf{A}\|_2 = \|\mathbf{A}\mathbf{v}_1\|_2$.

(3) $\mathcal{N}(\mathbf{A}) = \text{span} \{\mathbf{v}_{r+1}, \mathbf{v}_{r+2}, \dots, \mathbf{v}_n\}$.

(4) $\mathcal{R}(\mathbf{A}) = \text{span} \{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_r\}$.

(5) $\mathbf{A} = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^H$.



Back

Close



证明 沿用定理 1.8 中的记号, 式 (1.5) 可写为

$$\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^H = [\mathbf{U}_1, \mathbf{U}_2] \begin{bmatrix} \mathbf{\Sigma}_r & \mathbf{O} \\ \mathbf{O} & \mathbf{O} \end{bmatrix} \begin{bmatrix} \mathbf{V}_1^H \\ \mathbf{V}_2^H \end{bmatrix} = \mathbf{U}_1 \mathbf{\Sigma}_r \mathbf{V}_1^H. \quad (1.11)$$

(1) 由于 \mathbf{U} 和 \mathbf{V} 都是非奇异矩阵, 故立即有 $\text{rank}(\mathbf{A}) = \text{rank}(\mathbf{\Sigma}) = r$.

(2) 注意到 \mathbf{U} 和 \mathbf{V} 都是酉矩阵, 故有

$$\begin{aligned} \|\mathbf{A}\|_2 &= \max_{\|\mathbf{x}\|_2=1} \|\mathbf{A}\mathbf{x}\|_2 = \max_{\|\mathbf{x}\|_2=1} \|\mathbf{U} \mathbf{\Sigma} \mathbf{V}^H \mathbf{x}\|_2 = \max_{\|\mathbf{y}\|_2=1} \|\mathbf{\Sigma} \mathbf{y}\|_2 \\ &= \max \left\{ [(\sigma_1 y_1)^2 + (\sigma_2 y_2)^2 + \cdots + (\sigma_n y_n)^2]^{1/2} : \|\mathbf{y}\|_2 = 1 \right\} \\ &= \max_{1 \leq i \leq n} \sigma_i. \end{aligned}$$



Back

Close

设 σ_1 为最大奇异值, 其对应的右奇异向量为 \mathbf{v}_1 , 则

$$\|\mathbf{A}\mathbf{v}_1\|_2 = \|\mathbf{U}\boldsymbol{\Sigma}\mathbf{V}^H\mathbf{v}_1\|_2 = \|\boldsymbol{\Sigma}\mathbf{e}_1\|_2 = \sigma_1 = \|\mathbf{A}\|_2.$$

(3) 有

$$\begin{aligned}\mathcal{N}(\mathbf{A}) &= \{\mathbf{x} : \mathbf{A}\mathbf{x} = \mathbf{0}\} = \{\mathbf{x} : \mathbf{U}_1\boldsymbol{\Sigma}_r\mathbf{V}_1^H\mathbf{x} = \mathbf{0}\} = \{\mathbf{x} : \mathbf{V}_1^H\mathbf{x} = \mathbf{0}\} \\ &= \{\mathbf{x} : \mathbf{x} = k_{r+1}\mathbf{v}_{r+1} + \cdots + k_n\mathbf{v}_n, k_i \in \mathbb{C}\} \\ &= \text{span}\{\mathbf{v}_{r+1}, \mathbf{v}_{r+2}, \cdots, \mathbf{v}_n\}.\end{aligned}$$

(4) 由于

$$\begin{aligned}\mathcal{R}(\mathbf{A}) &= \{\mathbf{y} : \mathbf{y} = \mathbf{A}\mathbf{x}\} = \{\mathbf{y} : \mathbf{y} = \mathbf{U}_1(\boldsymbol{\Sigma}_r\mathbf{V}_1^H\mathbf{x})\} \subset \mathcal{R}(\mathbf{U}_1), \\ \mathcal{R}(\mathbf{U}_1) &= \{\mathbf{y} : \mathbf{y} = \mathbf{U}_1\mathbf{z}\} = \{\mathbf{y} : \mathbf{y} = (\mathbf{U}_1\boldsymbol{\Sigma}_r\mathbf{V}_1^T)(\mathbf{V}_1\boldsymbol{\Sigma}_r^{-1}\mathbf{z})\} \\ &= \{\mathbf{y} : \mathbf{y} = \mathbf{A}(\mathbf{V}_1\boldsymbol{\Sigma}_r^{-1}\mathbf{z})\} \subset \mathcal{R}(\mathbf{A}),\end{aligned}$$

故 $\mathcal{R}(\mathbf{A}) = \mathcal{R}(\mathbf{U}_1) = \text{span}\{\mathbf{u}_1, \mathbf{u}_2, \cdots, \mathbf{u}_r\}$.





(5) 直接计算式 (1.11), 得

$$\begin{aligned} \mathbf{A} &= [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_r] \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix} \begin{bmatrix} \mathbf{v}_1^H \\ \vdots \\ \mathbf{v}_r^H \end{bmatrix} \\ &= [\sigma_1 \mathbf{u}_1, \sigma_2 \mathbf{u}_2, \dots, \sigma_r \mathbf{u}_r] \begin{bmatrix} \mathbf{v}_1^H \\ \vdots \\ \mathbf{v}_r^H \end{bmatrix} \\ &= \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^H. \end{aligned}$$

证毕. □

下面的定理表明奇异值可以刻画一个矩阵与更低秩的矩阵之间的距离.

定理 1.10 设 $\mathbf{A} \in \mathbb{C}_r^{m \times n}$, 它的奇异值分解由定理 1.8 给出,



Back

Close

其中 $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ 为其非零奇异值, 则有

$$\min_{\text{rank}(\mathbf{B})=k} \|\mathbf{A} - \mathbf{B}\|_2 = \|\mathbf{A} - \mathbf{A}_k\|_2 = \sigma_{k+1}, \quad 0 \leq k \leq r-1, \quad (1.12)$$

式中:

$$\mathbf{A}_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^{\text{H}}, \quad k > 0, \quad \mathbf{A}_0 = \mathbf{O}. \quad (1.13)$$

证明 当 $k=0$ 时, $\|\mathbf{A}\|_2 = \sigma_1$, 结论显然成立. 设 $k > 0$, 由 \mathbf{A}_k 的定义及 \mathbf{A} 的奇异值分解, 有

$$\mathbf{U}^{\text{H}} \mathbf{A}_k \mathbf{V} = \text{diag}(\sigma_1, \cdots, \sigma_k, 0, \cdots, 0),$$

$$\mathbf{U}^{\text{H}} \mathbf{A} \mathbf{V} = \text{diag}(\sigma_1, \cdots, \sigma_k, \sigma_{k+1}, \cdots, \sigma_n).$$

于是有

$$\mathbf{U}^{\text{H}} (\mathbf{A} - \mathbf{A}_k) \mathbf{V} = \text{diag}(0, \cdots, 0, \sigma_{k+1}, \cdots, \sigma_n).$$





注意到 σ_{k+1} 是 $A - A_k$ 的最大奇异值, 立即有 $\|A - A_k\|_2 = \sigma_{k+1}$.
 由于 $\text{rank}(A_k) = k$, 故

$$\min_{\text{rank}(B)=k} \|A - B\|_2 \leq \|A - A_k\|_2 = \sigma_{k+1}.$$

下证任意秩为 k 的 $m \times n$ 阶矩阵 B , 均有 $\|A - B\|_2 \geq \sigma_{k+1}$.
 由于 $\text{rank}(B) = k$, 故 B 的零空间 $\mathcal{N}(B) = \{x : Bx = 0\}$ 的维数为 $n - k$, 故存在单位正交向量 x_1, \dots, x_{n-k} 使得 $\mathcal{N}(B) = \text{span}\{x_1, \dots, x_{n-k}\}$. 利用维数定理可知

$$\mathcal{S} := \text{span}\{x_1, \dots, x_{n-k}\} \cap \text{span}\{v_1, \dots, v_{k+1}\} \neq \{0\}.$$

在 \mathcal{S} 中取一非零单位向量 z , 即 z 满足 $\|z\|_2 = 1$, $Bz = 0$ 及

$$z = \sum_{i=1}^{k+1} \alpha_i v_i, \quad Az = \sum_{i=1}^{k+1} \alpha_i Av_i = \sum_{i=1}^{k+1} \sigma_i \alpha_i u_i.$$





注意到 $\|z\|_2^2 = \sum_{i=1}^{k+1} \alpha_i^2 = 1$, 立即有

$$\|A - B\|_2^2 \geq \|(A - B)z\|_2^2 = \|Az\|_2^2 = \sum_{i=1}^{k+1} \sigma_i^2 \alpha_i^2 \geq \sigma_{k+1}^2.$$

证毕. □

§1.2.4 矩阵的极分解和满秩分解

本节讨论矩阵的极分解和满秩分解. 极分解是指将一个复方阵分解为一个酉矩阵和 Hermite 半正定矩阵的乘积. 满秩分解是指将一个非零矩阵分解成列满秩矩阵和行满秩矩阵的乘积, 它是研究广义逆矩阵的重要工具之一. 对于极分解有下面的定理.

定理 1.11 设 $A \in \mathbb{C}^{n \times n}$. 则存在 n 阶酉矩阵 U 和 n 阶



Back

Close

Hermite 半正定矩阵 \mathbf{H} , 使得

$$\mathbf{A} = \mathbf{H}\mathbf{U}. \quad (1.14)$$

若 \mathbf{A} 是非奇异矩阵, 则上述分解是唯一的, 此时, \mathbf{H} 是 Hermite 正定矩阵.

证明 由奇异值分解定理可知, 存在酉矩阵 \mathbf{P} 和 \mathbf{Q} 使得

$$\mathbf{A} = \mathbf{P} \begin{bmatrix} \boldsymbol{\Sigma}_r & \mathbf{O} \\ \mathbf{O} & \mathbf{O} \end{bmatrix} \mathbf{Q}^{\mathrm{H}},$$

式中: $\boldsymbol{\Sigma}_r = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$, $\sigma_i > 0$ 为 \mathbf{A} 的奇异值; $r = \text{rank}(\mathbf{A})$. 将上式改写为

$$\mathbf{A} = \mathbf{P} \begin{bmatrix} \boldsymbol{\Sigma}_r & \mathbf{O} \\ \mathbf{O} & \mathbf{O} \end{bmatrix} \mathbf{P}^{\mathrm{H}} \mathbf{P} \mathbf{Q}^{\mathrm{H}},$$



令

$$H = P \begin{bmatrix} \Sigma_r & O \\ O & O \end{bmatrix} P^H, \quad U = PQ^H,$$

容易验证 H 为 Hermite 半正定矩阵, 而 U 为酉矩阵.

下面证明当 A 非奇异时分解是唯一的. 事实上, 若 A 还有极分解 $A = H_1 U_1$, 即

$$A = HU = H_1 U_1,$$

式中: U, U_1 为酉矩阵; H, H_1 为 Hermite 正定矩阵. 注意到

$$AA^H = H^2 = H_1^2,$$

则由定理 1.2 可知 $H_1 = H$. 于是, $U_1 = H_1^{-1}A = H^{-1}A = U$. 证毕. □



51/112



Back

Close



注 1.3 若定理 1.11 中的矩阵 A 是实方阵, 则分解式中的 U 和 H 分别为正交矩阵和对称半正定矩阵.

下面讨论满秩分解.

定义 1.11 设 $A \in \mathbb{C}_r^{m \times n} (r > 0)$, 若存在列满秩矩阵 $F \in \mathbb{C}_r^{m \times r}$ 和行满秩矩阵 $G \in \mathbb{C}_r^{r \times n}$, 使得 $A = FG$, 则称 FG 为 A 的一个满秩分解.

定理 1.12 设 $A \in \mathbb{C}_r^{m \times n} (r > 0)$, 则存在 $F \in \mathbb{C}_r^{m \times r}$ 和 $G \in \mathbb{C}_r^{r \times n}$, 使得 $A = FG$.

证明 利用初等变换, 可将 A 化为阶梯形矩阵

$$B = \begin{bmatrix} G \\ O \end{bmatrix}, \quad (G \in \mathbb{C}_r^{r \times n}),$$



Back

Close



即存在有限个初等矩阵的乘积 $P \in \mathbb{C}^{m \times m}$, 使得 $PA = B$. 由于 P 可逆, 划分

$$P^{-1} = [F, S], \quad (F \in \mathbb{C}_r^{m \times r}, S \in \mathbb{C}^{m \times (m-r)}).$$

于是有

$$A = P^{-1}B = [F, S] \begin{bmatrix} G \\ O \end{bmatrix} = FG.$$

证毕. □

例 1.1 求下列矩阵的满秩分解:

$$A = \begin{bmatrix} -1 & 0 & 1 & 2 \\ 1 & 2 & -1 & 1 \\ 2 & 2 & -2 & -1 \end{bmatrix}.$$



Back

Close



解 由

$$[\mathbf{A}, \mathbf{I}] = \left[\begin{array}{cccc|ccc} -1 & 0 & 1 & 2 & 1 & 0 & 0 \\ 1 & 2 & -1 & 1 & 0 & 1 & 0 \\ 2 & 2 & -2 & -1 & 0 & 0 & 1 \end{array} \right] \xrightarrow{\text{行}} \left[\begin{array}{cccc|ccc} -1 & 0 & 1 & 2 & 1 & 0 & 0 \\ 0 & 2 & 0 & 3 & 1 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 & -1 & 1 \end{array} \right],$$

可知

$$\mathbf{P} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & -1 & 1 \end{bmatrix}, \quad \mathbf{P}^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ -2 & 1 & 1 \end{bmatrix},$$

于是有

$$\mathbf{F} = \begin{bmatrix} 1 & 0 \\ -1 & 1 \\ -2 & 1 \end{bmatrix}, \quad \mathbf{G} = \begin{bmatrix} -1 & 0 & 1 & 2 \\ 0 & 2 & 0 & 3 \end{bmatrix}, \quad \mathbf{A} = \mathbf{F}\mathbf{G}.$$



Back

Close



定理 1.12 提供的算法求矩阵的满秩分解时需要计算矩阵 P 及 P^{-1} 的前 r 列, 这在高维情形计算量是巨大的. 下面介绍一种避免求逆矩阵的方法.

定义 1.12 设 $B \in \mathbb{C}_r^{m \times n} (r > 0)$ 满足: ① B 的后 $m - r$ 行上的元素都是零; ② B 中有 r 个列 (c_1 列, \dots , c_r 列) 构成 I_m 的前 r 个列. 则称 B 为拟 Hermite 标准形.

定理 1.13 设 $A \in \mathbb{C}_r^{m \times n} (r > 0)$ 经过初等行变换化为拟 Hermite 标准形 B , 那么 A 有满秩分解 $A = FG$, 其中 F 是由“ A 的 c_1 列, \dots , c_r 列”构成的矩阵, G 是由“ B 的前 r 行”构成的矩阵.

证明 经过初等行变换将 A 化为拟 Hermite 标准形 B , 等价于存在可逆矩阵 $P \in \mathbb{C}^{m \times m}$, 使得 $PA = B$, 或者 $A = P^{-1}B$.



Back

Close



根据 B 中的列标 c_1, \dots, c_r 构造 n 阶置换矩阵

$$P_1 = [e_{c_1}, \dots, e_{c_r}, e_{c_{r+1}}, \dots, e_{c_n}],$$

并对矩阵 A 和 B 按列分块:

$$A = [a_1, a_2, \dots, a_n], \quad B = [b_1, b_2, \dots, b_n].$$

于是可得

$$\begin{aligned} AP_1 &= [a_{c_1}, \dots, a_{c_r}, a_{c_{r+1}}, \dots, a_{c_n}], \\ BP_1 &= [b_{c_1}, \dots, b_{c_r}, b_{c_{r+1}}, \dots, b_{c_n}] = \begin{bmatrix} I_r & B_{12} \\ O & O \end{bmatrix}. \end{aligned}$$

划分 $P^{-1} = [F, S]$, 其中 $F \in \mathbb{C}_r^{m \times r}$, $S \in \mathbb{C}^{m \times (m-r)}$. 根据定理 1.12 可得满秩分解 $A = FG$, 且 G 是由“ B 的前 r 行”构成的矩阵.



由于

$$AP_1 = P^{-1}(BP_1) = [F, S] \begin{bmatrix} I_r & B_{12} \\ O & O \end{bmatrix} = [F, FB_{12}].$$

所以 F 是由 “ AP_1 的前 r 列” 构成的矩阵, 也就是由 “ A 的 c_1 列, \dots , c_r 列” 构成的矩阵. 证毕. \square

例 1.2 求下列矩阵的满秩分解:

$$A = \begin{bmatrix} 2 & 1 & 0 & 2 \\ 0 & 0 & 1 & 2 \\ 2 & 1 & 1 & 4 \end{bmatrix}.$$

解 注意到

$$A \xrightarrow{\text{行}} \begin{bmatrix} 2 & 1 & 0 & 2 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$



为拟 Hermite 标准形, 且 $c_1 = 2$, $c_2 = 3$, 故

$$\mathbf{F} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}, \quad \mathbf{G} = \begin{bmatrix} 2 & 1 & 0 & 2 \\ 0 & 0 & 1 & 2 \end{bmatrix}, \quad \mathbf{A} = \mathbf{FG}.$$



58/112



Back

Close



§1.3 向量和矩阵的范数

在许多实际问题中, 常需对同一线性空间中的向量 (或矩阵) 引入作为它们“大小”的一种度量, 进而比较两个向量 (或矩阵) 的“接近”程度. 引入这种体现其“大小”的量就是范数, 它们在理论与实际应用中都占有重要的地位.

§1.3.1 向量内积与向量范数

定义 1.13 设 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T \in \mathbb{C}^n$, $\mathbf{y} = (y_1, y_2, \dots, y_n)^T \in \mathbb{C}^n$, 称复数

$$(\mathbf{x}, \mathbf{y}) := \mathbf{y}^H \mathbf{x} = \sum_{i=1}^n x_i \bar{y}_i$$



Back

Close

为向量 \boldsymbol{x} 和 \boldsymbol{y} 的 (欧几里得) 内积或数量积. 而称

$$\|\boldsymbol{x}\|_2 = (\boldsymbol{x}, \boldsymbol{x})^{\frac{1}{2}} = \left(\sum_{i=1}^n |x_i|^2 \right)^{\frac{1}{2}} \quad (1.15)$$

为向量 \boldsymbol{x} 的 (欧几里得) 范数或 2-范数.

内积的一个重要性质是

$$(\boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}) = (\boldsymbol{x}, \boldsymbol{A}^{\text{H}}\boldsymbol{y}), \quad \boldsymbol{A} \in \mathbb{C}^{m \times n}, \quad \boldsymbol{x} \in \mathbb{C}^n, \quad \boldsymbol{y} \in \mathbb{C}^m. \quad (1.16)$$

\mathbb{C}^n 中的欧几里得内积与欧几里得范数还具有下列性质.

性质 1.6 设 $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{C}^n$, 则

- (1) $(\boldsymbol{x}, \boldsymbol{x}) = 0$ 当且仅当 $\boldsymbol{x} = \mathbf{0}$.
- (2) $(\lambda\boldsymbol{x}, \boldsymbol{y}) = \lambda(\boldsymbol{x}, \boldsymbol{y}), (\boldsymbol{x}, \lambda\boldsymbol{y}) = \bar{\lambda}(\boldsymbol{x}, \boldsymbol{y}), \forall \lambda \in \mathbb{C}$.
- (3) $(\boldsymbol{x}, \boldsymbol{y}) = \overline{(\boldsymbol{y}, \boldsymbol{x})}$.



60/112



Back

Close



$$(4) \quad (\mathbf{x}_1 + \mathbf{x}_2, \mathbf{y}) = (\mathbf{x}_1, \mathbf{y}) + (\mathbf{x}_2, \mathbf{y}).$$

$$(5) \quad \text{Cauchy-Schwarz 不等式: } |(\mathbf{x}, \mathbf{y})| \leq \|\mathbf{x}\|_2 \cdot \|\mathbf{y}\|_2.$$

$$(6) \quad \text{三角不等式: } \|\mathbf{x} + \mathbf{y}\|_2 \leq \|\mathbf{x}\|_2 + \|\mathbf{y}\|_2.$$

由 Schwarz 不等式容易证明

$$\|\mathbf{x}\|_2 = \max_{\|\mathbf{y}\|_2=1} |\mathbf{y}^H \mathbf{x}|, \quad \mathbf{x} \in \mathbb{C}^n. \quad (1.17)$$

下面给出向量范数的一般定义.

定义 1.14 给定 \mathbb{C}^n 中的某个实值函数 $\mathfrak{N}(\mathbf{x}) = \|\mathbf{x}\|$. 若对任意的 $\mathbf{x}, \mathbf{y} \in \mathbb{C}^n$ 有

$$(1) \quad \|\mathbf{x}\| \geq 0, \text{ 且 } \|\mathbf{x}\| = 0 \text{ 当且仅当 } \mathbf{x} = \mathbf{0}.$$

$$(2) \quad \|\lambda \mathbf{x}\| = |\lambda| \cdot \|\mathbf{x}\|, \quad \forall \lambda \in \mathbb{C}.$$

$$(3) \quad \|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|.$$

则称 $\|\mathbf{x}\|$ 为向量 \mathbf{x} 的范数. 定义了范数的线性空间称为赋范线性空间.



Back

Close



常用的向量范数有

$$(1) \quad \|\mathbf{x}\|_{\infty} = \max_{1 \leq i \leq n} |x_i| \quad (\infty\text{-范数}).$$

$$(2) \quad \|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i| \quad (1\text{-范数}).$$

$$(3) \quad \|\mathbf{x}\|_2 = \left(\sum_{i=1}^n |x_i|^2 \right)^{1/2} \quad (2\text{-范数}).$$

$$(4) \quad \|\mathbf{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p} \quad (p\text{-范数}).$$

不难证明, 当 $p \rightarrow \infty$ 时, 对于任意的 $\mathbf{x} \in \mathbb{C}^n$, 都有 $\|\mathbf{x}\|_p \rightarrow \|\mathbf{x}\|_{\infty}$. 此外, 由于 $|\|\mathbf{x}\| - \|\mathbf{y}\|| \leq \|\mathbf{x} - \mathbf{y}\|$, 故向量范数是 \mathbb{C}^n 中的连续函数.

性质 1.7 (向量范数的连续性) \mathbb{C}^n 中的向量范数 $\|\mathbf{x}\|$ 是 \mathbb{C}^n 中的连续函数.



Back

Close



性质 1.8 (向量范数的等价性) 设 $\|\mathbf{x}\|$ 和 $\|\mathbf{x}\|'$ 是 \mathbb{C}^n 中的任意两种范数, 则成立

$$c_1 \|\mathbf{x}\| \leq \|\mathbf{x}\|' \leq c_2 \|\mathbf{x}\|, \quad \mathbf{x} \in \mathbb{C}^n, \quad (1.18)$$

式中: $c_1, c_2 > 0$ 为与向量 \mathbf{x} 无关的常数.

定义 1.15 设 $\{\mathbf{x}^{(k)} = (x_1^{(k)}, x_2^{(k)}, \dots, x_n^{(k)})^T\}_{k=0}^\infty$ 是 \mathbb{C}^n 中的向量序列, $\mathbf{x} = (x_1, x_2, \dots, x_n)^T \in \mathbb{C}^n$. 若

$$\lim_{k \rightarrow \infty} x_i^{(k)} = x_i, \quad i = 1, 2, \dots, n,$$

则称序列 $\{\mathbf{x}^{(k)}\}$ 收敛于 \mathbf{x} , 记为 $\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{x}$.

利用范数的等价性可以得到向量序列收敛的充分必要条件.

定理 1.14 $\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{x}$ 当且仅当 $\lim_{k \rightarrow \infty} \|\mathbf{x}^{(k)} - \mathbf{x}\| = 0$, 其中 $\|\cdot\|$ 是 \mathbb{C}^n 中任意的向量范数.



Back

Close

§1.3.2 矩阵范数与内积

将 $m \times n$ 阶矩阵 \mathbf{A} 看作线性空间 $\mathbb{C}^{m \times n}$ 中的元素, 则完全可以按照定义 1.14 的方式引入矩阵的范数. 其中最常用的是与向量 2-范数相对应的范数

$$\|\mathbf{A}\|_{\text{F}} = \left(\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2 \right)^{1/2} \quad (1.19)$$

称为矩阵 \mathbf{A} 的 Frobenius 范数, 简称 F-范数.

利用奇异值分解定理, 容易证明

$$\|\mathbf{A}\|_{\text{F}} = \left(\sum_{i=1}^n \sigma_i^2 \right)^{1/2},$$

式中: $\sigma_1, \sigma_2, \dots, \sigma_n$ 为矩阵 \mathbf{A} 奇异值.

类似于向量范数的定义, 可以给出矩阵范数的一般定义.





定义 1.16 给定 $\mathbb{C}^{m \times n}$ 中的某个实值函数 $\mathfrak{N}(\mathbf{A}) = \|\mathbf{A}\|$. 若对任意的 $\mathbf{A}, \mathbf{B} \in \mathbb{C}^{m \times n}$ 有

(1) $\|\mathbf{A}\| \geq 0$, 且 $\|\mathbf{A}\| = 0$ 当且仅当 $\mathbf{A} = \mathbf{O}$.

(2) $\|\lambda \mathbf{A}\| = |\lambda| \cdot \|\mathbf{A}\|, \forall \lambda \in \mathbb{C}$.

(3) $\|\mathbf{A} + \mathbf{B}\| \leq \|\mathbf{A}\| + \|\mathbf{B}\|$.

则称 $\|\mathbf{A}\|$ 为矩阵 \mathbf{A} 的范数. 若矩阵范数满足

$$\|\mathbf{A}\mathbf{x}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{x}\|, \quad \forall \mathbf{x} \in \mathbb{C}^n, \mathbf{A} \in \mathbb{C}^{m \times n},$$

则称矩阵范数 $\|\cdot\|$ 和向量范数 $\|\cdot\|$ 是相容的, 其中 $\|\mathbf{A}\mathbf{x}\|$ 和 $\|\mathbf{x}\|$ 分别是 \mathbb{C}^m 和 \mathbb{C}^n 中的向量范数.

跟向量范数的等价性一样, 可以证明 $\mathbb{C}^{m \times n}$ 中的任意两个矩阵范数也等价, 即存在与矩阵 \mathbf{A} 无关的常数 $c_1, c_2 > 0$ 使得

$$c_1 \|\mathbf{A}\| \leq \|\mathbf{A}\|' \leq c_2 \|\mathbf{A}\|.$$





定义 1.17 设 $A \in \mathbb{C}^{m \times n}$, 给定一种向量范数 $\|\cdot\|$, 定义矩阵范数

$$\|A\| = \max_{\|x\| \neq 0} \frac{\|Ax\|}{\|x\|} = \max_{\|x\|=1} \|Ax\|. \quad (1.20)$$

称 $\|A\|$ 为 $\mathbb{C}^{m \times n}$ 中矩阵 A 的算子范数, 或称由该向量范数诱导出来的矩阵范数.

容易证明, 矩阵的算子范数与相应的向量范数是相容的, 且

$$\|AB\| \leq \|A\| \cdot \|B\|, \quad A \in \mathbb{C}^{m \times n}, \quad B \in \mathbb{C}^{n \times p},$$

其中矩阵范数都是由某个向量范数诱导出来的算子范数.

给定 \mathbb{C}^n 中的向量 p -范数, 可以诱导出相应的矩阵 p -算子范数, 记为 $\|\cdot\|_p$. 下面是三种常用的矩阵算子范数.

定理 1.15 设 $A = (a_{ij}) \in \mathbb{C}^{m \times n}$, 则



(1) $\|\mathbf{A}\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$, 称为行和范数或 ∞ -范数.

(2) $\|\mathbf{A}\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$, 称为列和范数或 1-范数.

(3) $\|\mathbf{A}\|_2 = \sigma_1 = \sqrt{\lambda_{\max}(\mathbf{A}^H \mathbf{A})}$, 称为谱范数或 2-范数, 其中 σ_1 是矩阵 \mathbf{A} 的最大奇异值, $\lambda_{\max}(\mathbf{A}^H \mathbf{A})$ 表示矩阵 $\mathbf{A}^H \mathbf{A}$ 的最大特征值.

证明 先证明 (1). 记 $\sigma = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$. 则对任意满足 $\|\mathbf{x}\|_\infty = 1$ 的向量 $\mathbf{x} \in \mathbb{C}^n$, 有

$$\begin{aligned} \|\mathbf{Ax}\|_\infty &= \max_{1 \leq i \leq m} \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}| \cdot |x_j| \\ &\leq \left(\max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}| \right) \|\mathbf{x}\|_\infty = \sigma. \end{aligned} \quad (1.21)$$



Back

Close



另外, 不妨设 $\sigma = \sum_{j=1}^n |a_{i_0j}|$. 取

$$\tilde{\mathbf{x}} = (\text{sign}(a_{i_01}), \text{sign}(a_{i_02}), \dots, \text{sign}(a_{i_0n}))^T,$$

则 $\mathbf{A} \neq \mathbf{O}$ 蕴含着 $\|\tilde{\mathbf{x}}\|_\infty = 1$. 由 $|a| = \text{sign}(a)a$, 有

$$\|\mathbf{A}\tilde{\mathbf{x}}\|_\infty = \max_{1 \leq i \leq m} \left| \sum_{j=1}^n a_{ij}\tilde{x}_j \right| \geq \left| \sum_{j=1}^n a_{i_0j}\tilde{x}_j \right| = \sum_{j=1}^n |a_{i_0j}| = \sigma. \quad (1.22)$$

结论 (2) 的证明与结论 (1) 类似. 最后给出结论 (3) 的证明. 注意到 $\mathbf{A}^H \mathbf{A} \in \mathbb{C}^{n \times n}$ 是 Hermite 半正定矩阵, 故其特征值为 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$, 相应的单位正交特征向量为 $\boldsymbol{\xi}_1, \boldsymbol{\xi}_2, \dots, \boldsymbol{\xi}_n \in \mathbb{C}^n$. 因此, 对任意满足 $\|\mathbf{x}\|_2 = 1$ 的向量 $\mathbf{x} \in \mathbb{C}^n$, 有

$$\mathbf{x} = \sum_{i=1}^n c_i \boldsymbol{\xi}_i, \quad \sum_{i=1}^n c_i^2 = 1.$$



Back

Close

于是有

$$\begin{aligned}\mathbf{x}^H \mathbf{A}^H \mathbf{A} \mathbf{x} &= \left(\sum_{i=1}^n c_i \boldsymbol{\xi}_i \right)^H \sum_{j=1}^n c_j \mathbf{A}^H \mathbf{A} \boldsymbol{\xi}_j \\ &= \left(\sum_{i=1}^n c_i \boldsymbol{\xi}_i \right)^H \sum_{j=1}^n c_j \lambda_j \boldsymbol{\xi}_j \\ &= \sum_{i=1}^n c_i^2 \lambda_i \boldsymbol{\xi}_i^H \boldsymbol{\xi}_i = \sum_{i=1}^n c_i^2 \lambda_i \leq \lambda_1.\end{aligned}$$

注意到

$$\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|_2=1} \|\mathbf{A}\mathbf{x}\|_2 = \max_{\|\mathbf{x}\|_2=1} (\mathbf{x}^H \mathbf{A}^H \mathbf{A} \mathbf{x})^{1/2},$$

故 $\|\mathbf{A}\|_2 \leq \sqrt{\lambda_1}$. 取 $\mathbf{x} = \boldsymbol{\xi}_1$, 则有

$$\mathbf{x}^H \mathbf{A}^H \mathbf{A} \mathbf{x} = \boldsymbol{\xi}_1^H \mathbf{A}^H \mathbf{A} \boldsymbol{\xi}_1 = \lambda_1 \boldsymbol{\xi}_1^H \boldsymbol{\xi}_1 = \lambda_1,$$



69/112



故

$$\begin{aligned}\|\mathbf{A}\|_2 &= \max_{\|\mathbf{x}\|_2=1} \|\mathbf{Ax}\|_2 = \max_{\|\mathbf{x}\|_2=1} (\mathbf{x}^H \mathbf{A}^H \mathbf{Ax})^{1/2} \\ &\geq (\boldsymbol{\xi}_1^H \mathbf{A}^H \mathbf{A} \boldsymbol{\xi}_1)^{1/2} = (\lambda_1 \boldsymbol{\xi}_1^H \boldsymbol{\xi}_1)^{1/2} = \sqrt{\lambda_1}.\end{aligned}$$

因此 $\|\mathbf{A}\|_2 = \sqrt{\lambda_1} = \sqrt{\lambda_{\max}(\mathbf{A}^H \mathbf{A})}$. 证毕. \square

与矩阵的行和范数及列和范数相比, 矩阵的谱范数显得不易计算, 但它有良好的分析性质.

定理 1.16 设 $\mathbf{A} \in \mathbb{C}^{m \times n}$, 则

$$(1) \quad \|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|_2=\|\mathbf{y}\|_2=1} |\mathbf{y}^H \mathbf{Ax}|.$$

$$(2) \quad \|\mathbf{A}^H\|_2 = \|\mathbf{A}^T\|_2 = \|\mathbf{A}\|_2.$$

$$(3) \quad \|\mathbf{A}^H \mathbf{A}\|_2 = \|\mathbf{A}\|_2^2.$$

$$(4) \quad \|\mathbf{A}\|_2^2 \leq \|\mathbf{A}\|_1 \cdot \|\mathbf{A}\|_\infty.$$





$$(5) \quad \|\mathbf{A}\|_2 \leq \|\mathbf{A}\|_F.$$

(6) 设 $\mathbf{U} \in \mathbb{C}^{m \times m}$ 和 $\mathbf{V} \in \mathbb{C}^{n \times n}$ 满足 $\mathbf{U}^H \mathbf{U} = \mathbf{I}_m$ 和 $\mathbf{V}^H \mathbf{V} = \mathbf{I}_n$, 则 $\|\mathbf{U} \mathbf{A} \mathbf{V}\|_2 = \|\mathbf{A}\|_2$.

证明 由算子范数的定义, 存在 $\mathbf{x}_0 \in \mathbb{C}^n$ 满足 $\|\mathbf{x}_0\|_2 = 1$ 和 $\|\mathbf{A}\|_2 = \|\mathbf{A} \mathbf{x}_0\|_2$. 由式 (1.17) 知,

$$\|\mathbf{A} \mathbf{x}_0\|_2 = \max_{\|\mathbf{y}\|_2=1} |\mathbf{y}^H \mathbf{A} \mathbf{x}_0|,$$

这意味着成立

$$\|\mathbf{A}\|_2 = \|\mathbf{A} \mathbf{x}_0\|_2 \leq \max_{\|\mathbf{x}\|_2=1, \|\mathbf{y}\|_2=1} |\mathbf{y}^H \mathbf{A} \mathbf{x}|.$$

另外, 由 Schwarz 不等式及范数的相容性, 有

$$|\mathbf{y}^H \mathbf{A} \mathbf{x}| \leq \|\mathbf{y}\|_2 \cdot \|\mathbf{A} \mathbf{x}\|_2 \leq \|\mathbf{y}\|_2 \cdot \|\mathbf{A}\|_2 \cdot \|\mathbf{x}\|_2,$$



Back

Close

故

$$\max_{\|x\|_2=1, \|y\|_2=1} |y^H A x| \leq \|A\|_2,$$

这就证明了结论 (1) .

由结论 (1) 有

$$\begin{aligned} \|A^T\|_2 &= \max_{\|x\|_2=\|y\|_2=1} |y^H A^T x| = \max_{\|x\|_2=\|y\|_2=1} |\bar{x}^H A \bar{y}| \\ &= \max_{\|\bar{x}\|_2=\|\bar{y}\|_2=1} |\bar{x}^H A \bar{y}| = \|A\|_2, \end{aligned}$$

式中: \bar{x}, \bar{y} 为 x, y 的共轭向量, 这里用到了一个标量与其转置相等.

同理, 有

$$\|A^H\|_2 = \max_{\|x\|_2=\|y\|_2=1} |y^H A^H x| = \max_{\|x\|_2=\|y\|_2=1} |x^H A y| = \|A\|_2,$$



72/112



Back

Close



这里用到了一个复数的模与其共轭转置的模相等. 至此证明了结论 (2).

注意到 $\mathbf{A}^H \mathbf{A}$ 是 Hermite 矩阵, 故由谱范数的定义, 有

$$\begin{aligned}\|\mathbf{A}^H \mathbf{A}\|_2 &= \sqrt{\lambda_{\max}((\mathbf{A}^H \mathbf{A})^H (\mathbf{A}^H \mathbf{A}))} = \sqrt{\lambda_{\max}((\mathbf{A}^H \mathbf{A})^2)} \\ &= \lambda_{\max}(\mathbf{A}^H \mathbf{A}) = \|\mathbf{A}\|_2^2,\end{aligned}$$

结论 (3) 得证.

由于 $\|\mathbf{A}\|_2^2$ 是 $\mathbf{A}^H \mathbf{A}$ 的最大特征值, 设其相应的特征向量为 $\mathbf{x} \neq \mathbf{0}$, 即 $\mathbf{A}^H \mathbf{A} \mathbf{x} = \|\mathbf{A}\|_2^2 \mathbf{x}$, 两边取 1-范数, 得

$$\begin{aligned}\|\mathbf{A}\|_2^2 \|\mathbf{x}\|_1 &= \|\|\mathbf{A}\|_2^2 \mathbf{x}\|_1 = \|\mathbf{A}^H \mathbf{A} \mathbf{x}\|_1 \\ &\leq \|\mathbf{A}^H\|_1 \cdot \|\mathbf{A}\|_1 \cdot \|\mathbf{x}\|_1 = \|\mathbf{A}\|_\infty \cdot \|\mathbf{A}\|_1 \cdot \|\mathbf{x}\|_1,\end{aligned}$$

两边除以 $\|\mathbf{x}\|_1$ 即得结论 (4).



Back

Close



由于 $\mathbf{A}^H \mathbf{A}$ 是 Hermite 半正定矩阵, 故其特征值 $\lambda_s(\mathbf{A}^H \mathbf{A})$, $s = 1, 2, \dots, n$ 均非负, 且满足

$$\sum_{s=1}^n \lambda_s(\mathbf{A}^H \mathbf{A}) = \text{tr}(\mathbf{A}^H \mathbf{A}) = \sum_{s=1}^n (\mathbf{A}^H \mathbf{A})_{ss},$$

从而有

$$\begin{aligned} \|\mathbf{A}\|_2^2 &= \lambda_{\max}(\mathbf{A}^H \mathbf{A}) \leq \sum_{s=1}^n \lambda_s(\mathbf{A}^H \mathbf{A}) \\ &= \sum_{s=1}^n (\mathbf{A}^H \mathbf{A})_{ss} = \sum_{s=1}^n \left(\sum_{i=1}^m |a_{is}|^2 \right) = \|\mathbf{A}\|_F^2, \end{aligned}$$

两边开平方即得结论 (5).

最后证明结论 (6). 注意到对任意的 n 阶酉矩阵 \mathbf{U} 和 n 维列向量 \mathbf{x} , 有

$$\|\mathbf{U}\mathbf{x}\|_2 = \sqrt{(\mathbf{U}\mathbf{x})^H(\mathbf{U}\mathbf{x})} = \sqrt{\mathbf{x}^H(\mathbf{U}^H\mathbf{U})\mathbf{x}} = \sqrt{\mathbf{x}^H\mathbf{x}} = \|\mathbf{x}\|_2,$$





即酉矩阵保持列向量的 2-范数不变. 由此, 有

$$\begin{aligned}\|UAV\|_2 &= \max_{\|x\|_2=1} \|UAVx\|_2 = \max_{\|y\|_2=1} \|UAy\|_2 \\ &= \max_{\|y\|_2=1} \|Ay\|_2 = \|A\|_2.\end{aligned}\tag{1.23}$$

证毕. □

定义 1.18 设 $A \in \mathbb{C}^{n \times n}$, 其特征值为 $\lambda_1, \lambda_2, \dots, \lambda_n$, 则称

$$\rho(A) = \max_{1 \leq i \leq n} |\lambda_i|$$

为矩阵 A 的谱半径.

由上述定义, $\|A\|_2$ 可定义为

$$\|A\|_2 = \sqrt{\rho(A^H A)}.$$



Back

Close

特别地, 当 \mathbf{A} 为 Hermite 矩阵时, 有

$$\|\mathbf{A}\|_2 = \rho(\mathbf{A}).$$

对于一般情况, 有如下定理.

定理 1.17 设 $\mathbf{A} \in \mathbb{C}^{n \times n}$, 则

(1) \mathbf{A} 的谱半径不超过 \mathbf{A} 的任何范数, 即

$$\rho(\mathbf{A}) \leq \|\mathbf{A}\|.$$

(2) 对任意正数 ε , 存在 $\mathbb{C}^{n \times n}$ 上的某种算子范数 $\|\cdot\|_\varepsilon$, 使得

$$\|\mathbf{A}\|_\varepsilon \leq \rho(\mathbf{A}) + \varepsilon.$$

证明 (1) 设 λ 是 \mathbf{A} 的一个特征值, 且 \mathbf{A} 的谱半径 $\rho(\mathbf{A}) = |\lambda|$, \mathbf{x}_0 是对应于 λ 的特征向量, 即 $\mathbf{A}\mathbf{x}_0 = \lambda\mathbf{x}_0$, 所以对任何一种向量





范数, 有 $\|\mathbf{A}\mathbf{x}_0\| = |\lambda| \cdot \|\mathbf{x}_0\|$, 故有

$$\rho(\mathbf{A}) = |\lambda| = \frac{\|\mathbf{A}\mathbf{x}_0\|}{\|\mathbf{x}_0\|} \leq \max_{\|\mathbf{x}\| \neq 0} \frac{\|\mathbf{A}\mathbf{x}\|}{\|\mathbf{x}\|} = \|\mathbf{A}\|.$$

(2) 由 Jordan 分解定理知, 存在非奇异矩阵 \mathbf{P} 使得

$$\mathbf{P}^{-1}\mathbf{A}\mathbf{P} = \begin{bmatrix} \lambda_1 & \delta_1 & & & \\ & \lambda_2 & \delta_2 & & \\ & & \ddots & \ddots & \\ & & & \lambda_{n-1} & \delta_{n-1} \\ & & & & \lambda_n \end{bmatrix},$$

式中: δ_i 等于 1 或 0. 对于任意的正数 ε , 令

$$\mathbf{D}_\varepsilon = \begin{bmatrix} 1 & & & & \\ & \varepsilon & & & \\ & & \ddots & & \\ & & & \varepsilon^{n-1} & \end{bmatrix},$$



则

$$D_{\varepsilon}^{-1}P^{-1}APD_{\varepsilon} = \begin{bmatrix} \lambda_1 & \varepsilon\delta_1 & & & \\ & \lambda_2 & \varepsilon\delta_2 & & \\ & & \ddots & \ddots & \\ & & & \lambda_{n-1} & \varepsilon\delta_{n-1} \\ & & & & \lambda_n \end{bmatrix}.$$

现定义一种新的矩阵范数

$$\|A\|_{\varepsilon} = \|D_{\varepsilon}^{-1}P^{-1}APD_{\varepsilon}\|_{\infty}, \quad A \in \mathbb{C}^{n \times n},$$

则容易验证这样定义的矩阵范数 $\|\cdot\|_{\varepsilon}$ 是由如下定义的向量范数诱导出来的算子范数:

$$\|x\|_{PD_{\varepsilon}} = \|(PD_{\varepsilon})^{-1}x\|_{\infty}, \quad x \in \mathbb{C}^n.$$



78/112



Back

Close



从而有

$$\|A\|_\varepsilon = \|D_\varepsilon^{-1} P^{-1} A P D_\varepsilon\|_\infty = \max_{1 \leq i \leq n} (|\lambda_i| + \varepsilon \delta_i) \leq \rho(A) + \varepsilon,$$

这里假设 $\delta_n = 0$. 证毕. □

类似于向量序列的极限定义, 有以下定义.

定义 1.19 设矩阵序列 $\{A^{(k)} = (a_{ij}^{(k)}) \in \mathbb{C}^{m \times n}\}_{k=0}^\infty$, $A = (a_{ij}) \in \mathbb{C}^{m \times n}$. 若

$$\lim_{k \rightarrow \infty} a_{ij}^{(k)} = a_{ij}, \quad i = 1, 2, \dots, m; \quad j = 1, 2, \dots, n,$$

则称序列 $\{A^{(k)}\}$ 收敛于 A , 记为 $\lim_{k \rightarrow \infty} A^{(k)} = A$.

利用矩阵范数的等价性, 可得以下定理.

定理 1.18 $\lim_{k \rightarrow \infty} A^{(k)} = A$ 当且仅当 $\lim_{k \rightarrow \infty} \|A^{(k)} - A\| = 0$, 其中 $\|\cdot\|$ 是 $\mathbb{C}^{m \times n}$ 中任意的矩阵范数.



Back

Close



关于矩阵范数, 还有下述定理.

定理 1.19 若 $\|A\| < 1$, 则矩阵 $I - A$ 非奇异, 且满足

$$\|(I - A)^{-1}\| \leq \frac{1}{1 - \|A\|}.$$

证明 用反证法. 设 $\det(I - A) = 0$, 则方程 $(I - A)x = 0$ 有非零解, 即存在 $x_0 \in \mathbb{C}^n$, $x_0 \neq 0$, 使得 $(I - A)x_0 = 0$. 故

$$\|A\| = \max_{\|x\| \neq 0} \frac{\|Ax\|}{\|x\|} \geq \frac{\|Ax_0\|}{\|x_0\|} = 1.$$

这与 $\|A\| < 1$ 矛盾.

进一步, 由于 $(I - A)(I - A)^{-1} = I$, 则 $(I - A)^{-1} = I + A(I - A)^{-1}$, 从而

$$\|(I - A)^{-1}\| \leq \|I\| + \|A\| \cdot \|(I - A)^{-1}\|.$$

将上式整理即得要证的结论. 证毕. □



Back

Close



定理 1.20 设 $\mathbf{A} \in \mathbb{C}^{n \times n}$, 则

$$(1) \quad \lim_{k \rightarrow \infty} \mathbf{A}^k = \mathbf{O} \iff \rho(\mathbf{A}) < 1.$$

$$(2) \quad \lim_{k \rightarrow \infty} \|\mathbf{A}^k\|^{\frac{1}{k}} = \rho(\mathbf{A}).$$

证明 (1) 充分性. 设 $\rho(\mathbf{A}) < 1$, 则存在 $\varepsilon > 0$ 满足 $\rho(\mathbf{A}) + 2\varepsilon < 1$. 于是由定理 1.17 知存在算子范数 $\|\cdot\|$ 使得 $\|\mathbf{A}\| \leq \rho(\mathbf{A}) + \varepsilon$. 因此

$$\|\mathbf{A}^k\| \leq \|\mathbf{A}\|^k \leq [\rho(\mathbf{A}) + \varepsilon]^k < (1 - \varepsilon)^k \rightarrow 0.$$

必要性. 设 $\lim_{k \rightarrow \infty} \mathbf{A}^k = \mathbf{O}$, 并假定 $\lambda \in \lambda(\mathbf{A})$ 满足 $\rho(\mathbf{A}) = |\lambda|$. 由于 $\lambda \in \lambda(\mathbf{A})$ 蕴含 $\lambda^k \in \lambda(\mathbf{A}^k)$, 故由定理 1.17 知对一切的 $k = 1, 2, \dots$ 成立

$$[\rho(\mathbf{A})]^k = |\lambda|^k = |\lambda^k| \leq \rho(\mathbf{A}^k) \leq \|\mathbf{A}^k\|,$$

故必有 $\rho(\mathbf{A}) < 1$.



Back

Close



(2) 由结论 (1) 的证明可知, 对任意的 $\varepsilon > 0$, 存在算子范数 $\|\cdot\|$, 满足

$$[\rho(\mathbf{A})]^k \leq \|\mathbf{A}^k\| \leq [\rho(\mathbf{A}) + \varepsilon]^k,$$

即

$$\rho(\mathbf{A}) \leq \|\mathbf{A}^k\|^{\frac{1}{k}} \leq \rho(\mathbf{A}) + \varepsilon,$$

由 $\varepsilon > 0$ 的任意性, 上式令 $k \rightarrow \infty$ 得

$$\lim_{k \rightarrow \infty} \|\mathbf{A}^k\|^{\frac{1}{k}} = \rho(\mathbf{A}).$$

再根据有限维空间范数的等价性, 对 $\mathbb{C}^{n \times n}$ 中的任意范数, 上述极限成立. 证毕. \square

利用定理 1.20 不难证明下面的重要结论.

定理 1.21 设 $\mathbf{A} \in \mathbb{C}^{n \times n}$, 则



Back

Close



(1) 矩阵级数 $\sum_{k=0}^{\infty} \mathbf{A}^k$ 收敛的充分必要条件是 $\rho(\mathbf{A}) < 1$.

(2) 若矩阵级数 $\sum_{k=0}^{\infty} \mathbf{A}^k$ 收敛, 则

$$\sum_{k=0}^{\infty} \mathbf{A}^k = (\mathbf{I} - \mathbf{A})^{-1},$$

且对于 $\mathbb{C}^{n \times n}$ 中的任意矩阵范数都有

$$\left\| (\mathbf{I} - \mathbf{A})^{-1} - \sum_{k=0}^m \mathbf{A}^k \right\| \leq \frac{\|\mathbf{A}\|^{m+1}}{1 - \|\mathbf{A}\|}.$$



Back

Close

§1.4 矩阵的广义逆

矩阵的广义逆是研究最小二乘问题及矩阵方程的一个重要工具. 首先给出矩阵广义逆的定义.

定义 1.20 设 $A \in \mathbb{C}^{m \times n}$, 若有 $X \in \mathbb{C}^{n \times m}$ 满足 Penrose (彭罗斯) 方程, 即

$$(1) \quad AXA = A.$$

$$(2) \quad XAX = X.$$

$$(3) \quad (AX)^H = AX.$$

$$(4) \quad (XA)^H = XA.$$

则称 X 为 A 的 Moore–Penrose 逆, 记为 A^\dagger .

注 1.4 若 $A \in \mathbb{R}^{m \times n}$, 则 $X = A^\dagger \in \mathbb{R}^{n \times m}$ 定义为满足下列四个方程的 X :





$$\begin{aligned}
 (1) \quad \mathbf{A}\mathbf{X}\mathbf{A} &= \mathbf{A}. & (2) \quad \mathbf{X}\mathbf{A}\mathbf{X} &= \mathbf{X}. \\
 (3) \quad (\mathbf{A}\mathbf{X})^T &= \mathbf{A}\mathbf{X}. & (4) \quad (\mathbf{X}\mathbf{A})^T &= \mathbf{X}\mathbf{A}.
 \end{aligned}$$

由定义 1.20 容易得到:

(1) $\mathbf{A} \in \mathbb{C}^{n \times n}$ 可逆时, $\mathbf{X} = \mathbf{A}^{-1}$ 满足 Penrose 方程, 故 $\mathbf{A}^\dagger = \mathbf{A}^{-1}$.

(2) $\mathbf{A} = \mathbf{O}_{m \times n}$ 时, $\mathbf{X} = \mathbf{O}_{n \times m}$ 满足 Penrose 方程, 故 $\mathbf{O}_{m \times n}^\dagger = \mathbf{O}_{n \times m}$.

(3) $\mathbf{A} = \mathbf{x} \in \mathbb{C}^{n \times 1}$ 时, $\mathbf{X} = \frac{1}{\|\mathbf{x}\|_2^2} \mathbf{x}^H$ 满足 Penrose 方程, 故 $\mathbf{x}^\dagger = \frac{1}{\|\mathbf{x}\|_2^2} \mathbf{x}^H$. 例如:

$$\begin{bmatrix} 1 \\ 1 + 2i \end{bmatrix}^\dagger = \frac{1}{6}(1, 1 - 2i).$$



Back

Close



定理 1.22 设 $F \in \mathbb{C}_r^{m \times r}$, $G \in \mathbb{C}_r^{r \times n}$ ($r \geq 1$), 则有

$$(1) \quad F^\dagger = (F^H F)^{-1} F^H, \quad F^\dagger F = I_r.$$

$$(2) \quad G^\dagger = G^H (G G^H)^{-1}, \quad G G^\dagger = I_r.$$

证明 先证结论 (1). 对于 F , 记 $X = (F^H F)^{-1} F^H$, 则有

$$F X F = F (F^H F)^{-1} F^H F = F,$$

$$X F X = (F^H F)^{-1} F^H F X = X,$$

$$(F X)^H = X^H F^H = F (F^H F)^{-1} F^H = F X,$$

$$(X F)^H = I_r^H = I_r = X F.$$

所以 $F^\dagger = (F^H F)^{-1} F^H$, 并且 $F^\dagger F = I_r$.

同理, 可证结论 (2). 证毕. □



Back

Close



定理 1.23 设 $A \in \mathbb{C}^{m \times n}$, 则 A^\dagger 存在且唯一.

证明 存在性. 当 $A = O$ 时, $A^\dagger = O$; 当 $A \neq O$ 时, $\text{rank}(A) = r \geq 1$, 从而 A 有满秩分解 $A = FG$ ($F \in \mathbb{C}_r^{m \times r}$, $G \in \mathbb{C}_r^{r \times n}$). 记 $X = G^\dagger F^\dagger$, 则有

$$\begin{aligned} AXA &= FGG^\dagger F^\dagger FG = F(GG^\dagger)(F^\dagger F)G = FG = A, \\ XAX &= G^\dagger F^\dagger FGG^\dagger F^\dagger = G^\dagger(F^\dagger F)(GG^\dagger)F^\dagger = G^\dagger F^\dagger = X, \\ (AX)^\text{H} &= (FGG^\dagger F^\dagger)^\text{H} = (FF^\dagger)^\text{H} = FF^\dagger = FGG^\dagger F^\dagger = AX, \\ (XA)^\text{H} &= (G^\dagger F^\dagger FG)^\text{H} = (G^\dagger G)^\text{H} = G^\dagger G = G^\dagger F^\dagger FG = XA, \end{aligned}$$

由定义可得

$$A^\dagger = G^\dagger F^\dagger = G^\text{H}(F^\text{H}AG^\text{H})^{-1}F^\text{H}. \quad (1.24)$$



Back

Close



唯一性. 对于 A , 如果 X 和 Y 都满足 Penrose 方程, 则有

$$\begin{aligned} X &= XAX = X \cdot AYA \cdot X = X \cdot (AY)(AX) \\ &= X \cdot (AY)^H(AX)^H = X \cdot (AXAY)^H = X \cdot (AY)^H \\ &= XAY = X \cdot AYA \cdot Y = (XA)(YA) \cdot Y \\ &= (XA)^H(YA)^H \cdot Y = (YAXA)^H \cdot Y \\ &= (YA)^H \cdot Y = YAY = Y, \end{aligned}$$

所以 A^\dagger 唯一. 证毕. □

定理 1.23 的存在性证明实际上给出了使用矩阵满秩分解的方法来计算非零矩阵广义逆. 下面给出一个例子.





例 1.3 已知

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 1 & 2 \\ 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \\ 2 & 1 & 2 & 1 \end{bmatrix},$$

求 \mathbf{A} 的满秩分解和 \mathbf{A}^\dagger .

解 $\mathbf{A} \xrightarrow{\text{初等行变换}} \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} : c_1 = 1, c_2 = 2,$

$$\mathbf{A} = \mathbf{F}\mathbf{G} : \quad \mathbf{F} = \begin{bmatrix} 1 & 2 \\ 0 & 1 \\ 1 & 0 \\ 2 & 1 \end{bmatrix}, \quad \mathbf{G} = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \end{bmatrix}.$$



Back

Close



因此, 有

$$\mathbf{F}^\dagger = (\mathbf{F}^\mathrm{T} \mathbf{F})^{-1} \mathbf{F}^\mathrm{T} = \begin{bmatrix} 6 & 4 \\ 4 & 6 \end{bmatrix}^{-1} \mathbf{F}^\mathrm{T} = \frac{1}{10} \begin{bmatrix} -1 & -2 & 3 & 4 \\ 4 & 3 & -2 & -1 \end{bmatrix},$$

$$\mathbf{G}^\dagger = \mathbf{G}^\mathrm{T} (\mathbf{G} \mathbf{G}^\mathrm{T})^{-1} = \mathbf{G}^\mathrm{T} \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}^{-1} = \frac{1}{2} \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix},$$

$$\mathbf{A}^\dagger = \mathbf{G}^\dagger \mathbf{F}^\dagger = \frac{1}{20} \begin{bmatrix} -1 & -2 & 3 & 4 \\ 4 & 3 & -2 & -1 \\ -1 & -2 & 3 & 4 \\ 4 & 3 & -2 & -1 \end{bmatrix}.$$





下面的定理说明使用矩阵奇异值分解的方法来计算广义逆更为便捷.

定理 1.24 设 $\mathbf{A} \in \mathbb{C}_r^{m \times n}$ ($r \geq 1$) 的奇异值分解为

$$\mathbf{A} = \mathbf{U} \begin{bmatrix} \boldsymbol{\Sigma}_r & \mathbf{O} \\ \mathbf{O} & \mathbf{O} \end{bmatrix} \mathbf{V}^{\mathrm{H}},$$

式中: \mathbf{U} 和 \mathbf{V} 及 $\boldsymbol{\Sigma}_r$ 的意义同式 (1.5), 则

$$\mathbf{A}^{\dagger} = \mathbf{V} \begin{bmatrix} \boldsymbol{\Sigma}_r^{-1} & \mathbf{O} \\ \mathbf{O} & \mathbf{O} \end{bmatrix} \mathbf{U}^{\mathrm{H}}. \quad (1.25)$$

证明 根据 Moore–Penrose 广义逆的定义, 直接验证即可证明.

注 1.5 需要指出, 可逆矩阵的逆 \mathbf{A}^{-1} 具有的性质, 对于一般矩阵的广义逆 \mathbf{A}^{\dagger} 不一定具有, 例如:



Back

Close



92/112

(1) $(\mathbf{AB})^\dagger \neq \mathbf{B}^\dagger \mathbf{A}^\dagger$: 取 $\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$, $\mathbf{B} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$, 则

$$\mathbf{AB} = \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}, \quad (\mathbf{AB})^\dagger = \frac{1}{2} \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix},$$

$$\mathbf{A}^\dagger = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}, \quad \mathbf{B}^\dagger = \mathbf{B}^{-1} = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{B}^\dagger \mathbf{A}^\dagger =$$

$$\begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$



Back

Close



(2) $\mathbf{A}^\dagger \mathbf{A} \neq \mathbf{A} \mathbf{A}^\dagger$: \mathbf{A} 不是方阵时, 这是明显的. \mathbf{A} 是方阵但不可逆时, 取

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}, \quad \mathbf{A}^\dagger = \frac{1}{2} \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix},$$

则

$$\mathbf{A}^\dagger \mathbf{A} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}, \quad \mathbf{A} \mathbf{A}^\dagger = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$



Back

Close



§1.5 几种特殊的矩阵类型

1. 不可约矩阵和对角占优矩阵

定义 1.21 设 A 是一个 n ($n \geq 2$) 阶矩阵, 如果存在 n 阶置换矩阵 P , 使得

$$P^T A P = \begin{bmatrix} A_{11} & A_{12} \\ O & A_{22} \end{bmatrix},$$

式中: A_{11} 和 A_{22} 分别为 r 阶和 $n-r$ 阶方阵 ($1 \leq r \leq n-1$). 则称 A 为可约矩阵. 如果不存在这样的置换矩阵, 则称 A 为不可约矩阵.

可约矩阵的一个等价定义如下.

定义 1.21' 设 $A = (a_{ij}) \in \mathbb{C}^{n \times n}$ ($n \geq 2$). 又设 $\mathcal{I} = \{1, 2, \dots, n\}$. 若存在 \mathcal{I} 的一个非空真子集 \mathcal{K} , 使得 $a_{ij} = 0$ ($i \notin \mathcal{K}, j \in \mathcal{K}$), 则称 A 为可约矩阵. 否则, 称 A 为不可约矩阵.





用定义 1.21' 判定一个矩阵是否可约更为方便.

例 1.4 设 $A = (a_{ij})$ 为三对角矩阵, 即满足 $a_{ij} = 0 (|i - j| > 1)$. 证明: 若

$$a_{i+1,i} \neq 0, \quad a_{i,i+1} \neq 0, \quad i = 1, 2, \dots, n-1,$$

则 A 是不可约矩阵.

证明 用反证法. 若 A 可约, 则由定义 1.21' 知, 存在 \mathcal{I} 的非空真子集 \mathcal{K} , 使得 $a_{ij} = 0 (i \notin \mathcal{K}, j \in \mathcal{K})$. 由于 \mathcal{K} 非空, 则 \mathcal{K} 至少有一个数, 设为 r . 由 $a_{r,r+1} \neq 0$ 知, $r+1 \in \mathcal{K}$. 类似可得 $r+2 \in \mathcal{K}, \dots, n \in \mathcal{K}$. 另外, 又由 $a_{r-1,r} \neq 0$ 知, $r-1 \in \mathcal{K}$. 类似可得 $r-2 \in \mathcal{K}, \dots, 1 \in \mathcal{K}$. 即有 $\mathcal{K} = \mathcal{I}$, 这与 \mathcal{K} 是 \mathcal{I} 的真子集矛盾. 故 A 为不可约矩阵.



Back

Close



定义 1.22 设 A 是一个 n 阶矩阵.

(1) 若 A 满足

$$|a_{ii}| \geq \sum_{j \neq i} |a_{ij}|, \quad i = 1, 2, \dots, n,$$

且其中至少有个严格不等式成立, 则称 A 为 (行) 弱对角占优.

(2) 若 A 满足

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}|, \quad i = 1, 2, \dots, n,$$

则称 A 为 (行) 严格对角占优.

类似可定义 (列) 弱对角占优和 (列) 严格对角占优.

以后往往不严格区分按行 (严格) 对角占优或按列 (严格) 对角占优而模糊地统称为 (严格) 对角占优. 弱对角占优且不可约的矩阵简称为不可约对角占优.



Back

Close



引理 1.1 若 n 阶矩阵 A 满足下列条件之一:

- (1) 严格对角占优.
- (2) 不可约对角占优.

则 A 非奇异, 即其行列式 $\det(A) \neq 0$.

证明 首先考虑 A 为严格对角占优的情形. 用反证法. 假设 A 是奇异的, 则存在非零向量 x 使得 $Ax = 0$. 不妨设 $|x_i| = \|x\|_\infty = 1$. 则有

$$|a_{ii}| = |a_{ii}x_i| = \left| \sum_{j \neq i} a_{ij}x_j \right| \leq \sum_{j \neq i} |a_{ij}|,$$

这与 A 严格对角占优矛盾.

再考虑 A 为不可约对角占优时结论成立. 仍用反证法. 设非零向量 x 满足 $Ax = 0$, 并定义

$$\mathcal{K} = \{k : |x_k| < 1\}.$$



Back

Close



易知 \mathcal{K} 非空. 否则 x 的所有分量的模均为 1, 则对于所有的 $i \in \mathcal{K}$, 均有

$$|a_{ii}| \leq \sum_{j \neq i} |a_{ij}|,$$

这与 A 对角占优矛盾. 此外, 因 A 不可约, 必存在 i, k 使得

$$a_{ik} \neq 0, \quad i \notin \mathcal{K}, \quad k \in \mathcal{K}.$$

于是 $|a_{ik}x_k| < |a_{ik}|$, 且

$$\begin{aligned} |a_{ii}| &\leq \sum_{j \notin \mathcal{K}, j \neq i} |a_{ij}| \cdot |x_j| + \sum_{j \in \mathcal{K}} |a_{ij}| \cdot |x_j| \\ &< \sum_{j \notin \mathcal{K}, j \neq i} |a_{ij}| + \sum_{j \in \mathcal{K}} |a_{ij}| = \sum_{j \neq i} |a_{ij}|, \end{aligned}$$

这又与 A 对角占优矛盾. 证毕. □





2. 非负矩阵和 M 矩阵

非负矩阵在迭代法中起着非常重要的作用. 一个非负矩阵就是其元素全为非负数的矩阵. 对两个 $m \times n$ 阶矩阵 A 和 B , 如果其所有相应的元素满足 $a_{ij} \geq b_{ij}$, 则称 $A \geq B$, 这样 “ \geq ” 就定义了矩阵集合上的一个偏序关系. 利用这种偏序关系, 非负矩阵 A 可以表示为 $A \geq O$. $A \geq B$ 也可表示为 $B \leq A$, 即 “ \leq ” 也定义了矩阵集合上的一个偏序关系.

性质 1.9 关于非负矩阵, 下列性质成立:

(1) 若 $A \geq O$, $B \geq O$, 则 $AB \geq O$, $A + B \geq O$ 且 $A^k \geq O$.

(2) 若 A, B, C 为非负矩阵且 $A \leq B$, 则 $AC \leq BC$, $CA \leq CB$.



Back

Close



(3) 若 $\mathbf{O} \leq \mathbf{A} \leq \mathbf{B}$, 则 $\mathbf{A}^T \leq \mathbf{B}^T$ 且 $\mathbf{A}^k \leq \mathbf{B}^k$ 对任意的 k 均成立.

(4) 若 $\mathbf{O} \leq \mathbf{A} \leq \mathbf{B}$, 则 $\|\mathbf{A}\|_1 \leq \|\mathbf{B}\|_1$, 且类似地 $\|\mathbf{A}\|_\infty \leq \|\mathbf{B}\|_\infty$.

定理 1.25 (Perron–Frobenius 定理) 设 $\mathbf{A} \in \mathbb{R}^{n \times n}$, 则有下列结论成立:

(1) 若 $\mathbf{A} \geq \mathbf{O}$, 则 \mathbf{A} 有一个非负特征值等于 $\rho(\mathbf{A})$; 对 $\rho(\mathbf{A}) > 0$, 相应的特征向量 $\mathbf{x} \geq \mathbf{0}$, 且当 \mathbf{A} 的任意元素增加时, $\rho(\mathbf{A})$ 不减少.

(2) 若 $\mathbf{A} \geq \mathbf{O}$ 不可约, 则 \mathbf{A} 有一个正特征值等于 $\rho(\mathbf{A})$; 对 $\rho(\mathbf{A}) > 0$, 其对应的特征向量 $\mathbf{x} > \mathbf{0}$; 当 \mathbf{A} 的任意元素增加时, $\rho(\mathbf{A})$ 增加; 且 $\rho(\mathbf{A})$ 是 \mathbf{A} 的一个简单特征值.



Back

Close



性质 1.10 设 $\mathbf{A} \in \mathbb{R}^{n \times n}$, 则有下列性质成立:

(1) 若 $\mathbf{O} \leq \mathbf{A} \leq \mathbf{B}$, 则 $\rho(\mathbf{A}) \leq \rho(\mathbf{B})$.

(2) 若 $|\mathbf{A}| \leq \mathbf{B}$ ($|\mathbf{A}|$ 表示 \mathbf{A} 的元素取绝对值后得到的矩阵), 则 $\rho(\mathbf{A}) \leq \rho(\mathbf{B})$.

(3) 设 $\mathbf{A} \geq \mathbf{O}$, 则 $\rho(\mathbf{A}) < 1$ 当且仅当 $\mathbf{I} - \mathbf{A}$ 非奇异且 $(\mathbf{I} - \mathbf{A})^{-1} \geq \mathbf{O}$.

(4) 设 $\mathbf{A} \geq \mathbf{O}$, $\mathbf{x} \geq \mathbf{0}$ 为非零向量, $\alpha > 0$. 若 $\mathbf{Ax} > (\geq) \alpha \mathbf{x}$, 则 $\rho(\mathbf{A}) > (\geq) \alpha$; 若 $\mathbf{Ax} < \alpha \mathbf{x}$, 则 $\rho(\mathbf{A}) < \alpha$.

定义 1.23 (1) 设 \mathbf{A} 是一个 n 阶矩阵. 若 \mathbf{A} 的主对角元是正的, 即 $a_{ii} > 0, i = 1, 2, \dots, n$, 而其非主对角元是非正的, 即 $a_{ij} \leq 0, i \neq j, i, j = 1, 2, \dots, n$, 则称 \mathbf{A} 为 Z 矩阵. 若 Z 矩阵 \mathbf{A} 为非奇异的, 且 $\mathbf{A}^{-1} \geq \mathbf{O}$, 则称 \mathbf{A} 为 M 矩阵.

(2) 记矩阵 $\langle \mathbf{A} \rangle = (\alpha_{ij})$, 其中主对角元 $\alpha_{ii} = |a_{ii}|$, 而非主对



Back

Close



角元 $\alpha_{ij} = -|a_{ij}|$, 则称 $\langle \mathbf{A} \rangle$ 为 \mathbf{A} 的比较矩阵. 若 $\langle \mathbf{A} \rangle$ 为非奇异的 M 矩阵, 则称 \mathbf{A} 为 H 矩阵.

关于 M 矩阵和 H 矩阵, 有下面一些常用的性质.

性质 1.11 设 \mathbf{A} 是 Z 矩阵, 则 \mathbf{A} 是 M 矩阵当且仅当 $\rho(\mathbf{B}) < 1$, 其中 $\mathbf{B} = \mathbf{I} - \mathbf{D}^{-1}\mathbf{A}$ 且 $\mathbf{D} = \text{diag}(\mathbf{A})$.

性质 1.12 设 $\mathbf{A} \in \mathbb{R}^{n \times n}$, 则有下列性质成立:

- (1) 严格对角占优或不可约对角占优矩阵是 H 矩阵.
- (2) 严格对角占优或不可约对角占优矩阵的 Z 矩阵是 M 矩阵.
- (3) 若 \mathbf{A} 为 H 矩阵, 则 $|\mathbf{A}|^{-1} \leq \langle \mathbf{A} \rangle^{-1}$.
- (4) 若 $\mathbf{A} = \mathbf{D} - \mathbf{B}$ 为 H 矩阵, $\mathbf{D} = \text{diag}(\mathbf{A})$, 则 $|\mathbf{D}|$ 非奇异, 且 $\rho(|\mathbf{D}|^{-1}|\mathbf{B}|) < 1$.



Back

Close



性质 1.13 设 $A, B \in \mathbb{R}^{n \times n}$ 是两个非奇异的 M 矩阵, 且 $A \leq B$, 则

(1) $A^{-1} \geq B^{-1}$.

(2) A 和 B 的每个主子矩阵也是 M 矩阵.

(3) 满足 $A \leq C \leq B$ 的 C 都是 M 矩阵. 特别地, 若 $A \leq C \leq \text{diag}(A)$, 则 C 是 M 矩阵.

性质 1.14 若 A 是 M 矩阵, B 是 Z 矩阵, 且 $A \leq B$, 则 B 也是 M 矩阵.

性质 1.15 (1) 若分块矩阵 $A = (A_{ij})_{i,j=1}^m$ 是 M 矩阵, 且其主对角块 A_{ii} 为方阵, 则 A_{ii} 也是 M 矩阵.

(2) 若 $A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}$ 是 M 矩阵, 则 Schur 补 $S = A_{22} - A_{21}A_{11}^{-1}A_{12}$ 也是 M 矩阵.



Back

Close



3. 正定矩阵

关于正定矩阵, 在实矩阵的情形, 前面已作了介绍. 下面考虑复矩阵的情形.

定义 1.24 (1) 设矩阵 $\mathbf{A} \in \mathbb{C}^{n \times n}$, 若对任意非零向量 $\mathbf{x} \in \mathbb{C}^n$ 都有 $\operatorname{Re}(\mathbf{x}^H \mathbf{A} \mathbf{x}) > 0$, 则称 \mathbf{A} 为正定的. 若 \mathbf{A} 还是 Hermite 的, 则称为 Hermite 正定的, 记为 HPD.

(2) 设矩阵 $\mathbf{A} \in \mathbb{C}^{n \times n}$, 若对任意非零向量 $\mathbf{x} \in \mathbb{R}^n$ 都有 $\mathbf{x}^T \mathbf{A} \mathbf{x} > 0$, 则称 \mathbf{A} 为正实的.

任意 (实或复) 方阵 \mathbf{A} 均可分裂为

$$\mathbf{A} = \mathbf{H} + \mathrm{i}\mathbf{S}, \quad (1.26)$$

式中:

$$\mathbf{H} = \frac{1}{2}(\mathbf{A} + \mathbf{A}^H), \quad \mathbf{S} = \frac{1}{2\mathrm{i}}(\mathbf{A} - \mathbf{A}^H).$$



Back

Close



注意到 H 和 S 都是 Hermite 的, 而 iS 是反 Hermite 的. 矩阵 H 和 iS 分别称为 A 的 Hermite 部分和反 Hermite 部分. 当 A 是实矩阵且 u 是实向量时, 有 $(Au, u) = (Hu, u)$. 分裂 (1.26) 称为矩阵 A 的一个 Hermite-反 Hermite 分裂, 简称 HS 分裂.

正定矩阵具有下面一些常用的性质.

性质 1.16 关于矩阵 A , 下列性质成立:

(1) 设 A 为实正定矩阵, 则 A 是非奇异的, 且对任意的实向量 x , 存在标量 $\alpha > 0$ 满足 $(Ax, x) \geq \alpha \|x\|^2$.

(2) 正定矩阵 $A \in \mathbb{C}^{n \times n}$ 的所有特征值均有正的实部.

(3) 设 $A \in \mathbb{C}^{n \times n}$ 为正定矩阵, $P \in \mathbb{C}^{n \times n}$ 为 n 阶非奇异矩阵, 则 $P^H A P$ 亦为正定矩阵.

(4) 正定矩阵 $A \in \mathbb{C}^{n \times n}$ 的所有主子阵均为正定矩阵. 特别地, A 的所有对角元素均有正的实部.



Back

Close



(5) 设 $\mathbf{A} \in \mathbb{C}^{n \times n}$, 则 \mathbf{A} 是正定矩阵当且仅当 $\mathbf{A} + \mathbf{A}^H$ 为 Hermite 正定的.

定理 1.26 对于矩阵 \mathbf{A} 的 HS 分裂 (1.26), 其特征值 λ_i 满足

$$\lambda_{\min}(\mathbf{H}) \leq \operatorname{Re}(\lambda_i) \leq \lambda_{\max}(\mathbf{H}), \quad \lambda_{\min}(\mathbf{S}) \leq \operatorname{Im}(\lambda_i) \leq \lambda_{\max}(\mathbf{S}).$$

当 \mathbf{B} 为对称正定矩阵时, $\mathbb{C}^n \times \mathbb{C}^n$ 到 \mathbb{C} 上的映射 $\mathbf{x}, \mathbf{y} \rightarrow (\mathbf{x}, \mathbf{y})_B \equiv (\mathbf{B}\mathbf{x}, \mathbf{y})$ 是 \mathbb{C}^n 上的一个内积, 称此内积为能量内积. 而称其诱导范数为能量范数. 有时, 可以找到一个 HPD 矩阵 \mathbf{B} , 使得一个给定的在欧几里得内积下的非 Hermite 矩阵 \mathbf{A} 在能量内积下成为 Hermite 的, 即:

$$(\mathbf{A}\mathbf{x}, \mathbf{y})_B = (\mathbf{x}, \mathbf{A}\mathbf{y})_B, \quad \forall \mathbf{x}, \mathbf{y}.$$

最简单的例子是 $\mathbf{A} = \mathbf{B}^{-1}\mathbf{C}$ 和 $\mathbf{A} = \mathbf{C}\mathbf{B}$, 其中 \mathbf{C} 是 Hermite 的且 \mathbf{B} 是 Hermite 正定的.



Back

Close

§1.6 模型问题: Poisson 问题



107/112

考虑二维规则区域上的 Poisson 问题

$$\begin{cases} -\left(\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2}\right) + c\frac{\partial u}{\partial x} + d\frac{\partial u}{\partial y} + eu = f(x, y), & (x, y) \in \Omega, \\ u(x, y)|_{\partial\Omega} = 0, \end{cases} \quad (1.27)$$

式中: $\Omega = (0, 1) \times (0, 1)$; f 为给定的函数; c, d, e 为非负常数.

设 x, y 方向均取 $n + 1$ 个等距网格, 则内网格点共有 n^2 个, 步长为 $h = \frac{1}{n + 1}$, 如图 1.1 所示.



Back

Close




图 1.1 区域离散和节点标号

将

$$u_{xx}(x_i, y_j) \approx \frac{u_{i+1,j} - 2u_{ij} + u_{i-1,j}}{h^2}, \quad u_{yy}(x_i, y_j) \approx \frac{u_{i,j+1} - 2u_{ij} + u_{i,j-1}}{h^2},$$

$$u_x(x_i, y_j) \approx \frac{u_{i+1,j} - u_{i-1,j}}{2h}, \quad u_y(x_i, y_j) \approx \frac{u_{i,j+1} - u_{i,j-1}}{2h},$$

$$u(x_i, y_j) \approx u_{ij}, \quad f(x_i, y_j) \approx f_{ij}.$$



Back

Close

代入式 (1.27) 的第 1 式并整理, 得

$$(4 + h^2 e)u_{ij} - (u_{i+1,j} + u_{i-1,j} + u_{i,j+1} + u_{i,j-1}) + \frac{hc}{2}(u_{i+1,j} - u_{i-1,j}) + \frac{hd}{2}(u_{i,j+1} - u_{i,j-1}) = h^2 f_{ij}, \quad i, j = 1, 2, \dots, n.$$

该方程组包含了 n^2 个未知量, 它的矩阵形式为

$$\mathbf{A}\mathbf{u} = \mathbf{f}, \quad (1.28)$$

式中: $\mathbf{A} = \mathbf{A}_1 + \mathbf{A}_2 + \mathbf{A}_3$ 为 n^2 阶的块三对角矩阵, 其具体形式为





$$\mathbf{A}_1 = \begin{bmatrix} B & -I & & & \\ -I & B & -I & & \\ & \ddots & \ddots & \ddots & \\ & & -I & B & -I \\ & & & -I & B \end{bmatrix}, \quad (1.29)$$

$$\mathbf{A}_2 = \frac{hc}{2} \begin{bmatrix} O & I & & & \\ -I & O & I & & \\ & \ddots & \ddots & \ddots & \\ & & -I & O & I \\ & & & -I & O \end{bmatrix}, \quad (1.30)$$



Back

Close



$$\mathbf{A}_3 = \frac{hd}{2} \begin{bmatrix} \mathbf{O} & -\mathbf{I} & & & \\ \mathbf{I} & \mathbf{O} & -\mathbf{I} & & \\ & \ddots & \ddots & \ddots & \\ & & \mathbf{I} & \mathbf{O} & -\mathbf{I} \\ & & & \mathbf{I} & \mathbf{O} \end{bmatrix}, \quad (1.31)$$

这里

$$\mathbf{B} = \begin{bmatrix} 4 + h^2e & -1 & & & \\ -1 & 4 + h^2e & -1 & & \\ & \ddots & \ddots & \ddots & \\ & & -1 & 4 + h^2e & -1 \\ & & & -1 & 4 + h^2e \end{bmatrix} \quad (1.32)$$



Back

Close



为对称三对角矩阵, \mathbf{I} 为 n 阶单位矩阵. n^2 维列向量 \mathbf{u} 定义为

$$\mathbf{u} = (u_{11}, u_{12}, \cdots, u_{1n}, u_{21}, u_{22}, \cdots, u_{2n}, \cdots, u_{n1}, u_{n2}, \cdots, u_{nn})^T,$$

网格中的每个内部节点都对应一个分量, u_{ij} 表示 $u(ih, jh)$ 的近似, 这些分量按沿 y 方向变化最快的方式排列. 图 1.1 中节点 A, B, C, D 的标号分别为 $(1, 1), (1, n), (n, 1), (n, n)$, 节点 (i, j) 对应的标号为 $i * n + j$, 它的上下左右的四个相邻节点为

$$i * n + (j + 1), \quad i * n + (j - 1), \quad (i - 1) * n + j, \quad (i + 1) * n + j.$$

右端向量 \mathbf{f} 为

$$\mathbf{f} = h^2(f_{11}, f_{12}, \cdots, f_{1n}, f_{21}, f_{22}, \cdots, f_{2n}, \cdots, f_{n1}, f_{n2}, \cdots, f_{nn})^T.$$

以后常常用此模型做数值实验, 故称它为模型问题.



Back

Close