



# 数值线性代数与算法

## 第五章 线性最小二乘问题的数值解法





当给定的矩阵  $A \in \mathbb{C}^{n \times n}$  非奇异时, 对任何向量  $b \in \mathbb{C}^n$ , 线性方程组  $Ax = b$  总有唯一解  $x = A^{-1}b$ . 但在许多实际问题中, 矩阵  $A$  不是方阵, 甚至不是满秩的, 而且  $b \notin \mathcal{R}(A)$ . 此时, 方程组  $Ax = b$  可能无解或者有无穷多个解. 本章将讨论这样的一类线性方程组的有关理论及数值方法.

## §5.1 线性最小二乘问题的数学性质

本节讨论线性最小二乘问题的有关性质. 首先给出最小二乘问题的定义.

**定义 5.1** 设  $A \in \mathbb{C}^{m \times n}$ ,  $b \in \mathbb{C}^m$ , 确定  $x \in \mathbb{C}^n$  使得

$$\|Ax - b\|_2 = \min_{z \in \mathbb{C}^n} \|Az - b\|_2. \quad (5.1)$$

问题 (5.1) 称为线性最小二乘问题 (Least Squares, LS 问题), 而  $x$





则称为最小二乘解或极小解. 称  $\mathbf{r}(\mathbf{x}) = \mathbf{b} - \mathbf{A}\mathbf{x}$  为残差向量 (简称残量).

所有最小二乘解的集合记为  $S_{\text{LS}}$ , 即

$$S_{\text{LS}} = \{\mathbf{x} \in \mathbb{C}^n : \mathbf{x} \text{ 满足 (5.1)}\}. \quad (5.2)$$

$S_{\text{LS}}$  中 2-范数最小者称为极小范数解, 记为  $\mathbf{x}_{\text{LS}}$ , 即

$$\|\mathbf{x}_{\text{LS}}\|_2 = \min \{\|\mathbf{x}\|_2 : \mathbf{x} \in S_{\text{LS}}\}.$$

线性最小二乘问题 (5.1) 的解  $\mathbf{x}$  又可称为线性方程组

$$\mathbf{A}\mathbf{x} = \mathbf{b}, \quad \mathbf{A} \in \mathbb{C}^{m \times n}, \quad \mathbf{b} \in \mathbb{C}^m \quad (5.3)$$

的最小二乘解, 即  $\mathbf{x}$  在残量  $\mathbf{r}(\mathbf{x}) = \mathbf{b} - \mathbf{A}\mathbf{x}$  的 2-范数最小的意义下满足方程组 (5.3). 当  $m > n$  时称为超定方程组或矛盾方程组; 当  $m < n$  时称为欠定方程组.



Back

Close



不难发现, 若将矩阵  $A$  写成  $A = [a_1, a_2, \dots, a_n]$ ,  $a_i \in \mathbb{C}^m$ ,  $i = 1, 2, \dots, n$ , 则求解最小二乘问题 (5.1) 等价于求  $\{a_i\}_{i=1}^n$  的线性组合使之与向量  $b$  之差的 2-范数达到最小. 可分为两种情况: 第一种是  $\{a_i\}_{i=1}^n$  线性无关, 即  $A$  为列满秩; 第二种是  $\{a_i\}_{i=1}^n$  线性相关, 即  $A$  为秩亏的. 下面分别针对这两种情形讨论最小二乘问题 (5.1) 极小解的数值解法.

### §5.1.1 最小二乘解的特征及一般表示

矩阵的广义逆是研究线性方程组 (5.3) 最小二乘解的一个重要而有用的工具. 下面讨论:

(1) 当方程组 (5.3) 有解时, 如何确定  $x_0 \in \mathbb{C}^n$ , 使得

$$\|x_0\|_2 = \min_{Ax=b} \|x\|_2,$$

称这样的  $x_0$  为方程组 (5.3) 的极小范数解.



Back

Close



(2) 当方程组 (5.3) 无解时, 如何确定  $\boldsymbol{x}_0 \in \mathbb{C}^n$ , 使得

$$\|\boldsymbol{x}_0\|_2 = \min_{\min \|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|_2} \|\boldsymbol{x}\|_2,$$

称这样的  $\boldsymbol{x}_0$  为方程组 (5.3) 的极小范数最小二乘解.

引理 5.1 设  $\boldsymbol{A} \in \mathbb{C}^{m \times n}$ , 则有

(1)  $[\mathcal{R}(\boldsymbol{A})]^\perp = \mathcal{N}(\boldsymbol{A}^H)$ , 并且  $\mathbb{C}^m = \mathcal{R}(\boldsymbol{A}) \oplus \mathcal{N}(\boldsymbol{A}^H)$  (或  $\mathcal{R}(\boldsymbol{A}) = [\mathcal{N}(\boldsymbol{A}^H)]^\perp$ ).

(2)  $[\mathcal{R}(\boldsymbol{A}^H)]^\perp = \mathcal{N}(\boldsymbol{A})$ , 并且  $\mathbb{C}^n = \mathcal{R}(\boldsymbol{A}^H) \oplus \mathcal{N}(\boldsymbol{A})$  (或  $\mathcal{N}(\boldsymbol{A}) = [\mathcal{R}(\boldsymbol{A}^H)]^\perp$ ).

证明 (1) 将  $\boldsymbol{A}$  按列划分为  $\boldsymbol{A} = [\boldsymbol{a}_1, \boldsymbol{a}_2, \dots, \boldsymbol{a}_n]$ , 其中  $\boldsymbol{a}_i \in \mathbb{C}^m$  ( $i = 1, 2, \dots, n$ ), 由于

$$\mathcal{R}(\boldsymbol{A}) = \text{span}\{\boldsymbol{a}_1, \boldsymbol{a}_2, \dots, \boldsymbol{a}_n\},$$



Back

Close

所以

$$\begin{aligned} [\mathcal{R}(\mathbf{A})]^\perp &= \{\mathbf{x} : \mathbf{x} \perp \mathbf{a}_i, i = 1, 2, \cdots, n\} \\ &= \{\mathbf{x} : \mathbf{a}_i^H \mathbf{x} = 0, i = 1, 2, \cdots, n\} \\ &= \{\mathbf{x} : \mathbf{A}^H \mathbf{x} = \mathbf{0}\} = \mathcal{N}(\mathbf{A}^H), \end{aligned}$$

即  $\mathcal{R}(\mathbf{A}) \perp \mathcal{N}(\mathbf{A}^H)$ , 从而  $\mathcal{R}(\mathbf{A}) + \mathcal{N}(\mathbf{A}^H)$  为直和. 再由

$$\dim \mathcal{R}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}^H) = \text{rank}(\mathbf{A}) + [m - \text{rank}(\mathbf{A})] = m,$$

可得  $\mathbb{C}^m = \mathcal{R}(\mathbf{A}^H) \oplus \mathcal{N}(\mathbf{A})$ .

(2) 在 (1) 中以  $\mathbf{A}^H \in \mathbb{C}^{n \times m}$  代替  $\mathbf{A} \in \mathbb{C}^{m \times n}$  即可得 (2). 证毕.

□



6/96



Back

Close



设矩阵  $A$  的奇异值分解为

$$A = U \begin{bmatrix} \Sigma_r & O \\ O & O \end{bmatrix} V^H,$$

式中:  $U = [U_1, U_2]$ ,  $V = [V_1, V_2]$  为酉矩阵,  $U_1 = [\mathbf{u}_1, \cdots, \mathbf{u}_r]$ ,  
 $U_2 = [\mathbf{u}_{r+1}, \cdots, \mathbf{u}_n]$ ,  $V_1 = [\mathbf{v}_1, \cdots, \mathbf{v}_r]$ ,  $V_2 = [\mathbf{v}_{r+1}, \cdots, \mathbf{v}_n]$ ;  
 $\Sigma_r = \text{diag}(\sigma_1, \cdots, \sigma_r)$ ,  $\sigma_1 \geq \cdots \geq \sigma_r > 0$ . 于是

$$A = U_1 \Sigma_r V_1^H, \quad A^\dagger = V_1 \Sigma_r^{-1} U_1^H, \quad A^H = V_1 \Sigma_r U_1^H. \quad (5.4)$$

容易验证

$$AA^\dagger = U_1 U_1^H, \quad A^\dagger A = V_1 V_1^H, \quad A^H A = V_1 \Sigma_r^2 V_1^H. \quad (5.5)$$

由于  $\{\mathbf{u}_i\}_{i=1}^r$  和  $\{\mathbf{v}_i\}_{i=r+1}^n$  分别是  $\mathcal{R}(A)$  和  $\mathcal{N}(A)$  的标准正交基,



Back

Close



故  $\mathcal{R}(\mathbf{A})$  和  $\mathcal{N}(\mathbf{A})$  上的正交投影矩阵分别为:

$$\begin{aligned} \mathbf{P}_{\mathcal{R}(\mathbf{A})} &= \mathbf{U}_1 \mathbf{U}_1^{\mathrm{H}} = \mathbf{A} \mathbf{A}^{\dagger}, \\ \mathbf{P}_{\mathcal{N}(\mathbf{A})} &= \mathbf{V}_2 \mathbf{V}_2^{\mathrm{H}} = \mathbf{I}_n - \mathbf{V}_1 \mathbf{V}_1^{\mathrm{H}} = \mathbf{I}_n - \mathbf{A}^{\dagger} \mathbf{A}. \end{aligned} \quad (5.6)$$

而  $\mathcal{R}(\mathbf{A})^{\perp} = \mathcal{N}(\mathbf{A}^{\mathrm{H}})$  和  $\mathcal{N}(\mathbf{A})^{\perp} = \mathcal{R}(\mathbf{A}^{\mathrm{H}})$  上的正交投影矩阵分别为

$$\mathbf{P}_{\mathcal{R}(\mathbf{A})^{\perp}} = \mathbf{I}_m - \mathbf{A} \mathbf{A}^{\dagger}, \quad \mathbf{P}_{\mathcal{N}(\mathbf{A})^{\perp}} = \mathbf{A}^{\dagger} \mathbf{A}. \quad (5.7)$$

有下面的定理.

**定理 5.1** 设  $\mathbf{A} \in \mathbb{C}^{m \times n}$ ,  $\mathbf{b} \in \mathbb{C}^m$ , 则线性方程组 (5.3) 有解的充要条件是

$$\mathbf{A} \mathbf{A}^{\dagger} \mathbf{b} = \mathbf{b}, \quad (5.8)$$

并且在有解时, 其通解为

$$\mathbf{x} = \mathbf{A}^{\dagger} \mathbf{b} + (\mathbf{I} - \mathbf{A}^{\dagger} \mathbf{A}) \mathbf{z}, \quad (5.9)$$

其中  $\mathbf{z} \in \mathbb{C}^n$  任意.







证明 若  $AA^\dagger b = b$ , 则显然方程组 (5.3) 有解  $x = A^\dagger b$ . 反之, 若  $Ax = b$ , 则

$$AA^\dagger b = AA^\dagger Ax = Ax = b.$$

下面证明其通解为式 (5.9). 事实上, 根据式 (5.6), 有

$$\mathcal{N}(A) = \{(I_n - A^\dagger A)z : z \in \mathbb{C}^n\}.$$

故线性方程组 (5.3) 的通解可以表示为  $x = A^\dagger b + (I - A^\dagger A)z$ , 其中  $z \in \mathbb{C}^n$  任意. 证毕.  $\square$

**注 5.1** 式 (5.9) 表明:  $x_0 = A^\dagger b$  是方程组  $Ax = b$  的一个解, 而  $(I - A^\dagger A)z$  是对应齐次方程组  $Ax = 0$  的通解.

**定理 5.2** 如果方程组 (5.3) 有解, 则它的极小范数解  $x_0$  唯一, 并且  $x_0 = A^\dagger b$ .



Back

Close



证明 先证  $x_0 \in \mathcal{R}(A^H)$ . 若  $x_0 \notin \mathcal{R}(A^H)$ , 则由引理 5.1 (2) 作向量分解, 得

$$x_0 = y_0 + y_1, \quad y_0 \in \mathcal{R}(A^H), \quad y_1 \in \mathcal{N}(A) = [\mathcal{R}(A^H)]^\perp, \quad y_1 \neq 0.$$

由于  $y_0 \perp y_1$ , 所以

$$\|x_0\|_2^2 = \|y_0\|_2^2 + \|y_1\|_2^2 > \|y_0\|_2^2.$$

但是  $Ay_0 = Ay_0 + Ay_1 = Ax_0 = b$ , 所以  $x_0$  不是方程组 (5.3) 的极小范数解. 这与前提冲突, 故  $x_0 \in \mathcal{R}(A^H)$ .

再证  $x_0$  唯一. 若  $z_0$  也是方程 (5.3) 的极小范数解, 则  $z_0 \in \mathcal{R}(A^H)$ , 从而

$$x_0 - z_0 \in \mathcal{R}(A^H) = [\mathcal{N}(A)]^\perp.$$

另外, 由于  $A(x_0 - z_0) = 0$ , 所以  $x_0 - z_0 \in \mathcal{N}(A)$ , 故只能有  $x_0 - z_0 = 0$ . 即  $x_0 = z_0$ .





最后证  $x_0 = A^\dagger b$ . 根据定理 5.1 可得方程组 (5.3) 的通解为

$$x = A^\dagger b + (I - A^\dagger A)z \quad (z \in \mathbb{C}^n \text{ 任意}).$$

取  $z = 0$ , 则  $x_0 = A^\dagger b$  是方程组 (5.3) 的一个解. 因为

$$\begin{aligned} (x_0, (I - A^\dagger A)z) &= z^H (I - A^\dagger A)^H x_0 \\ &= z^H (I - A^\dagger A) A^\dagger b \\ &= z^H (A^\dagger - A^\dagger A A^\dagger) b = 0, \end{aligned}$$

所以

$$\|x\|_2^2 = \|x_0\|_2^2 + \|(I - A^\dagger A)z\|_2^2 \geq \|x_0\|_2^2.$$

故  $x_0 = A^\dagger b$  是方程组 (5.3) 的极小范数解. 证毕.  $\square$

**定理 5.3** 如果线性方程组 (5.3) 无解, 则它的极小范数最小二乘解  $x_0$  唯一, 并且  $x_0 = A^\dagger b$ .





证明 由于方程组 (5.3) 无解, 所以  $\mathbf{b} \notin \mathcal{R}(\mathbf{A})$ . 根据引理 5.1 (1) 作向量分解  $\mathbf{b} = \mathbf{b}_1 + \mathbf{b}_2$ , 其中  $\mathbf{b}_1 \in \mathcal{R}(\mathbf{A})$ ,  $\mathbf{b}_2 \in \mathcal{N}(\mathbf{A}^H) = [\mathcal{R}(\mathbf{A})]^\perp$  且  $\mathbf{b}_2 \neq \mathbf{0}$ . 注意到  $\mathbf{Ax} - \mathbf{b}_1 \in \mathcal{R}(\mathbf{A})$  及  $\mathbf{b}_2 \in [\mathcal{R}(\mathbf{A})]^\perp$ , 可得  $(\mathbf{Ax} - \mathbf{b}_1) \perp \mathbf{b}_2$ , 于是有

$$\|\mathbf{Ax} - \mathbf{b}\|_2^2 = \|(\mathbf{Ax} - \mathbf{b}_1) + (-\mathbf{b}_2)\|_2^2 = \|\mathbf{Ax} - \mathbf{b}_1\|_2^2 + \|\mathbf{b}_2\|_2^2,$$

这表明  $\min \|\mathbf{Ax} - \mathbf{b}\|_2$  等价于  $\min \|\mathbf{Ax} - \mathbf{b}_1\|_2$ .

因为  $\mathbf{b}_1 \in \mathcal{R}(\mathbf{A})$ , 所以方程组  $\mathbf{Ax} = \mathbf{b}_1$  有解, 根据定理 5.2 可得它的唯一极小范数解为  $\mathbf{A}^\dagger \mathbf{b}_1$ . 由于  $\mathbf{b}_2 \in \mathcal{N}(\mathbf{A}^H)$ , 所以  $\mathbf{A}^H \mathbf{b}_2 = \mathbf{0}$ . 于是得

$$\mathbf{A}^\dagger \mathbf{b}_2 = \mathbf{A}^\dagger \mathbf{A} \mathbf{A}^\dagger \mathbf{b}_2 = \mathbf{A}^\dagger (\mathbf{A} \mathbf{A}^\dagger)^H \mathbf{b}_2 = \mathbf{A}^\dagger (\mathbf{A}^\dagger)^H \mathbf{A}^H \mathbf{b}_2 = \mathbf{0},$$

所以  $\mathbf{x}_0 = \mathbf{A}^\dagger \mathbf{b} = \mathbf{A}^\dagger (\mathbf{b}_1 + \mathbf{b}_2) = \mathbf{A}^\dagger \mathbf{b}_1$  是方程组  $\mathbf{Ax} = \mathbf{b}_1$  的唯一极小范数解, 也是方程组 (5.3) 的唯一极小范数最小二乘解. 证毕.

□



Back

Close



## §5.1.2 线性 LS 的等价性问题

### 1. 法方程

下面的定理给出了最小二乘问题极小解的一个刻画.

**定理 5.4**  $\boldsymbol{x}$  是最小二乘问题 (5.1) 的极小解, 即  $\boldsymbol{x} \in S_{\text{LS}}$  的充分必要条件是  $\boldsymbol{x}$  为方程

$$\boldsymbol{A}^{\text{H}} \boldsymbol{A} \boldsymbol{x} = \boldsymbol{A}^{\text{H}} \boldsymbol{b} \quad (5.10)$$

的解, 其中式 (5.10) 称为最小二乘问题的法方程.

**证明** 注意到最小二乘问题 (5.1) 等价于极小化问题

$$\min \varphi(\boldsymbol{x}) = \frac{1}{2} \|\boldsymbol{A} \boldsymbol{x} - \boldsymbol{b}\|_2^2 = \frac{1}{2} \boldsymbol{x}^{\text{H}} (\boldsymbol{A}^{\text{H}} \boldsymbol{A}) \boldsymbol{x} - (\boldsymbol{b}^{\text{H}} \boldsymbol{A}) \boldsymbol{x} + \frac{1}{2} \|\boldsymbol{b}\|_2^2.$$

由于  $\boldsymbol{A}^{\text{H}} \boldsymbol{A} \in \mathbb{C}^{n \times n}$  是半正定矩阵, 因此  $n$  元实函数  $\varphi(\boldsymbol{x})$  是凸函数, 故  $\boldsymbol{x}$  是最小二乘问题 (5.1) 的极小解等价于

$$\nabla \varphi(\boldsymbol{x}) = \boldsymbol{A}^{\text{H}} (\boldsymbol{A} \boldsymbol{x} - \boldsymbol{b}) = \mathbf{0}.$$

证毕.

□



定理 5.4 说明最小二乘问题 (5.1) 与法方程 (5.10) 是等价的, 即法方程 (5.10) 与最小二乘问题 (5.1) 有相同的解集.

## 2. KKT 方程

下面的定理给出最小二乘问题 (5.1) 的另一个等价性问题.

定理 5.5 设  $A \in \mathbb{C}^{m \times n}$ ,  $b \in \mathbb{R}^n$ . 则  $x$  和  $r = b - Ax$  分别为最小二乘问题 (5.1) 的极小解和残量的充分必要条件是  $x$  和  $r$  为鞍点系统

$$\begin{bmatrix} I & A \\ A^H & O \end{bmatrix} \begin{bmatrix} r \\ x \end{bmatrix} = \begin{bmatrix} b \\ 0 \end{bmatrix} \quad (5.11)$$

的解. 上述线性系统称为最小二乘问题的 Karush-Kuhn-Tucker 方程 (KKT 方程).

证明 若  $x$  为最小二乘问题 (5.1) 的极小解, 而  $r = b - Ax$  为





其残量, 则

$$\boldsymbol{x} = \boldsymbol{A}^\dagger \boldsymbol{b} + (\boldsymbol{I} - \boldsymbol{A}^\dagger \boldsymbol{A}) \boldsymbol{z}, \quad \boldsymbol{r} = \boldsymbol{b} - \boldsymbol{A} \boldsymbol{x} = \boldsymbol{b} - \boldsymbol{A} \boldsymbol{A}^\dagger \boldsymbol{b} = (\boldsymbol{I} - \boldsymbol{A} \boldsymbol{A}^\dagger) \boldsymbol{b}.$$

由广义逆  $\boldsymbol{A}^\dagger$  的性质及等式  $\boldsymbol{r} + \boldsymbol{A} \boldsymbol{x} = \boldsymbol{b}$ , 得

$$\boldsymbol{A}^H \boldsymbol{r} = \boldsymbol{A}^H (\boldsymbol{I} - \boldsymbol{A} \boldsymbol{A}^\dagger) \boldsymbol{b} = [(\boldsymbol{I} - \boldsymbol{A} \boldsymbol{A}^\dagger) \boldsymbol{A}]^H \boldsymbol{b} = \mathbf{0}.$$

故式 (5.11) 是相容的线性系统, 且  $\boldsymbol{x}$  和  $\boldsymbol{r}$  满足式 (5.11).

反之, 通过验证广义逆的四个条件, 可以验证

$$\boldsymbol{B}^\dagger \equiv \begin{bmatrix} \boldsymbol{I} & \boldsymbol{A} \\ \boldsymbol{A}^H & \mathbf{O} \end{bmatrix}^\dagger = \begin{bmatrix} \boldsymbol{I} - \boldsymbol{A} \boldsymbol{A}^\dagger & (\boldsymbol{A}^\dagger)^H \\ \boldsymbol{A}^\dagger & -\boldsymbol{A}^\dagger (\boldsymbol{A}^\dagger)^H \end{bmatrix}.$$

故式 (5.11) 的任一解向量  $\boldsymbol{x}, \boldsymbol{r}$  有如下形式

$$\begin{bmatrix} \boldsymbol{r} \\ \boldsymbol{x} \end{bmatrix} = \boldsymbol{B}^\dagger \begin{bmatrix} \boldsymbol{b} \\ \mathbf{0} \end{bmatrix} + (\boldsymbol{I} - \boldsymbol{B}^\dagger \boldsymbol{B}) \begin{bmatrix} \boldsymbol{y} \\ \boldsymbol{z} \end{bmatrix} = \begin{bmatrix} (\boldsymbol{I} - \boldsymbol{A} \boldsymbol{A}^\dagger) \boldsymbol{b} \\ \boldsymbol{A}^\dagger \boldsymbol{b} - (\boldsymbol{I} - \boldsymbol{A}^\dagger \boldsymbol{A}) \boldsymbol{z} \end{bmatrix},$$





式中:  $\mathbf{y} \in \mathbb{C}^m$ ,  $\mathbf{z} \in \mathbb{C}^n$  为任意向量. 故满足式 (5.11) 的任一组向量  $\mathbf{x}, \mathbf{r}$  分别为式 (5.1) 的极小解和残量. 证毕.  $\square$

### §5.1.3 线性最小二乘问题的正则化

设矩阵  $\mathbf{A} \in \mathbb{C}_r^{m \times n}$  的奇异值分解为

$$\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^{\text{H}}, \quad (5.12)$$

式中:  $\mathbf{U} = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_m]$  为  $m$  阶酉矩阵;  $\mathbf{V} = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n]$  为  $n$  阶酉矩阵;  $l = \min\{m, n\}$ ;  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0 = \sigma_{r+1} = \dots = \sigma_l = 0$ ,

$$\mathbf{\Sigma} = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_l). \quad (5.13)$$

则最小二乘问题 (5.1) 的极小范数最小二乘解  $\mathbf{x}_{\text{LS}}$  可表示为

$$\mathbf{x}_{\text{LS}} = \mathbf{A}^{\dagger} \mathbf{b} = \sum_{i=1}^r \frac{\mathbf{u}_i^{\text{H}} \mathbf{b}}{\sigma_i} \mathbf{v}_i. \quad (5.14)$$



Back

Close





由于舍入误差的存在, 所有用于计算  $A^\dagger$  和  $x_{LS}$  的算法, 实际上是计算某个扰动矩阵  $\hat{A} = A + \Delta A$  的广义逆  $\hat{A}^\dagger$  以及  $\hat{x}_{LS} = \hat{A}^\dagger \hat{b}$ .

当  $A$  为病态的满秩矩阵, 即存在  $k$  ( $1 \leq k < l$ ), 使得  $\sigma_k \gg \sigma_{k+1} \approx 0$ . 由于在极小解  $x_{LS}$  的表达式中存在项

$$\frac{u_i^H b}{\sigma_i} v_i, \quad i = k + 1, \dots, l,$$

因此, 对  $A$  的较小扰动, 将会使极小解  $x_{LS}$  产生很大的误差. 此时, 称  $A$  为数值秩亏的. 当矩阵  $A$  秩亏而  $\Delta A$  很小, 则广义逆的不连续性表明了原来意义上的秩不再适用于数值计算. 当  $\hat{A}$  和  $A$  的秩不相同,  $\hat{A}^\dagger$  和  $A^\dagger$ ,  $\hat{x}_{LS}$  和  $x_{LS}$  可能会相差很大, 而且扰动  $\Delta A$  越小, 其相差的程度会越大.

### 1. 截断的 LS 问题

最小二乘问题的第一种正则化方法是截断的 LS 问题. 首先给





出矩阵  $\mathbf{A}$  的  $\delta$  秩的定义.

定义 5.2 设  $\mathbf{A} \in \mathbb{C}^{m \times n}$  和  $\delta > 0$  给定. 称数

$$k = \min_{\mathbf{B} \in \mathbb{C}^{m \times n}} \{\text{rank}(\mathbf{B}) : \|\mathbf{A} - \mathbf{B}\|_2 \leq \delta\} \quad (5.15)$$

为矩阵  $\mathbf{A}$  的  $\delta$  秩.

由定义 5.2 和矩阵的降秩最佳逼近定理, 当  $k < l$  时, 有

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = \min_{\text{rank}(\mathbf{B}) \leq k} \|\mathbf{A} - \mathbf{B}\|_2 = \sigma_{k+1},$$

式中:

$$\mathbf{A}_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^{\text{H}}.$$

因此, 矩阵  $\mathbf{A}$  的  $\delta$  秩为  $k$  的充分必要条件是

$$\sigma_1 \geq \cdots \geq \sigma_k > \sigma_{k+1} \geq \cdots \geq \sigma_l.$$



Back

Close



对于最小二乘问题 (5.1), 截断的 LS 问题为

$$\|\mathbf{A}_k \mathbf{x} - \mathbf{b}\|_2 = \min_{\mathbf{z} \in \mathbb{C}^n} \|\mathbf{A}_k \mathbf{z} - \mathbf{b}\|_2, \quad (5.16)$$

式中:  $\mathbf{A}_k$  为  $\mathbf{A}$  的最佳秩- $k$  逼近. 此时, 式 (5.16) 的极小范数最小二乘解  $\bar{\mathbf{x}}_{\text{LS}}$  可表示为

$$\bar{\mathbf{x}}_{\text{LS}} = \mathbf{A}_k^\dagger \mathbf{b} = \sum_{i=1}^k \frac{\mathbf{u}_i^H \mathbf{b}}{\sigma_i} \mathbf{v}_i. \quad (5.17)$$

## 2. Tikhonov 正则化

最小二乘问题的另一种正则化方法是 Tikhonov 正则化, 即考虑如下的正则化问题:

$$\|\mathbf{A} \mathbf{x} - \mathbf{b}\|_2^2 + \tau^2 \|\mathbf{D} \mathbf{x}\|_2^2 = \min_{\mathbf{z} \in \mathbb{C}^n} \|\mathbf{A} \mathbf{z} - \mathbf{b}\|_2^2 + \tau^2 \|\mathbf{D} \mathbf{z}\|_2^2, \quad (5.18)$$

式中:  $\tau > 0$ ;  $\mathbf{D} = \text{diag}(d_1, d_2, \dots, d_n)$  为正定的对角矩阵.



Back

Close



易见, 式 (5.18) 等价于

$$\left\| \begin{bmatrix} \tau \mathbf{D} \\ \mathbf{A} \end{bmatrix} \mathbf{x} - \begin{bmatrix} \mathbf{0} \\ \mathbf{b} \end{bmatrix} \right\|_2^2 = \min_{\mathbf{z} \in \mathbb{C}^n} \left\| \begin{bmatrix} \tau \mathbf{D} \\ \mathbf{A} \end{bmatrix} \mathbf{z} - \begin{bmatrix} \mathbf{0} \\ \mathbf{b} \end{bmatrix} \right\|_2^2, \quad (5.19)$$

当  $\tau > 0$  时, 系数矩阵是列满秩的, 因此有唯一的最小二乘解.

设  $m \geq n$ . 则当  $\mathbf{D} = \mathbf{I}$  时, 式 (5.19) 系数矩阵的奇异值为  $\tilde{\sigma}_i = \sqrt{\sigma_i^2 + \tau^2}$ ,  $i = 1, 2, \dots, n$ . 此时式 (5.18) 的解可表示为

$$\mathbf{x}(\tau) = \sum_{i=1}^n \frac{(\mathbf{u}_i^H \mathbf{b}) \sigma_i}{\sigma_i^2 + \tau^2} \mathbf{v}_i = \sum_{i=1}^n \frac{(\mathbf{u}_i^H \mathbf{b}) \eta_i}{\sigma_i} \mathbf{v}_i, \quad \eta_i = \frac{\sigma_i^2}{\sigma_i^2 + \tau^2}, \quad (5.20)$$

式中:  $\eta_i$  为滤波因子. 当  $\tau \ll \sigma_i$  时,  $\eta_i \approx 1$ ; 当  $\tau \gg \sigma$  时,  $\eta_i \ll 1$ .

正则化问题 (5.18) 的优点是它的解可以通过 QR 分解

$$\begin{bmatrix} \tau \mathbf{D} \\ \mathbf{A} \end{bmatrix} = \mathbf{Q} \begin{bmatrix} \mathbf{R} \\ \mathbf{O} \end{bmatrix}$$



得到.

**注 5.2** 最小二乘问题的正则化已经把原来的最小二乘问题化为新的最小二乘问题. 事实上, 由式 (5.17) 和式 (5.20) 可以看出, 截断的 LS 问题和 Tikhonov 正则化的 LS 问题, 与最小二乘问题 (5.1) 的极小范数最小二乘解以及相应的残量各不相同. 正则化方法通常用于处理病态最小二乘问题和反问题等不适定问题.



21/96



Back

Close



## §5.2 求解满秩最小二乘问题的数值方法

本节假定最小二乘问题 (5.1) 中的矩阵  $\mathbf{A} \in \mathbb{C}^{m \times n}$  ( $m \geq n$ ) 为列满秩矩阵, 即  $\text{rank}(\mathbf{A}) = n$ . 此时最小二乘问题 (5.1) 有唯一的极小范数最小二乘解  $\mathbf{x}_{\text{LS}}$ , 并且连续地依赖给定的数据  $\mathbf{A}$  和  $\mathbf{b}$ . 对于这类问题, 介绍两种最基本的数值方法.

### §5.2.1 法方程方法

由定理 5.4, 最小二乘问题 (5.1) 等价于其法方程

$$\mathbf{A}^{\text{H}} \mathbf{A} \mathbf{x} = \mathbf{A}^{\text{H}} \mathbf{b}.$$

当  $\text{rank}(\mathbf{A}) = n$  时,  $\mathbf{A}^{\text{H}} \mathbf{A}$  为 Hermite 正定矩阵, 法方程 (5.10) 的唯一解可以用 Cholesky 分解法求得. 写出算法步骤如下:





**算法 5.1 (法方程 Cholesky 分解法)** 给定  $\mathbf{A} \in \mathbb{C}^{m \times n}$  ( $m \geq n$ ) 为列满秩矩阵,  $\mathbf{b} \in \mathbb{C}^m$ . 本算法计算  $\|\mathbf{Ax} - \mathbf{b}\|_2$  的极小解  $\mathbf{x}_{\text{LS}}$ .

步 1, 对  $n$  阶 Hermite 正定矩阵  $\mathbf{B} = \mathbf{A}^H \mathbf{A}$  作 Cholesky 分解  $\mathbf{B} = \mathbf{LL}^H$ , 其中  $\mathbf{L}$  为下三角矩阵.

步 2, 依次解  $\mathbf{Ly} = \mathbf{A}^H \mathbf{b}$ ,  $\mathbf{L}^H \mathbf{x} = \mathbf{y}$  得到最小二乘问题 (5.1) 的解  $\mathbf{x}_{\text{LS}}$ .

$n$  阶 Hermite 正定矩阵  $\mathbf{B}$  的 Cholesky 分解需要  $O(n^3/3)$  次乘法. 而计算  $\mathbf{A}^H \mathbf{A}$  需要  $mn^2$  次乘法. 在算法 5.1 中第 2 步的计算量 (约  $O(n^2)$  次乘法) 与第 1 步相比可以忽略. 所以该算法需要的乘法次数为  $O(mn^2 + n^3/3)$ . 当  $m \gg n$  时, 算法的主要工作量在于  $\mathbf{A}^H \mathbf{A}$  的计算.



### §5.2.2 QR 分解方法

本节考虑最小二乘问题 (5.1) 中的矩阵  $A \in \mathbb{R}^{m \times n}$  ( $m \geq n$ ) 的情形. 根据正交矩阵保持向量 2-范数不变的性质, 对于任意的正交矩阵  $Q \in \mathbb{R}^{m \times m}$ , 最小二乘问题 (5.1) 等价于

$$\|Q^T(Ax - b)\|_2 = \min \{ \|Q^T(Az - b)\|_2 : z \in \mathbb{R}^n \}. \quad (5.21)$$

这样, 就可望通过适当选取正交矩阵  $Q$ , 使原问题 (5.1) 转化为较为容易求解的最小二乘问题 (5.21), 这就是正交化方法—QR 分解方法的基本思想.

设  $A$  有 QR 分解:

$$A = Q \begin{bmatrix} R \\ O \end{bmatrix} = Q_1 R, \quad (5.22)$$







式中:  $Q \in \mathbb{R}^{m \times m}$  为正交矩阵;  $Q_1$  为  $Q$  的前  $n$  列组成的矩阵;  
 $R \in \mathbb{R}^{n \times n}$  为对角元均为正的上三角矩阵.

现取式 (5.21) 中的正交矩阵为分解式 (5.22) 中的  $Q$ , 并记

$$f = Q^T b = \begin{bmatrix} Q_1^T \\ Q_2^T \end{bmatrix} b = \begin{bmatrix} f_1 \\ f_2 \end{bmatrix} \begin{matrix} n \\ m - n \end{matrix}, \quad (5.23)$$

则对任意的  $x \in \mathbb{C}^n$ , 有

$$\begin{aligned} \|Q^T(Ax - b)\|_2^2 &= \left\| \begin{bmatrix} R \\ O \end{bmatrix} x - Q^T b \right\|_2^2 = \left\| \begin{bmatrix} R \\ O \end{bmatrix} x - \begin{bmatrix} f_1 \\ f_2 \end{bmatrix} \right\|_2^2 \\ &= \|Rx - f_1\|_2^2 + \|f_2\|_2^2. \end{aligned}$$

由此可知,  $x$  是最小二乘问题 (5.1) 的解, 当且仅当  $x$  是上三角形方程组  $Rx = f_1$  的解.



Back

Close



根据上述讨论,有如下的 QR 分解算法. 在实施过程中, 采取对增广矩阵  $\tilde{\mathbf{A}} = [\mathbf{A}, \mathbf{b}]$  进行 QR 分解:

$$\mathbf{H}_n \cdots \mathbf{H}_2 \mathbf{H}_1 [\mathbf{A}, \mathbf{b}] = [\mathbf{R}, \tilde{\mathbf{b}}] \implies \mathbf{Q}^T [\mathbf{A}, \mathbf{b}] = [\mathbf{R}, \tilde{\mathbf{b}}], \quad (5.24)$$

得

$$\mathbf{A} = \mathbf{Q}\mathbf{R}, \quad \tilde{\mathbf{b}} = \mathbf{Q}^T \mathbf{b},$$

式中:  $\mathbf{Q} = \mathbf{H}_1 \mathbf{H}_2 \cdots \mathbf{H}_n$ . 式 (5.24) 表明, 对增广矩阵  $\tilde{\mathbf{A}} = [\mathbf{A}, \mathbf{b}]$  实施 QR 分解, 当把矩阵  $\mathbf{A}$  约化为上三角矩阵  $\mathbf{R}$  时, 向量  $\mathbf{b}$  约化成了  $\mathbf{Q}^T \mathbf{b}$ , 这正是所需要的.

**算法 5.2 (LS 问题 QR 分解法)** 给定  $\mathbf{A} \in \mathbb{R}^{m \times n} (m \geq n)$  为列满秩矩阵,  $\mathbf{b} \in \mathbb{R}^m$ . 本算法计算  $\|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2$  的极小解  $\mathbf{x}_{\text{LS}}$ .

步 1, 计算增广矩阵  $\tilde{\mathbf{A}} = [\mathbf{A}, \mathbf{b}]$  的 QR 分解并覆盖  $\tilde{\mathbf{A}}$ .

步 2, 用回代法求解上三角形方程组  $\text{triu}(\tilde{\mathbf{A}}(1:n, 1:n))\mathbf{x} = \tilde{\mathbf{A}}(1:n, n+1)$ , 得到最小二乘解  $\mathbf{x}_{\text{LS}}$ , 其中记号  $\text{triu}(\mathbf{B})$  表示提取矩阵  $\mathbf{B}$  的上三角部分组成的上三角形矩阵.



Back

Close



用算法 5.2 求解满秩最小二乘问题需要  $2mn^2 - 2n^3/3$  个 flop. 更新  $b$  所需的  $O(mn)$  个 flop 和回代法所需的  $O(n^2)$  个 flop 与分解  $A$  所需的工作量相比是微不足道的.

注 5.3 算法 5.2 的主要工作量集中在增广矩阵  $\tilde{A}$  的 QR 分解. 可用如下三种方法之一实现这一分解:

- (1) Householder 方法.
- (2) Givens 正交化方法.
- (3) 修正的 Gram-Schmit 方法.

根据算法 5.2, 采用 Householder 变换 QR 分解编制 MATLAB 程序如下:

```
function [x]=ls_houseqr(A,b)
%用Householder变换QR分解求最小二乘问题min||Ax-b||
[m,n]=size(A);
```



Back

Close



```
[A]=house_qr([A,b]); %调用Householder变换QR分解程序  
x=triu(A(1:n,1:n))\A(1:n,n+1);
```

例 5.1 用 MATLAB 程序 ls\_houseqr.m 求解最小二乘问题

$\min \| \mathbf{Ax} - \mathbf{b} \|_2$ , 其中

$$\mathbf{A} = \begin{bmatrix} 2 & 3 & 4 & 5 \\ 4 & 3 & 2 & 1 \\ 4 & 5 & 6 & 7 \\ 9 & 5 & 7 & 2 \\ 4 & 2 & 5 & 3 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 20 \\ 22 \\ 35 \\ 42 \\ 50 \end{bmatrix}.$$

解 在 MATLAB 命令窗口输入:

```
>> A=[2 3 4 5; 4 3 2 1; 4 5 6 7; 9 5 7 2; 4 2 5 3];  
>> b=[20 22 35 42 50]'; x=ls_houseqr(A,b)
```

即可得计算结果.



Back

Close



## §5.3 求解秩亏最小二乘问题的数值解法

本节讨论秩亏最小二乘问题  $\min \|Ax - b\|_2$  的数值解法. 如果  $A \in \mathbb{R}_r^{m \times n}$  ( $m \geq n$ ) 是秩亏损的, 即  $\text{rank}(A) = r < n$ , 此时, 最小二乘问题 (5.1) 有无穷多个解, 且 5.2 节所介绍的处理满秩最小二乘问题的法方程方法和 QR 分解法都不再有效. 因此, 本节专门讨论秩亏最小二乘问题的数值求解方法.

### §5.3.1 列主元 QR 分解法

当矩阵  $A$  秩亏损时, 其 QR 分解不一定能给出列空间  $\mathcal{R}(A)$  的一组标准正交基. 此时可计算经过列置换之后的矩阵  $\tilde{A} = AP$  的 QR 分解来解决, 即  $AP = QR$ , 其中  $P$  是置换矩阵.

下面介绍列主元 QR 分解法来解决秩亏的最小二乘问题. 设



Back

Close

最小二乘问题 (5.1) 中的已知向量  $\mathbf{b}$  分解为

$$\mathbf{b} = \mathbf{b}_1 + \mathbf{b}_2, \quad \mathbf{b}_1 \in \mathcal{R}(\mathbf{A}), \quad \mathbf{b}_2 \in \mathcal{R}(\mathbf{A})^\perp. \quad (5.25)$$

易证问题 (5.1) 等价于

$$\mathbf{A}\mathbf{x} = \mathbf{b}_1. \quad (5.26)$$

现假定  $\mathcal{R}(\mathbf{A}) = \mathcal{R}(\mathbf{Q}_1)$ , 其中  $\mathbf{Q}_1 \in \mathbb{R}^{m \times r}$  且  $\mathbf{Q}_1^T \mathbf{Q}_1 = \mathbf{I}_r$ , 即  $\mathbf{Q}_1$  的列构成  $\mathcal{R}(\mathbf{A})$  的一组标准正交基. 则存在矩阵  $\mathbf{S} \in \mathbb{R}^{r \times n}$  和向量  $\mathbf{h} \in \mathbb{R}^r$ , 使得

$$\mathbf{A} = \mathbf{Q}_1 \mathbf{S}, \quad \mathbf{b}_1 = \mathbf{Q}_1 \mathbf{h}. \quad (5.27)$$

将式 (5.27) 代入式 (5.26), 并注意到  $\mathbf{Q}_1$  的列线性无关, 可知 (5.26) 等价于

$$\mathbf{S}\mathbf{x} = \mathbf{h}. \quad (5.28)$$





显然方程组 (5.28) 总是有解的. 进一步, 由式 (5.27) 可知

$$S = Q_1^T A, \quad h = Q_1^T b_1 = Q_1^T (b - b_2) = Q_1^T b. \quad (5.29)$$

因此, 只要求得  $\mathcal{R}(A)$  的一组标准正交基, 就可以通过式 (5.29) 和式 (5.28) 求得最小二乘问题 (5.1) 的任一解.

现由于  $\text{rank}(A) = r < n$ , 2.2 节介绍的 QR 分解式 (2.9) 一般不能产生  $\mathcal{R}(A)$  的一组标准正交基. 但如果先对  $A$  的列进行适当的排列使其前  $r$  列线性无关, 然后再进行 QR 分解, 则仍然可以产生  $\mathcal{R}(A)$  的一组标准正交基.

设有分解式

$$AP = Q \begin{bmatrix} R_{11} & R_{12} \\ O & O \end{bmatrix} \begin{matrix} r \\ m-r \end{matrix}, \quad (5.30)$$

$r \qquad n-r$





式中:  $P$  为置换矩阵;  $Q$  为正交矩阵;  $R_{11}$  为非奇异的上三角矩阵.  
则  $Q$  的前  $r$  列就是  $\mathcal{R}(A)$  的一组标准正交基.

一旦求出式 (5.30) 的分解式, 则由式 (5.26), 有

$$(Q^T AP)(P^T x) = Q^T b_1,$$

由式 (5.30) 并令  $P^T x = \begin{bmatrix} w \\ z \end{bmatrix}$ , 得

$$\begin{bmatrix} R_{11} & R_{12} \\ O & O \end{bmatrix} \begin{bmatrix} w \\ z \end{bmatrix} = Q^T b_1 = \begin{bmatrix} Q_1^T \\ Q_2^T \end{bmatrix} b_1 = \begin{bmatrix} h \\ g \end{bmatrix},$$

即

$$\begin{bmatrix} R_{11}w + R_{12}z \\ 0 \end{bmatrix} = \begin{bmatrix} h \\ g \end{bmatrix}.$$



Back

Close



由此, 得

$$w = R_{11}^{-1}(h - R_{12}z), \quad g = 0.$$

故

$$x = P \begin{bmatrix} w \\ z \end{bmatrix} = P \begin{bmatrix} R_{11}^{-1}(h - R_{12}z) \\ z \end{bmatrix}, \quad z \in \mathbb{R}^{n-r},$$

这就是最小二乘问题 (5.1) 的通解. 注意到上式还可以写为

$$\begin{aligned} x &= x_b + P \begin{bmatrix} -R_{11}^{-1}R_{12} \\ I_{n-r} \end{bmatrix} z, \\ x_b &= P \begin{bmatrix} R_{11}^{-1}h \\ 0 \end{bmatrix}, \quad z \in \mathbb{R}^{n-r}, \end{aligned} \tag{5.31}$$

式中:  $x_b$  为最小二乘问题的基本解.





下面讨论分解式 (5.30) 的具体实施过程. 类似于分解式 (2.9) 的计算过程, 这一分解可用 Householder 变换和适当的初等列变换相结合逐步求得. 假设对某一正整数  $k$ , 已经求得  $k - 1$  个 Householder 变换  $H_1, H_2, \dots, H_{k-1}$  和  $k - 1$  个初等变换矩阵  $P_1, P_2, \dots, P_{k-1}$ , 使得

$$\begin{aligned} R_{k-1} &= (H_{k-1} \cdots H_2 H_1) A (P_1 P_2 \cdots P_{k-1}) \\ &= \begin{bmatrix} R_{11}^{(k-1)} & R_{12}^{(k-1)} \\ \mathbf{O} & R_{22}^{(k-1)} \end{bmatrix} \begin{matrix} k-1 \\ m-k+1 \end{matrix}, \end{aligned} \quad (5.32)$$

$k-1 \quad n-k+1$

式中:  $R_{11}^{(k-1)}$  为非奇异的上三角矩阵. 现记

$$R_{22}^{(k-1)} = [\mathbf{v}_k^{(k-1)}, \mathbf{v}_{k+1}^{(k-1)}, \dots, \mathbf{v}_n^{(k-1)}],$$

即  $\mathbf{v}_i^{(k-1)}$  表示  $R_{22}^{(k-1)}$  的第  $i - k + 1$  列. 下一步是首先确定指标





$p (k \leq p \leq n)$  满足

$$\|\mathbf{v}_p^{(k-1)}\|_2 = \max \left\{ \|\mathbf{v}_k^{(k-1)}\|_2, \|\mathbf{v}_{k+1}^{(k-1)}\|_2, \dots, \|\mathbf{v}_n^{(k-1)}\|_2 \right\}. \quad (5.33)$$

若  $\|\mathbf{v}_p^{(k-1)}\|_2 = 0$ , 停止计算. 否则取  $\mathbf{P}_k$  为第  $k$  列与第  $p$  列交换的初等变换矩阵, 并确定一个 Householder 变换  $\widetilde{\mathbf{H}}_k \in \mathbb{R}^{(m-k+1) \times (m-k+1)}$ , 使得

$$\widetilde{\mathbf{H}}_k \mathbf{v}_p^{(k-1)} = \gamma_{kk} \mathbf{e}_1.$$

令  $\mathbf{H}_k = \text{diag}(\mathbf{I}_{k-1}, \widetilde{\mathbf{H}}_k)$ , 则有

$$\mathbf{R}_k = \begin{bmatrix} \mathbf{R}_{11}^{(k)} & \mathbf{R}_{12}^{(k)} \\ \mathbf{O} & \mathbf{R}_{22}^{(k)} \end{bmatrix} \begin{matrix} k \\ m - k \end{matrix}, \quad (5.34)$$

$k \quad n - k$

式中:  $\mathbf{R}_{11}^{(k)}$  为  $k \times k$  阶非奇异上三角矩阵.





这样, 从  $k = 1$  出发, 依次进行  $r (= \text{rank}(\mathbf{A}))$  次“列选主元”的 Householder 变换, 即可得到分解式 (5.30). 值得一提的是, 如果只是利用这一分解来求秩亏的最小二乘问题的解 (通常是用来求基本解), 那么正交矩阵  $\mathbf{Q} = \mathbf{H}_1 \mathbf{H}_2 \cdots \mathbf{H}_r$  没有必要显式地计算, 只需将计算过程中每一步的 Householder 变换同步地作用在向量  $\mathbf{b}$  上即可.

此外, 为了减少“列选主元”的计算量, 不必每一步都按照 2-范数的定义去计算式 (5.33) 中的范数, 因为对于任何正交矩阵  $\mathbf{Q} \in \mathbb{R}^{l \times l}$  均成立

$$\mathbf{Q}^T \mathbf{x} = \begin{bmatrix} \alpha \\ \mathbf{z} \end{bmatrix} \begin{matrix} 1 \\ l-1 \end{matrix} \implies \|\mathbf{z}\|_2^2 = \|\mathbf{x}\|_2^2 - \alpha^2.$$

这样, 可以通过修正旧的范数来得到新的范数, 即

$$\|\mathbf{x}^{(j)}\|_2^2 = \|\mathbf{x}^{(j-1)}\|_2^2 - a_{kj}^2.$$





综上所述, 可写出计算分解式 (5.30) 的算法并用以求解秩亏最小二乘问题的详细步骤如下.

### 算法 5.3 (秩亏最小二乘问题的列主元 QR 分解法)

步 1, 输入矩阵  $\mathbf{A} = (a_{ij}) \in \mathbb{R}^{m \times n}$ ,  $\mathbf{b} \in \mathbb{R}^m$ . 计算

$$p(j) := j, \quad \sigma_j = \mathbf{A}(:, j)^T \mathbf{A}(:, j), \quad j = 1, 2, \dots, n.$$

置  $k := 1$ .

步 2, 确定  $r$  使满足  $\sigma_r = \max_{k \leq j \leq n} \sigma_j$ . 若  $\sigma_r = 0$ , 停算.

步 3, 交换  $p(r)$  与  $p(k)$ ,  $\sigma_r$  与  $\sigma_k$  以及  $\mathbf{A}(:, r)$  与  $\mathbf{A}(:, k)$ .

步 4, 确定一个 Householder 矩阵  $\widetilde{\mathbf{H}}_k$  使得

$$\widetilde{\mathbf{H}}_k \mathbf{A}(k : m, k) = \gamma_{kk} \mathbf{e}_1,$$

并计算

$$[\mathbf{A}, \mathbf{b}] := \text{diag}(\mathbf{I}_{k-1}, \widetilde{\mathbf{H}}_k)[\mathbf{A}, \mathbf{b}], \quad \sigma_j := \sigma_j - a_{kj}^2, \quad j = k+1, \dots, n.$$

步 5, 置  $k := k+1$ , 转步 2.





算法 5.3 的运算量是  $2mnr - r^2(m + n) + 2r^3/3$  次乘除法, 其中  $r = \text{rank}(\mathbf{A})$ . 分解式 (5.30) 中的上三角矩阵  $\mathbf{R}$  存储在  $\mathbf{A}$  的上三角部分, 初等变换矩阵  $\mathbf{P}$  由整数向量  $p(1:n)$  来记录, 即  $\mathbf{P} = \mathbf{P}_1\mathbf{P}_2\cdots\mathbf{P}_r$ , 其中  $\mathbf{P}_k$  是通过单位矩阵交换第  $k$  列与第  $p(k)$  列而得到. 而第  $k$  个 Householder 向量的  $k+1:n$  分量存储在  $\mathbf{A}(k+1:m, k)$  中.

根据算法 5.3 编制 MATLAB 程序如下:

```
function [x,fval,P]=piv_house_qr(A,b)
%秩亏最小二乘问题的列主元QR分解法
[m,n]=size(A); %Q=eye(m);
A1=A; b1=b;
P=eye(n);
for j=1:n
```



Back

Close



```
        c(j)=A(1:m,j) '*A(1:m,j);  
end  
[cr,r]=max(c);  
for k=1:n  
    if (cr<=0), break; end  
    c([k r])=c([r k]);  
    P(:, [k r])=P(:, [r k]);  
    A(1:m, [k r])= A(1:m, [r k]);  
    [v,beta]=house(A(k:m,k));  
    H=eye(m-k+1)-beta*v*v';  
    A(k:m,k:n)=H*A(k:m,k:n);  
    b(k:m)=H*b(k:m);  
    for j=k+1:n
```





```
        c(j)=c(j)-A(k,j)^2;
    end
    [cr,r]=max(c(k+1:n));
    r=r+k;
end
for i=1:m
    if sum(abs(A(i,:)))<1.0e-10
        rank=i-1; break;
    end
end
R11=A(1:rank,1:rank); c=b(1:rank);
x=P*[R11\c; zeros(rank,1)];
fval=norm(A1*x-b1);
```







例 5.2 用 MATLAB 程序 piv\_house\_qr.m 求解超定方程组  $Ax = b$  的最小二乘解, 其中

$$A = \begin{bmatrix} 1 & 2 & 3 & 4 \\ 1 & 4 & 5 & 6 \\ 1 & 5 & 6 & 7 \\ 1 & 8 & 9 & 10 \\ 1 & 11 & 12 & 13 \end{bmatrix}, \quad x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix}, \quad b = \begin{bmatrix} 11 \\ 13 \\ 15 \\ 18 \\ 20 \end{bmatrix}.$$

解 在 MATLAB 命令窗口输入:

```
>> A=[1 2 3 4; 1 4 5 6; 1 5 6 7; 1 8 9 10; 1 11 12 13];  
>> b=[11 13 15 18 20]';  
>> [x,fval,P]=piv_house_qr(A,b)
```

即可得计算结果.

此外, 如果希望求出秩亏最小二乘问题的极小范数解, 则还需





将分解式 (5.30) 中的  $R_{12}$  约化为零矩阵. 这可通过  $r$  次 Householder 变换来完成. 即确定  $r$  个 Householder 变换  $Z_1, \dots, Z_r$  和一个置换矩阵  $\tilde{P}$  使得

$$[R_{11}, R_{12}] Z_1 \cdots Z_r \tilde{P} = [T, O],$$

式中:  $T \in \mathbb{R}^{r \times r}$  为上三角矩阵.

现令  $Z = P Z_1 \cdots Z_r \tilde{P}$ , 则有

$$Q^T A Z = \begin{bmatrix} T & O \\ O & O \end{bmatrix} \begin{matrix} r \\ m-r \end{matrix}, \quad (5.35)$$

$r \quad n-r$

由此, 得

$$x_{LS} = Z \begin{bmatrix} T^{-1} c \\ 0 \end{bmatrix},$$

式中:  $c$  为由  $Q^T b$  前  $r$  个分量构成的  $r$  维向量.



### §5.3.2 奇异值分解法



43/96

设  $\mathbf{A} \in \mathbb{R}^{m \times n}$  ( $m > n$ ) 的奇异值分解为

$$\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T, \quad \mathbf{\Sigma} = \begin{bmatrix} \mathbf{\Sigma}_r & \mathbf{O} \\ \mathbf{O} & \mathbf{O} \end{bmatrix} \begin{matrix} r \\ m - r \end{matrix}, \quad (5.36)$$

$r \quad n - r$

式中:  $\mathbf{U} = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_m]$  和  $\mathbf{V} = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n]$  为正交矩阵;  $\mathbf{\Sigma}_r = \text{diag}(\sigma_1, \dots, \sigma_r)$ ,  $\sigma_1 \geq \dots \geq \sigma_r > 0$ . 则由定理 5.2 和定理 5.3 可知

$$\mathbf{x}_{\text{LS}} = \mathbf{A}^\dagger \mathbf{b} = \mathbf{V} \begin{bmatrix} \mathbf{\Sigma}_r^{-1} & \mathbf{O} \\ \mathbf{O} & \mathbf{O} \end{bmatrix} \mathbf{U}^T = \sum_{i=1}^r \frac{\mathbf{u}_i^T \mathbf{b}}{\sigma_i} \mathbf{v}_i. \quad (5.37)$$

因此, 一旦求出分解式 (5.36), 就可由式 (5.37) 容易地求出最小二乘问题 (5.1) 的极小范数解  $\mathbf{x}_{\text{LS}}$ .





例 5.3 用 MATLAB 系统自带的奇异值分解函数 `svd.m` 求解超定方程组  $\mathbf{Ax} = \mathbf{b}$ , 其中

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 & 4 \\ 1 & 4 & 5 & 6 \\ 1 & 5 & 6 & 7 \\ 1 & 8 & 9 & 10 \\ 1 & 11 & 12 & 13 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 11 \\ 13 \\ 15 \\ 18 \\ 20 \end{bmatrix}.$$

解 编制 MATLAB 程序, 并存成文件名 `ex53.m`:

%例5.3 ex53.m

```
A=[1 2 3 4; 1 4 5 6; 1 5 6 7; 1 8 9 10; 1 11 12 13];
```

```
b=[11 13 15 18 20]';
```

```
[m,n]=size(A);
```

```
[U,S,V]=svd(A);
```



Back

Close



45/96

```
% x=(V*pinv(S)*U')*b;
for i=1:n
    if abs(S(i,i))<1.0e-6
        r=i-1; break;
    end
end    %r=rank(S);
x=zeros(n,1);
for i=1:r
    x=x+(U(:,i)')*b/S(i,i))*V(:,i);
end
x
fval=norm(A*x-b)
```

然后在命令窗口输入 ex53 即可得计算结果.



Back

Close

观察到求出的最小二乘解与例 5.2 不一样. 原因是本例求出的是极小范数解, 而例 5.2 只是一个基解. 但它们对应的最优值是相同的.



46/96



Back

Close

## §5.4 求解最小二乘问题的迭代方法

对于某些大型稀疏的最小二乘问题, 前面介绍的直接解法不一定有效. 此时, 迭代法应该是最好的选择. 本节讨论大型稀疏最小二乘问题

$$\|Ax - b\|_2 = \min_{z \in \mathbb{R}^n} \|Az - b\|_2 \quad (5.38)$$

解的迭代算法, 包括矩阵分裂迭代法和 Krylov 子空间迭代法. 本节假定矩阵  $A$  是  $m \times n$  ( $m \geq n$ ) 阶的列满秩实矩阵,  $b$  是  $m$  维实向量, 即  $A \in \mathbb{R}_n^{m \times n}$ ,  $b \in \mathbb{R}^m$ . 于是, 最小二乘问题 (5.38) 有唯一的最小二乘解  $x_{LS}$ . 这里所考虑的迭代算法基于最小二乘问题的法方程

$$A^T Ax = A^T b, \quad (5.39)$$



或基于其 KKT 方程

$$\begin{bmatrix} \mathbf{I}_m & \mathbf{A} \\ \mathbf{A}^T & \mathbf{O} \end{bmatrix} \begin{bmatrix} \mathbf{r} \\ \mathbf{x} \end{bmatrix} = \begin{bmatrix} \mathbf{b} \\ \mathbf{0} \end{bmatrix}. \quad (5.40)$$

### §5.4.1 基于法方程的矩阵分裂迭代法

由于  $\mathbf{A} \in \mathbb{R}^{m \times n}$  是列满秩的, 因此, 原则上讲, 任何适用于求解对称正定方程组的迭代方法都可用于求解最小二乘问题的法方程 (5.39), 从而得到相应的求解最小二乘问题 (5.38) 的迭代算法.

为了方便起见, 将  $\mathbf{A}$  按列分块为  $\mathbf{A} = [\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n]$ , 并记  $d_i = \mathbf{a}_i^T \mathbf{a}_i$ ,  $i = 1, 2, \dots, n$ .  $\mathbf{D} = \text{diag}(d_1, d_2, \dots, d_n)$ . 于是可将矩阵  $\mathbf{A}^T \mathbf{A}$  分裂为

$$\mathbf{A}^T \mathbf{A} = \mathbf{D} - \mathbf{L} - \mathbf{L}^T, \quad (5.41)$$

这里  $-\mathbf{L}$  是其严格下三角部分.







## 1. Jacobi 迭代法

在分裂  $A^T A = M - N$  中, 令  $M = D$ ,  $N = L + L^T$ , 则得到 Jacobi 迭代格式为

$$\mathbf{x}^{(k+1)} = D^{-1}[(D - A^T A)\mathbf{x}^{(k)} + A^T \mathbf{b}], \quad k = 0, 1, \dots, \quad (5.42)$$

或等价地, 有

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + D^{-1} A^T (\mathbf{b} - A \mathbf{x}^{(k)}), \quad k = 0, 1, \dots. \quad (5.43)$$

显然, Jacobi 迭代法的迭代矩阵为  $G_J = I - D^{-1} A^T A$ , 且迭代过程不需要显式地计算  $A^T A$ .

在实际计算中, 可以对每个分量进行迭代. 令  $\mathbf{r}^{(k)} = \mathbf{b} - A \mathbf{x}^{(k)}$ , 执行下面的算法:

$$\mathbf{r}^{(0)} = \mathbf{b} - A \mathbf{x}^{(0)}; \quad k = 0;$$

$$\text{while } (\|\mathbf{r}^{(k)}\|_2 / \|\mathbf{r}^{(0)}\|_2 \leq \varepsilon)$$



Back

Close



50/96

**for**  $i = 1 : n$

$$d_i = \mathbf{a}_i^T \mathbf{a}_i;$$

$$x_i^{(k+1)} = x_i^{(k)} + \mathbf{a}_i^T \mathbf{r}^{(k)} / d_i;$$

**end**

$$\mathbf{r}^{(k+1)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(k+1)};$$

$$k = k + 1;$$

**end**

Jacobi 迭代法的 MATLAB 程序如下:

```
function [x,fval,k,time]=nls_jacobi(A,b,x,tol,max_it)
%Jacobi算法求解法方程A'Ax=A'b
tic; n=size(A,2); r=b-A*x;
d=zeros(n,1); nr=norm(A'*r); k=0;
for i=1:n
```



Back

Close



```
        d(i)=A(:,i) '*A(:,i);  
end  
while (k<=max_it)  
    k=k+1;  
    for i=1:n  
        x(i)=x(i)+A(:,i) '*r/d(i);  
    end  
    r=b-A*x; s=A'*r;  
    if (norm(s)/nr<tol)  
        break;  
    end  
end  
fval=norm(r); time=toc;
```





例 5.4 利用 Jacobi 迭代法的 MATLAB 程序, 计算最小二乘问题  $\min \|\mathbf{b} - \mathbf{A}\mathbf{x}\|_2$  的极小解, 其中

$$\mathbf{A} = \begin{bmatrix} 4 & -1 & 0 & 0 \\ 1 & 4 & -1 & 0 \\ 0 & 1 & 4 & -1 \\ 0 & 0 & 1 & 4 \\ 1 & 3 & 2 & 1 \\ 0 & 2 & 0 & 3 \\ 8 & 2 & 3 & 1 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 9 \\ 12 \\ 11 \\ 13 \\ 17 \\ 15 \\ 19 \end{bmatrix}.$$

取初始点为零向量, 容许误差为  $10^{-10}$ .

解 编写 MATLAB 脚本文件 ex54.m, 并在命令窗口运行之, 迭代 708 次, 得到极小解和极小值

$$\mathbf{x}^* = (1.1019, 2.7905, 1.9907, 2.6509)^T, \quad \|\mathbf{b} - \mathbf{A}\mathbf{x}^*\|_2 = 9.2279.$$



Back

Close



## 2. Gauss-Seidel 迭代法

在分裂  $A^T A = M - N$  中, 令  $M = D - L$ ,  $N = L^T$ , 则得到 Gauss-Seidel 迭代格式为

$$\mathbf{x}^{(k+1)} = D^{-1} [L\mathbf{x}^{(k+1)} + (D - L - A^T A)\mathbf{x}^{(k)} + A^T \mathbf{b}], \quad k = 0, 1, \dots, \quad (5.44)$$

或等价地, 有

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + (D - L)^{-1} A^T (\mathbf{b} - A\mathbf{x}^{(k)}), \quad k = 0, 1, \dots. \quad (5.45)$$

不难发现, Gauss-Seidel 迭代法的迭代矩阵为  $G_S = (D - L)^{-1}(D - L - A^T A) = (D - L)^{-1}L^T$ , 并需要显式地计算  $A^T A$ .

为了避免  $A^T A$  的显式计算, 可在第  $k$  步引入辅助变量  $z_1 =$



Back

Close



$\mathbf{x}^{(k)}$ ,  $\mathbf{r}_1 = \mathbf{r}^{(k)}$ , 则式 (5.44) 可化为

$$\begin{aligned}\mathbf{x}^{(k+1)} &= \mathbf{D}^{-1}[\mathbf{L}\mathbf{x}^{(k+1)} + \mathbf{A}^T\mathbf{b} + (\mathbf{D} - \mathbf{L} - \mathbf{A}^T\mathbf{A})\mathbf{x}^{(k)}] \\ &= \mathbf{x}^{(k)} + \mathbf{D}^{-1}[\mathbf{L}(\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}) + \mathbf{A}^T(\mathbf{b} - \mathbf{A}\mathbf{x}^{(k)})] \\ &= \mathbf{z}_1 + \mathbf{D}^{-1}[\mathbf{L}(\mathbf{x}^{(k+1)} - \mathbf{z}_1) + \mathbf{A}^T\mathbf{r}_1].\end{aligned}\quad (5.46)$$

详细的算法步骤如下:

```
 $\mathbf{r}^{(0)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(0)}; k = 0;$   
while ( $\|\mathbf{r}^{(k)}\|_2 / \|\mathbf{r}^{(0)}\|_2 \leq \varepsilon$ )  
     $\mathbf{r}_1 = \mathbf{r}^{(k)}; \mathbf{z}_1 = \mathbf{x}^{(k)};$   
    for  $i = 1 : n$   
         $d_i = \mathbf{a}_i^T \mathbf{a}_i; \alpha_i = \mathbf{a}_i^T \mathbf{r}_i / d_i;$   
         $\mathbf{z}_{i+1} = \mathbf{z}_i + \alpha_i \mathbf{e}^{(i)};$   
         $\mathbf{r}_{i+1} = \mathbf{r}_i - \alpha_i \mathbf{a}_i;$ 
```



Back

Close



**end**

$$\mathbf{x}^{(k+1)} = \mathbf{z}_{n+1};$$

$$\mathbf{r}^{(k+1)} = \mathbf{r}_{n+1};$$

$$k = k + 1;$$

**end**

以上算法不再需要显式地计算  $\mathbf{A}^T \mathbf{A}$ .

Gauss-Seidel 迭代法的 MATLAB 程序如下:

```
function [x,fval,k,time]=nls_seidel(A,b,x,tol,max_it)
%Gauss--Seidel算法求解法方程A'Ax=A'b
tic;n=size(A,2);
r=b-A*x;d=zeros(n,1);
nr=norm(A'*r);k=0;E=eye(n);
for (i=1:n
```



Back

Close



56/96

```
d(i)=A(:,i) '*A(:,i);  
end  
D=diag(d); Z=[x]; R=[r];  
while (k<=max_it)  
    k=k+1;  
    for i=1:n  
        delta=A(:,i) '*R(:,i)/d(i);  
        z=Z(:,i)+delta*E(:,i);  
        r=R(:,i)-delta*A(:,i);  
        Z=[Z,z]; R=[R,r];  
    end  
    x=Z(:,n+1); r=b-A*x;  
    Z=[x]; R=[r];
```



Back

Close





```
    if(norm(A'*r)/nr<tol),break;end  
end  
fval=norm(r); time=toc;
```

**例 5.5** 利用 Gauss-Seidel 迭代法的 MATLAB 程序, 计算例 5.4 中的最小二乘问题  $\min \|\mathbf{b} - \mathbf{A}\mathbf{x}\|_2$  的极小解. 取初始点为零向量, 容许误差为  $10^{-10}$ .

**解** 编写 MATLAB 脚本文件 ex55.m, 并在命令窗口运行之, 迭代 19 次, 得到极小解和极小值

$$\mathbf{x}^* = (1.1019, 2.7905, 1.9907, 2.6509)^T,$$

$$\|\mathbf{b} - \mathbf{A}\mathbf{x}^*\|_2 = 9.2279.$$



Back

Close



### 3. SOR 迭代法

在分裂  $\mathbf{A}^T \mathbf{A} = \mathbf{M} - \mathbf{N}$  中, 令

$$\mathbf{M} = \frac{1}{\omega}(\mathbf{D} - \omega \mathbf{L}), \quad \mathbf{N} = \frac{1}{\omega}[(1 - \omega)\mathbf{D} + \omega \mathbf{L}^T], \quad \omega \neq 0,$$

则得到 SOR 迭代格式为

$$\mathbf{x}^{(k+1)} = \omega \mathbf{D}^{-1}(\mathbf{L} \mathbf{x}^{(k+1)} + \mathbf{L}^T \mathbf{x}^{(k)} + \mathbf{A}^T \mathbf{b}) + (1 - \omega) \mathbf{x}^{(k)}, \quad k = 0, 1, \dots, \quad (5.47)$$

式中:  $\omega$  为松弛因子. 或等价地, 有

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \omega \mathbf{D}^{-1}[\mathbf{L}(\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}) + \mathbf{A}^T(\mathbf{b} - \mathbf{A} \mathbf{x}^{(k)})], \quad k = 0, 1, \dots. \quad (5.48)$$

上述迭代法也需要显式地计算  $\mathbf{A}^T \mathbf{A}$ , 其迭代矩阵为  $\mathbf{G}_\omega = (\mathbf{D} - \omega \mathbf{L})^{-1}[(1 - \omega)\mathbf{D} + \omega \mathbf{L}^T]$ .

同样, 为了避免显式计算  $\mathbf{A}^T \mathbf{A}$ , 可在第  $k$  步引入辅助变量





$\mathbf{z}_1 = \mathbf{x}^{(k)}$ ,  $\mathbf{r}_1 = \mathbf{r}^{(k)}$ , 则式 (5.47) 可化为

$$\begin{aligned}\mathbf{x}^{(k+1)} &= \mathbf{x}^{(k)} + \omega \mathbf{D}^{-1} [\mathbf{L}(\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}) + \mathbf{A}^T(\mathbf{b} - \mathbf{A}\mathbf{x}^{(k)})] \\ &= \mathbf{z}_1 + \omega \mathbf{D}^{-1} [\mathbf{L}(\mathbf{x}^{(k+1)} - \mathbf{z}_1) + \mathbf{A}^T \mathbf{r}_1].\end{aligned}\quad (5.49)$$

详细的算法步骤如下:

```
 $\mathbf{r}^{(0)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(0)}; k = 0;$   
while ( $\|\mathbf{r}^{(k)}\|_2 / \|\mathbf{r}^{(0)}\|_2 \leq \varepsilon$ )  
     $\mathbf{r}_1 = \mathbf{r}^{(k)}; \mathbf{z}_1 = \mathbf{x}^{(k)};$   
    for  $i = 1 : n$   
         $d_i = \mathbf{a}_i^T \mathbf{a}_i; \alpha_i = \omega \mathbf{a}_i^T \mathbf{r}_i / d_i;$   
         $\mathbf{z}_{i+1} = \mathbf{z}_i + \alpha_i \mathbf{e}^{(i)};$   
         $\mathbf{r}_{i+1} = \mathbf{r}_i - \alpha_i \mathbf{a}_i;$   
    end
```



Back

Close



$$\boldsymbol{x}^{(k+1)} = \boldsymbol{z}_{n+1}, \boldsymbol{r}^{(k+1)} = \boldsymbol{r}_{n+1};$$

$$k = k + 1;$$

end

注 5.4 关于上述三种迭代法的收敛性定理, 跟第 3 章中求解线性方程组的 Jacobi 迭代法、Gauss-Seidel 迭代法和 SOR 迭代法相类似, 只需将此处的  $\boldsymbol{A}^T \boldsymbol{A}$  和  $\boldsymbol{A}^T \boldsymbol{b}$  分别视作方程  $\boldsymbol{A} \boldsymbol{x} = \boldsymbol{b}$  中的  $\boldsymbol{A}$  和  $\boldsymbol{b}$  即可得到类似的结论.

SOR 迭代法的 MATLAB 程序如下:

```
function [x,fval,k,time]=nls_sor(A,b,w,x,tol,max_it)
%SOR迭代法求解法方程A'Ax=A'b
tic;n=size(A,2);r=b-A*x;d=zeros(n,1);
nr=norm(A'*r);k=0; E=eye(n);
for(i=1:n),d(i)=A(:,i)'*A(:,i);end
```



Back

Close



```
D=diag(d);Z=[x];R=[r];
while (k<=max_it)
    k=k+1;
    for i=1:n
        delta=w*A(:,i) '*R(:,i)/d(i);
        z=Z(:,i)+delta*E(:,i);
        r=R(:,i)-delta*A(:,i);
        Z=[Z,z]; R=[R,r];
    end
    x=Z(:,n+1);r=b-A*x;Z=[x];R=[r];
    if(norm(A'*r)/nr<tol),break;end
end
fval=norm(r);time=toc;
```





62/96

例 5.6 利用 SOR 迭代法的 MATLAB 程序, 计算最小二乘问题  $\min \|b - Ax\|_2$  的极小解, 其中

$$A = \begin{bmatrix} 1 & 23.73 & 5.49 & 1.21 \\ 1 & 22.34 & 4.32 & 1.35 \\ 1 & 28.84 & 5.04 & 1.92 \\ 1 & 27.67 & 4.72 & 1.49 \\ 1 & 20.83 & 5.35 & 1.56 \\ 1 & 22.27 & 4.27 & 1.50 \\ 1 & 27.57 & 5.25 & 1.85 \\ 1 & 28.01 & 4.62 & 1.51 \end{bmatrix}, \quad x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix}, \quad b = \begin{bmatrix} 15.02 \\ 12.62 \\ 14.86 \\ 13.98 \\ 15.91 \\ 12.47 \\ 15.80 \\ 14.32 \end{bmatrix}.$$

取初始点为零向量, 松弛因子  $\omega = 1.06$ , 容许误差为  $10^{-6}$ .

解 编写 MATLAB 脚本文件 ex56.m, 并在命令窗口运行之, 迭



Back

Close

代 1134 次, 得到极小解和极小值

$$\mathbf{x}^* = (-0.0054, 0.0169, 2.4468, 1.2954)^T,$$

$$\|\mathbf{b} - \mathbf{A}\mathbf{x}^*\|_2 = 0.9959.$$

### §5.4.2 基于法方程的共轭梯度法

由于  $\mathbf{A} \in \mathbb{R}^{m \times n}$  ( $m \geq n$ ) 列满秩, 故最小二乘问题的法方程 (5.39) 是对称正定方程组. 因此, 法方程 (5.39) 等价于极小化问题

$$\min f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T (\mathbf{A}^T \mathbf{A}) \mathbf{x} - (\mathbf{A}^T \mathbf{b})^T \mathbf{x}. \quad (5.50)$$

事实上,  $f(\mathbf{x})$  的梯度为

$$\nabla f(\mathbf{x}) = \mathbf{A}^T \mathbf{A} \mathbf{x} - \mathbf{A}^T \mathbf{b},$$

且对任意给定的非零向量  $\mathbf{p}$  和实数  $\alpha$ , 有

$$f(\mathbf{x} + \alpha \mathbf{p}) = f(\mathbf{x}) + \alpha \nabla f(\mathbf{x})^T \mathbf{p} + \frac{1}{2} \alpha^2 \mathbf{p}^T \mathbf{A}^T \mathbf{A} \mathbf{p}.$$





若  $\mathbf{x}^*$  是法方程 (5.39) 的解, 则有  $\nabla f(\mathbf{x}^*) = \mathbf{0}$ . 因此, 对任意非零向量  $\mathbf{p} \in \mathbb{R}^n$ , 有

$$f(\mathbf{x}^* + \alpha \mathbf{p}) \begin{cases} > f(\mathbf{x}^*), & \alpha \neq 0, \\ = f(\mathbf{x}^*), & \alpha = 0. \end{cases}$$

故  $\mathbf{x}^*$  是  $f(\mathbf{x})$  的极小点. 反之, 因  $\mathbf{A}^T \mathbf{A}$  对称正定, 可知  $f(\mathbf{x})$  在  $\mathbb{R}^n$  中有唯一的极小点. 若  $\mathbf{x}^*$  是  $f(\mathbf{x})$  的极小点, 则必有  $\nabla f(\mathbf{x}^*) = \mathbf{A}^T \mathbf{A} \mathbf{x}^* - \mathbf{A}^T \mathbf{b} = \mathbf{0}$ , 即  $\mathbf{x}^*$  是法方程 (5.39) 的解.

类似于用共轭梯度法求解对称正定方程组  $\mathbf{A} \mathbf{x} = \mathbf{b}$  的思想, 设  $\mathbf{x}^{(0)} \in \mathbb{R}^n$  是任意给定的一个初始向量, 对于  $k = 0, 1, 2, \dots$ , 从  $\mathbf{x}^{(k)}$  出发, 沿方向  $\mathbf{p}^{(k)}$  求函数  $f(\mathbf{x})$  在直线  $\mathbf{x} = \mathbf{x}^{(k)} + \alpha \mathbf{p}^{(k)}$  上的极小点, 得

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)}, \quad \mathbf{r}^{(k)} = \mathbf{b} - \mathbf{A} \mathbf{x}^{(k)}, \quad (5.51)$$







$$\mathbf{s}^{(k)} = \mathbf{A}^T \mathbf{r}^{(k)}, \quad \alpha_k = \frac{(\mathbf{s}^{(k)}, \mathbf{p}^{(k)})}{(\mathbf{p}^{(k)}, \mathbf{A}^T \mathbf{A} \mathbf{p}^{(k)})}, \quad (5.52)$$

称向量  $\mathbf{p}^{(k)}$  为搜索方向. 若向量组  $\mathbf{p}^{(0)}, \mathbf{p}^{(1)}, \dots, \mathbf{p}^{(k-1)}$  满足

$$(\mathbf{p}^{(i)}, \mathbf{A}^T \mathbf{A} \mathbf{p}^{(j)}) = 0, \quad i \neq j, \quad (5.53)$$

且  $\mathbf{p}^{(k)} \neq \mathbf{0}$ ,  $k = 0, 1, \dots, n-1$ , 则称向量组  $\{\mathbf{p}^{(k)}\}$  为  $\mathbb{R}^n$  中关于  $\mathbf{A}^T \mathbf{A}$  的一个共轭向量组, 称迭代法 (5.51) 为共轭方向法. 特别地, 若取  $\mathbf{p}^{(0)} = \mathbf{s}^{(0)}$ ,

$$\mathbf{p}^{(k+1)} = \mathbf{s}^{(k+1)} + \beta_k \mathbf{p}^{(k)}, \quad \beta_k = -\frac{(\mathbf{s}^{(k+1)}, \mathbf{A}^T \mathbf{A} \mathbf{p}^{(k)})}{(\mathbf{p}^{(k)}, \mathbf{A}^T \mathbf{A} \mathbf{p}^{(k)})}, \quad (5.54)$$

则称为共轭梯度法.

由式 (5.51)、式 (5.52) 及式 (5.54) 可知, 若存在  $k \geq 0$ , 使得  $\mathbf{s}^{(k)} = \mathbf{0}$ , 则  $\mathbf{x}^{(k)}$  为最小二乘问题的解, 且有  $\alpha_k = \beta_k = 0$ ,  $\mathbf{s}^{(k+1)} = \mathbf{p}^{(k+1)} = \mathbf{0}$ . 此外, 在上述的共轭梯度法中每次迭代需要计





算 4 次矩阵与向量的乘法, 因此有必要对  $\alpha_k$  和  $\beta_k$  的计算公式进行化简.

**定理 5.6** 在共轭梯度法 (5.51)、(5.52) 和 (5.54) 中, 若  $k > 0$ ,  $\mathbf{s}^{(k)} \neq \mathbf{0}$ , 则有

$$\begin{cases} (\mathbf{s}^{(k)}, \mathbf{s}^{(i)}) = (\mathbf{s}^{(k)}, \mathbf{p}^{(i)}) = (\mathbf{p}^{(k)}, \mathbf{A}^T \mathbf{A} \mathbf{p}^{(i)}) = 0, & 0 \leq i < k, \\ (\mathbf{p}^{(k)}, \mathbf{s}^{(i)}) = (\mathbf{s}^{(k)}, \mathbf{s}^{(k)}), & 0 \leq i \leq k. \end{cases} \quad (5.55)$$

证明 由定理的条件, 有  $\alpha_i \neq 0, i = 0, 1, \dots, k$ . 根据迭代公式, 得

$$\begin{cases} \mathbf{s}^{(k+1)} = \mathbf{A}^T \mathbf{r}^{(k+1)} = \mathbf{A}^T (\mathbf{b} - \mathbf{A} \mathbf{x}^{(k+1)}) = \mathbf{s}^{(k)} - \alpha_k \mathbf{A}^T \mathbf{A} \mathbf{p}^{(k)}, \\ \mathbf{p}^{(k+1)} = \mathbf{s}^{(k+1)} + \beta_k \mathbf{p}^{(k)} = \mathbf{s}^{(k)} - \alpha_k \mathbf{A}^T \mathbf{A} \mathbf{p}^{(k)} + \beta_k \mathbf{p}^{(k)}. \end{cases} \quad (5.56)$$



Back

Close



下面用归纳法证明定理的结论. 注意到

$$\begin{aligned}(\mathbf{s}^{(1)}, \mathbf{s}^{(0)}) &= (\mathbf{s}^{(1)}, \mathbf{p}^{(0)}) = (\mathbf{s}^{(0)}, \mathbf{p}^{(0)}) - \alpha_0(\mathbf{A}^T \mathbf{A} \mathbf{p}^{(0)}, \mathbf{p}^{(0)}) = 0, \\(\mathbf{p}^{(1)}, \mathbf{A}^T \mathbf{A} \mathbf{p}^{(0)}) &= (\mathbf{s}^{(1)}, \mathbf{A}^T \mathbf{A} \mathbf{p}^{(0)}) + \beta_0(\mathbf{p}^{(0)}, \mathbf{A}^T \mathbf{A} \mathbf{p}^{(0)}) = 0, \\(\mathbf{p}^{(1)}, \mathbf{s}^{(0)}) &= (\mathbf{p}^{(1)}, \mathbf{s}^{(1)} + \alpha_0 \mathbf{A}^T \mathbf{A} \mathbf{p}^{(0)}) = (\mathbf{p}^{(1)}, \mathbf{s}^{(1)}) \\&= (\mathbf{s}^{(1)} + \beta_0 \mathbf{p}^{(0)}, \mathbf{s}^{(1)}) = (\mathbf{s}^{(1)}, \mathbf{s}^{(1)}),\end{aligned}$$

即  $k = 1$  时结论成立. 现假定一直到  $k (> 1)$  时, 结论成立. 则

$$\begin{aligned}(\mathbf{s}^{(k+1)}, \mathbf{p}^{(k)}) &= (\mathbf{s}^{(k)}, \mathbf{p}^{(k)}) - \alpha_k(\mathbf{A}^T \mathbf{A} \mathbf{p}^{(k)}, \mathbf{p}^{(k)}) = 0, \\(\mathbf{p}^{(k+1)}, \mathbf{A}^T \mathbf{A} \mathbf{p}^{(k)}) &= (\mathbf{s}^{(k+1)}, \mathbf{A}^T \mathbf{A} \mathbf{p}^{(k)}) + \beta_k(\mathbf{p}^{(k)}, \mathbf{A}^T \mathbf{A} \mathbf{p}^{(k)}) = 0, \\(\mathbf{s}^{(k+1)}, \mathbf{s}^{(k)}) &= (\mathbf{s}^{(k+1)}, \mathbf{p}^{(k)} - \beta_{k-1} \mathbf{p}^{(k-1)}) = -\beta_{k-1}(\mathbf{s}^{(k+1)}, \mathbf{p}^{(k-1)}) \\&= -\beta_{k-1}(\mathbf{s}^{(k)} - \alpha_k \mathbf{A}^T \mathbf{A} \mathbf{p}^{(k)}, \mathbf{p}^{(k-1)}) = 0.\end{aligned}$$





当  $i < k$  时, 有

$$\begin{aligned}
 (\mathbf{s}^{(k+1)}, \mathbf{p}^{(i)}) &= (\mathbf{s}^{(k)}, \mathbf{p}^{(i)}) - \alpha_k (\mathbf{A}^T \mathbf{A} \mathbf{p}^{(k)}, \mathbf{p}^{(i)}) = 0, \\
 (\mathbf{p}^{(k+1)}, \mathbf{A}^T \mathbf{A} \mathbf{p}^{(i)}) &= (\mathbf{s}^{(k+1)}, \mathbf{A}^T \mathbf{A} \mathbf{p}^{(i)}) + \beta_k (\mathbf{p}^{(k)}, \mathbf{A}^T \mathbf{A} \mathbf{p}^{(i)}) \\
 &= (\mathbf{s}^{(k+1)}, \mathbf{A}^T \mathbf{A} \mathbf{p}^{(i)}) = (\mathbf{s}^{(k+1)}, (\mathbf{s}^{(i)} - \mathbf{s}^{(i+1)})/\alpha_i) = 0, \\
 (\mathbf{s}^{(k+1)}, \mathbf{s}^{(i)}) &= (\mathbf{s}^{(k+1)}, \mathbf{p}^{(i)} - \beta_{i-1} \mathbf{p}^{(i-1)}) = -\beta_{i-1} (\mathbf{s}^{(k+1)}, \mathbf{p}^{(i-1)}) \\
 &= -\beta_{i-1} (\mathbf{s}^{(k)} - \alpha_k \mathbf{A}^T \mathbf{A} \mathbf{p}^{(k)}, \mathbf{p}^{(i-1)}) = 0.
 \end{aligned}$$

又当  $i \leq k+1$  时, 有

$$\begin{aligned}
 (\mathbf{p}^{(k+1)}, \mathbf{s}^{(i)}) &= \left( \mathbf{p}^{(k+1)}, \mathbf{s}^{(k+1)} + \sum_{l=i}^k \alpha_l \mathbf{A}^T \mathbf{A} \mathbf{p}^{(l)} \right) = (\mathbf{p}^{(k+1)}, \mathbf{s}^{(k+1)}) \\
 &= (\mathbf{s}^{(k+1)} + \beta_k \mathbf{p}^{(k)}, \mathbf{s}^{(k+1)}) = (\mathbf{s}^{(k+1)}, \mathbf{s}^{(k+1)}).
 \end{aligned}$$

由归纳法原理, 定理得证.

□





利用式 (5.56) 的第 1 式, 当  $\alpha_k \neq 0$  时, 有

$$\mathbf{A}^T \mathbf{A} \mathbf{p}^{(k)} = \frac{\mathbf{s}^{(k)} - \mathbf{s}^{(k+1)}}{\alpha_k},$$

代入  $\alpha_k$  和  $\beta_k$  的表达式并化简, 得

$$\alpha_k = \frac{\|\mathbf{s}^{(k)}\|_2^2}{\|\mathbf{A} \mathbf{p}^{(k)}\|_2^2}, \quad \beta_k = \frac{\|\mathbf{s}^{(k+1)}\|_2^2}{\|\mathbf{s}^{(k)}\|_2^2}. \quad (5.57)$$

**算法 5.4 (CGLS)** 给定矩阵  $\mathbf{A} \in \mathbb{R}_n^{m \times n}$ , 向量  $\mathbf{b} \in \mathbb{R}^m$  和容许误差  $\varepsilon > 0$ . 本算法计算向量  $\mathbf{x}^{(k)}$ , 使得  $\|\mathbf{s}^{(k)}\|_2 / \|\mathbf{s}^{(0)}\|_2 \leq \varepsilon$ , 其中  $\mathbf{r}^{(k)} = \mathbf{b} - \mathbf{A} \mathbf{x}^{(k)}$ ,  $\mathbf{s}^{(k)} = \mathbf{A}^T \mathbf{r}^{(k)}$ .

取初始向量  $\mathbf{x}^{(0)} \in \mathbb{R}^n$ ;

计算  $\mathbf{r}^{(0)} = \mathbf{b} - \mathbf{A} \mathbf{x}^{(0)}$ ;  $\mathbf{p}^{(0)} = \mathbf{s}^{(0)} = \mathbf{A}^T \mathbf{r}^{(0)}$ ;  $\gamma_0 = \|\mathbf{s}^{(0)}\|_2^2$ ;

$k = 0$ ;

**while** ( $\|\mathbf{s}^{(k)}\|_2 / \|\mathbf{s}^{(0)}\|_2 \leq \varepsilon$ )



Back

Close



$$\mathbf{q}^{(k)} = \mathbf{A}\mathbf{p}^{(k)}; \alpha_k = \gamma_k / \|\mathbf{q}^{(k)}\|_2^2;$$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)};$$

$$\mathbf{r}^{(k+1)} = \mathbf{r}^{(k)} - \alpha_k \mathbf{q}^{(k)}; \mathbf{s}^{(k+1)} = \mathbf{A}^T \mathbf{r}^{(k+1)};$$

$$\gamma_{k+1} = \|\mathbf{s}^{(k+1)}\|_2^2; \beta_k = \gamma_{k+1} / \gamma_k;$$

$$\mathbf{p}^{(k+1)} = \mathbf{s}^{(k+1)} + \beta_k \mathbf{p}^{(k)};$$

$$k = k + 1;$$

end

算法 5.4 的有限终止性、收敛性和收敛速度的分析与求解对称正定方程组  $\mathbf{A}\mathbf{x} = \mathbf{b}$  的共轭梯度法相类似, 此处不再赘述. 此外, 不难发现算法 5.4 的每次迭代已经减少到只需计算两次矩阵与向量的乘法.

算法 5.4 的 MATLAB 程序如下:



Back

Close



71/96

```
function [x,fval,k,time]=nls_cg(A,b,x,tol,max_it)
%CG算法求解法方程A'Ax=A'b
tic; n=size(A,2); r=b-A*x;
s=A'*r; p=s; gama=s'*s;
nr=norm(s); k=0;
while (k<=max_it)
    k=k+1; q=A*p; alpha=gama/(q'*q);
    x=x+alpha*p; r=r-alpha*q; s=A'*r;
    if (norm(s)/nr<tol), break; end
    gama1=s'*s; beta=gama1/gama;
    p=s+beta*p; gama=gama1;
end
fval=norm(r); time=toc;
```



Back

Close



**例 5.7** 利用 CG 迭代法的 MATLAB 程序, 计算例 5.6 中的最小二乘问题  $\min \|\mathbf{b} - \mathbf{A}\mathbf{x}\|_2$  的极小解, 并与 SOR 迭代法进行比较 (取初始点为零向量, 松弛因子  $\omega = 1.06$ , 容许误差  $\varepsilon = 10^{-10}$ ).

**解** 编写 MATLAB 脚本文件 ex57.m, 并在命令窗口运行之, 得到数值结果如表 5.1 所示.

表 5.1 CG 法与 SOR 法的数值结果

算法	迭代次数	CPU时间	极小解	极小值
SOR	2889	0.2275	$(-0.0309, 0.0171, 2.4509, 1.2954)^T$	0.9959
CG	5	0.0031	$(-0.0309, 0.0171, 2.4509, 1.2954)^T$	0.9959

### §5.4.3 基于 KKT 方程的 SOR 类迭代法

由于 SOR 迭代法要求方程组系数矩阵的对角元均不为零, 故不能直接将 SOR 迭代法用于求解最小二乘问题 (5.38) 的 KKT 方







程 (5.40), 但可以通过适当的等价变形使之满足 SOR 迭代法的条件.

事实上, KKT 方程 (5.40) 等价于

$$\begin{bmatrix} \mathbf{A} & \mathbf{I}_m \\ \mathbf{O} & \mathbf{A}^T \end{bmatrix} \begin{bmatrix} \mathbf{x} \\ \mathbf{r} \end{bmatrix} = \begin{bmatrix} \mathbf{b} \\ \mathbf{0} \end{bmatrix}. \quad (5.58)$$

由于  $\mathbf{A} \in \mathbb{R}_n^{m \times n}$ , 不失一般性, 可将  $\mathbf{A}$  进行如下分块:

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_1 \\ \mathbf{A}_2 \end{bmatrix} \begin{matrix} n \\ m - n \end{matrix}, \quad (5.59)$$

式中:  $\mathbf{A}_1 \in \mathbb{R}^{n \times n}$  为非奇异阵. 再将  $\mathbf{r}$  和  $\mathbf{b}$  进行相应的分块, 即

$$\mathbf{r} = \begin{bmatrix} \mathbf{v} \\ \mathbf{w} \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} \mathbf{b}_1 \\ \mathbf{b}_2 \end{bmatrix},$$



Back

Close

式中:  $\boldsymbol{v}, \boldsymbol{b}_1 \in \mathbb{R}^n$ ,  $\boldsymbol{w}, \boldsymbol{b}_2 \in \mathbb{R}^{m-n}$ . 则式 (5.58) 变成

$$\begin{bmatrix} \boldsymbol{A}_1 & \boldsymbol{I}_n & \boldsymbol{O} \\ \boldsymbol{A}_2 & \boldsymbol{O} & \boldsymbol{I}_{m-n} \\ \boldsymbol{O} & \boldsymbol{A}_1^{\mathrm{T}} & \boldsymbol{A}_2^{\mathrm{T}} \end{bmatrix} \begin{bmatrix} \boldsymbol{x} \\ \boldsymbol{v} \\ \boldsymbol{w} \end{bmatrix} = \begin{bmatrix} \boldsymbol{b}_1 \\ \boldsymbol{b}_2 \\ \boldsymbol{0} \end{bmatrix}. \quad (5.60)$$

式 (5.60) 可进一步等价变形为

$$\begin{bmatrix} \boldsymbol{A}_1 & \boldsymbol{O} & \boldsymbol{I}_n \\ \boldsymbol{A}_2 & \boldsymbol{I}_{m-n} & \boldsymbol{O} \\ \boldsymbol{O} & \boldsymbol{A}_2^{\mathrm{T}} & \boldsymbol{A}_1^{\mathrm{T}} \end{bmatrix} \begin{bmatrix} \boldsymbol{x} \\ \boldsymbol{w} \\ \boldsymbol{v} \end{bmatrix} = \begin{bmatrix} \boldsymbol{b}_1 \\ \boldsymbol{b}_2 \\ \boldsymbol{0} \end{bmatrix}. \quad (5.61)$$

记

$$\boldsymbol{B} = \begin{bmatrix} \boldsymbol{A}_1 & \boldsymbol{O} & \boldsymbol{I}_n \\ \boldsymbol{A}_2 & \boldsymbol{I}_{m-n} & \boldsymbol{O} \\ \boldsymbol{O} & \boldsymbol{A}_2^{\mathrm{T}} & \boldsymbol{A}_1^{\mathrm{T}} \end{bmatrix}, \quad \boldsymbol{y} = \begin{bmatrix} \boldsymbol{x} \\ \boldsymbol{w} \\ \boldsymbol{v} \end{bmatrix}, \quad \boldsymbol{c} = \begin{bmatrix} \boldsymbol{b}_1 \\ \boldsymbol{b}_2 \\ \boldsymbol{0} \end{bmatrix},$$



则方程组 (5.61) 可写成

$$By = c. \quad (5.62)$$

由于  $A_1$  是非奇异的, 不难验证矩阵  $B$  也是非奇异的.

现按照矩阵  $B$  的自然分块, 有

$$D = \begin{bmatrix} A_1 & O & O \\ O & I_{m-n} & O \\ O & O & A_1^T \end{bmatrix}, \quad L = - \begin{bmatrix} O & O & O \\ A_2 & O & O \\ O & A_2^T & O \end{bmatrix}, \quad U = - \begin{bmatrix} O & O & I_n \\ O & O & O \\ O & O & O \end{bmatrix}. \quad (5.63)$$

以及

$$\mathcal{L} = D^{-1}L = \begin{bmatrix} O & O & O \\ -A_2 & O & O \\ O & -A_1^{-T}A_2^T & O \end{bmatrix},$$
$$\mathcal{U} = D^{-1}U = \begin{bmatrix} O & O & -A_1^{-1} \\ O & O & O \\ O & O & O \end{bmatrix}. \quad (5.64)$$





由此, 可得以下结论:

(1) Jacobi 迭代格式为

$$\mathbf{y}^{(k+1)} = \mathcal{G}_J \mathbf{y}^{(k)} + \mathbf{f}_J, \quad (5.65)$$

式中: 迭代矩阵  $\mathcal{G}_J$  和右端向量  $\mathbf{f}_J$  分别为

$$\mathcal{G}_J = \mathcal{L} + \mathcal{U} = \begin{bmatrix} \mathbf{O} & \mathbf{O} & -\mathbf{A}_1^{-1} \\ -\mathbf{A}_2 & \mathbf{O} & \mathbf{O} \\ \mathbf{O} & -(\mathbf{A}_2 \mathbf{A}_1^{-1})^T & \mathbf{O} \end{bmatrix}, \quad \mathbf{f}_J = \mathbf{D}^{-1} \mathbf{c} = \begin{bmatrix} \mathbf{A}_1^{-1} \mathbf{b}_1 \\ \mathbf{b}_2 \\ \mathbf{0} \end{bmatrix}. \quad (5.66)$$

详细的迭代格式为

$$\begin{cases} \mathbf{x}^{(k+1)} = \mathbf{A}_1^{-1} (\mathbf{b}_1 - \mathbf{v}^{(k)}), \\ \mathbf{w}^{(k+1)} = \mathbf{b}_2 - \mathbf{A}_2 \mathbf{x}^{(k)}, \\ \mathbf{v}^{(k+1)} = -\mathbf{A}_1^{-T} \mathbf{A}_2^T \mathbf{w}^{(k)}, \end{cases} \quad k = 0, 1, 2, \dots. \quad (5.67)$$



Back

Close



此外, 若记  $\mathbf{A}_3 = \mathbf{A}_2 \mathbf{A}_1^{-1}$ , 直接计算, 得

$$\begin{aligned} \mathcal{G}_J^3 &= - \begin{bmatrix} \mathbf{A}_1^{-1} \mathbf{A}_3^T \mathbf{A}_2 & \mathbf{O} & \mathbf{O} \\ \mathbf{O} & \mathbf{A}_2 \mathbf{A}_1^{-1} \mathbf{A}_3^T & \mathbf{O} \\ \mathbf{O} & \mathbf{O} & \mathbf{A}_3^T \mathbf{A}_2 \mathbf{A}_1^{-1} \end{bmatrix} \\ &= - \begin{bmatrix} \mathbf{A}_1^{-1} \mathbf{A}_3^T \mathbf{A}_3 \mathbf{A}_1 & \mathbf{O} & \mathbf{O} \\ \mathbf{O} & \mathbf{A}_3 \mathbf{A}_3^T & \mathbf{O} \\ \mathbf{O} & \mathbf{O} & \mathbf{A}_3^T \mathbf{A}_3 \end{bmatrix}. \end{aligned} \quad (5.68)$$

(2) SOR 迭代格式为

$$\mathbf{y}^{(k+1)} = \mathcal{G}_\omega \mathbf{y}^{(k)} + \mathbf{f}_\omega, \quad (5.69)$$

式中: 迭代矩阵  $\mathcal{G}_\omega$  和右端向量  $\mathbf{f}_\omega$  分别为

$$\mathcal{G}_\omega = (\mathbf{I} - \omega \mathcal{L})^{-1} [(1 - \omega) \mathbf{I} + \omega \mathcal{U}], \quad \mathbf{f}_\omega = \omega (\mathbf{I} - \omega \mathcal{L})^{-1} \mathbf{f}_J. \quad (5.70)$$



仍记  $\mathbf{A}_3 = \mathbf{A}_2 \mathbf{A}_1^{-1}$ , 直接计算, 得

$$\begin{aligned}
 \mathcal{G}_\omega &= \begin{bmatrix} \mathbf{I} & \mathbf{O} & \mathbf{O} \\ \omega \mathbf{A}_2 & \mathbf{I} & \mathbf{O} \\ \mathbf{O} & \omega \mathbf{A}_3^T & \mathbf{I} \end{bmatrix}^{-1} \begin{bmatrix} (1-\omega)\mathbf{I} & \mathbf{O} & -\omega \mathbf{A}_1^{-1} \\ \mathbf{O} & (1-\omega)\mathbf{I} & \mathbf{O} \\ \mathbf{O} & \mathbf{O} & (1-\omega)\mathbf{I} \end{bmatrix} \\
 &= \begin{bmatrix} \mathbf{I} & \mathbf{O} & \mathbf{O} \\ -\omega \mathbf{A}_2 & \mathbf{I} & \mathbf{O} \\ \omega^2 \mathbf{A}_3^T \mathbf{A}_2 & -\omega \mathbf{A}_3^T & \mathbf{I} \end{bmatrix} \begin{bmatrix} (1-\omega)\mathbf{I} & \mathbf{O} & -\omega \mathbf{A}_1^{-1} \\ \mathbf{O} & (1-\omega)\mathbf{I} & \mathbf{O} \\ \mathbf{O} & \mathbf{O} & (1-\omega)\mathbf{I} \end{bmatrix} \\
 &= \begin{bmatrix} (1-\omega)\mathbf{I} & \mathbf{O} & -\omega \mathbf{A}_1^{-1} \\ -\omega(1-\omega)\mathbf{A}_2 & (1-\omega)\mathbf{I} & \omega^2 \mathbf{A}_3 \\ \omega(1-\omega)^2 \mathbf{A}_3^T \mathbf{A}_2 & -\omega(1-\omega)\mathbf{A}_3^T & (1-\omega)\mathbf{I} - \omega^3 \mathbf{A}_3^T \mathbf{A}_3 \end{bmatrix} \\
 &:= (1-\omega)\mathbf{I} + \mathcal{K}_\omega,
 \end{aligned}$$



这里

$$\mathcal{K}_\omega = \begin{bmatrix} \mathbf{O} & \mathbf{O} & -\omega \mathbf{A}_1^{-1} \\ -\omega(1-\omega)\mathbf{A}_2 & \mathbf{O} & \omega^2 \mathbf{A}_3 \\ \omega(1-\omega)^2 \mathbf{A}_3^\top \mathbf{A}_2 & -\omega(1-\omega) \mathbf{A}_3^\top & -\omega^3 \mathbf{A}_3^\top \mathbf{A}_3 \end{bmatrix},$$

$$\mathbf{f}_\omega = \omega \begin{bmatrix} \mathbf{I} & \mathbf{O} & \mathbf{O} \\ \omega \mathbf{A}_2 & \mathbf{I} & \mathbf{O} \\ \mathbf{O} & \omega \mathbf{A}_3^\top & \mathbf{I} \end{bmatrix}^{-1} \begin{bmatrix} \mathbf{A}_1^{-1} \mathbf{b}_1 \\ \mathbf{b}_2 \\ \mathbf{0} \end{bmatrix}$$

$$= \omega \begin{bmatrix} \mathbf{I} & \mathbf{O} & \mathbf{O} \\ -\omega \mathbf{A}_2 & \mathbf{I} & \mathbf{O} \\ \omega^2 \mathbf{A}_3^\top \mathbf{A}_2 & -\omega \mathbf{A}_3^\top & \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{A}_1^{-1} \mathbf{b}_1 \\ \mathbf{b}_2 \\ \mathbf{0} \end{bmatrix}$$

$$= \begin{bmatrix} \omega \mathbf{A}_1^{-1} \mathbf{b}_1 \\ \omega(\mathbf{b}_2 - \omega \mathbf{A}_3 \mathbf{b}_1) \\ -\omega^2 \mathbf{A}_3^\top (\mathbf{b}_2 - \omega \mathbf{A}_3 \mathbf{b}_1) \end{bmatrix}.$$



79/96



Back

Close

则详细的 SOR 迭代格式为

$$\begin{cases} \mathbf{x}^{(k+1)} = (1 - \omega)\mathbf{x}^{(k)} + \omega\mathbf{A}_1^{-1}(\mathbf{b}_1 - \mathbf{v}^{(k)}), \\ \mathbf{w}^{(k+1)} = (1 - \omega)\mathbf{w}^{(k)} - \omega(1 - \omega)\mathbf{A}_2\mathbf{x}^{(k)} - \omega^2\mathbf{A}_3(\mathbf{b}_1 - \mathbf{v}^{(k)}) + \omega\mathbf{b}_2, \\ \mathbf{v}^{(k+1)} = (1 - \omega)\mathbf{v}^{(k)} + \omega(1 - \omega)^2\mathbf{A}_3^T\mathbf{A}_2\mathbf{x}^{(k)} - \omega(1 - \omega)\mathbf{A}_3^T\mathbf{w}^{(k)} \\ \quad - \omega^2\mathbf{A}_3^T[\mathbf{b}_2 - \omega\mathbf{A}_3(\mathbf{b}_1 - \mathbf{v}^{(k)})], \quad k = 0, 1, 2, \dots \end{cases} \quad (5.71)$$

特别地, 在上式中取  $\omega = 1$ , 可得 Gauss-Seidel 迭代格式:

$$\begin{cases} \mathbf{x}^{(k+1)} = \mathbf{A}_1^{-1}(\mathbf{b}_1 - \mathbf{v}^{(k)}), \\ \mathbf{w}^{(k+1)} = \mathbf{b}_2 - \mathbf{A}_3(\mathbf{b}_1 - \mathbf{v}^{(k)}), \\ \mathbf{v}^{(k+1)} = -\mathbf{A}_3^T[\mathbf{b}_2 - \mathbf{A}_3(\mathbf{b}_1 - \mathbf{v}^{(k)})], \quad k = 0, 1, 2, \dots \end{cases} \quad (5.72)$$







(3) SSOR 的迭代矩阵  $\mathcal{H}_\omega$  和右端向量  $\mathbf{g}_\omega$  分别为

$$\begin{aligned}\mathcal{H}_\omega &= (\mathbf{I} - \omega\mathcal{U})^{-1}[(1 - \omega)\mathbf{I} + \omega\mathcal{L}](\mathbf{I} - \omega\mathcal{L})^{-1}[(1 - \omega)\mathbf{I} + \omega\mathcal{U}] \\ &= (\mathbf{I} - \omega\mathcal{U})^{-1}(\mathbf{I} - \omega\mathcal{L})^{-1}[(1 - \omega)\mathbf{I} + \omega\mathcal{L}][(1 - \omega)\mathbf{I} + \omega\mathcal{U}],\end{aligned}\tag{5.73}$$

$$\mathbf{g}_\omega = \omega(2 - \omega)(\mathbf{I} - \omega\mathcal{U})^{-1}(\mathbf{I} - \omega\mathcal{L})^{-1}\mathbf{f}_J.\tag{5.74}$$

显然,  $\mathcal{H}_\omega$  相似于

$$\begin{aligned}\hat{\mathcal{H}}_\omega &= (\mathbf{I} - \omega\mathcal{L})^{-1}[(1 - \omega)\mathbf{I} + \omega\mathcal{L}][(1 - \omega)\mathbf{I} + \omega\mathcal{U}](\mathbf{I} - \omega\mathcal{U})^{-1} \\ &= (\mathbf{I} - \omega\mathcal{L})^{-1}[(1 - \omega)\mathbf{I} + \omega\mathcal{L}](\mathbf{I} - \omega\mathcal{U})^{-1}[(1 - \omega)\mathbf{I} + \omega\mathcal{U}] \\ &:= \mathcal{W}(\mathcal{L})\mathcal{W}(\mathcal{U}),\end{aligned}\tag{5.75}$$

这里

$$\mathcal{W}(\mathcal{Z}) = (\mathbf{I} - \omega\mathcal{Z})^{-1}[(1 - \omega)\mathbf{I} + \omega\mathcal{Z}].\tag{5.76}$$



直接计算, 得

$$\mathcal{W}(\mathcal{L}) = \begin{bmatrix} (1-\omega)\mathbf{I} & \mathbf{O} & \mathbf{O} \\ -\omega(2-\omega)\mathbf{A}_2 & (1-\omega)\mathbf{I} & \mathbf{O} \\ \omega^2(2-\omega)\mathbf{A}_3^T\mathbf{A}_2 & -\omega(2-\omega)\mathbf{A}_3^T & (1-\omega)\mathbf{I} \end{bmatrix},$$
$$\mathcal{W}(\mathcal{U}) = \begin{bmatrix} (1-\omega)\mathbf{I} & \mathbf{O} & -\omega(2-\omega)\mathbf{A}_1^{-1} \\ \mathbf{O} & (1-\omega)\mathbf{I} & \mathbf{O} \\ \mathbf{O} & \mathbf{O} & (1-\omega)\mathbf{I} \end{bmatrix}.$$

于是, 有

$$\hat{\mathcal{H}}_\omega = \mathcal{W}(\mathcal{L})\mathcal{W}(\mathcal{U}) = (1-\omega)^2\mathbf{I} + \mathcal{T}_\omega, \quad (5.77)$$

式中:

$$\mathcal{T}_\omega = \begin{bmatrix} \mathbf{O} & \mathbf{O} & -\sigma\mathbf{A}_1^{-1} \\ -\sigma\mathbf{A}_2 & \mathbf{O} & \omega^2(2-\omega^2)\mathbf{A}_3 \\ \omega\sigma\mathbf{A}_3^T\mathbf{A}_2 & -\sigma\mathbf{A}_3^T & -\omega^2(2-\omega)^2\mathbf{A}_3^T\mathbf{A}_3 \end{bmatrix},$$



这里  $\sigma = \omega(1 - \omega)(2 - \omega)$ .

$$\begin{aligned}
 \mathbf{g}_\omega &= \omega(2 - \omega)(\mathbf{I} - \omega\mathcal{U})^{-1}(\mathbf{I} - \omega\mathcal{L})^{-1}\mathbf{f}_J \\
 &= \omega(2 - \omega) \begin{bmatrix} \mathbf{I} & \mathbf{O} & \omega\mathbf{A}_1^{-1} \\ \mathbf{O} & \mathbf{I} & \mathbf{O} \\ \mathbf{O} & \mathbf{O} & \mathbf{I} \end{bmatrix}^{-1} \begin{bmatrix} \mathbf{I} & \mathbf{O} & \mathbf{O} \\ \omega\mathbf{A}_2 & \mathbf{I} & \mathbf{O} \\ \mathbf{O} & \omega\mathbf{A}_3^\top & \mathbf{I} \end{bmatrix}^{-1} \mathbf{f}_J \\
 &= \omega(2 - \omega) \begin{bmatrix} \mathbf{I} & \mathbf{O} & -\omega\mathbf{A}_1^{-1} \\ \mathbf{O} & \mathbf{I} & \mathbf{O} \\ \mathbf{O} & \mathbf{O} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{I} & \mathbf{O} & \mathbf{O} \\ -\omega\mathbf{A}_2 & \mathbf{I} & \mathbf{O} \\ \omega^2\mathbf{A}_3^\top\mathbf{A}_2 & -\omega\mathbf{A}_3^\top & \mathbf{I} \end{bmatrix} \mathbf{f}_J \\
 &= \omega(2 - \omega) \begin{bmatrix} \mathbf{A}_1^{-1}\mathbf{b}_1 + \omega^2\mathbf{A}_3^\top\mathbf{A}_3\mathbf{b}_1 + \omega^2\mathbf{A}_1^{-1}\mathbf{A}_3^\top\mathbf{b}_2 \\ \mathbf{b} - \omega\mathbf{A}_3\mathbf{b}_1 \\ \omega^2\mathbf{A}_3^\top\mathbf{A}_3\mathbf{b}_1 - \omega\mathbf{A}_3^\top\mathbf{b}_2 \end{bmatrix}.
 \end{aligned}$$



据此即可写出 SSOR 迭代法的迭代格式

$$\mathbf{y}^{(k+1)} = \mathcal{T}_\omega \mathbf{y}^{(k)} + \mathbf{g}_\omega. \quad (5.78)$$

上述 Jacobi 迭代、SOR 迭代和 SSOR 迭代的收敛性分析可参考文献 [23].

#### §5.4.4 基于 KKT 方程的 HSS 迭代法

现在考虑最小二乘问题 (5.38) 的 KKT 方程

$$\begin{bmatrix} \mathbf{I} & \mathbf{A} \\ \mathbf{A}^\mathrm{T} & \mathbf{O} \end{bmatrix} \begin{bmatrix} \mathbf{r} \\ \mathbf{x} \end{bmatrix} = \begin{bmatrix} \mathbf{b} \\ \mathbf{0} \end{bmatrix} \quad (5.79)$$

的迭代解法. 由于式 (5.79) 的系数矩阵是对称不定的, 为了设计更



有效的迭代算法, 将其改成成如下的等价形式:

$$\mathbf{B}\mathbf{z} := \begin{bmatrix} \mathbf{I} & \mathbf{A} \\ -\mathbf{A}^T & \mathbf{O} \end{bmatrix} \begin{bmatrix} \mathbf{r} \\ \mathbf{x} \end{bmatrix} = \begin{bmatrix} \mathbf{b} \\ \mathbf{0} \end{bmatrix} := \mathbf{f}, \quad (5.80)$$

此时的 KKT 矩阵是非奇异的非对称半正定矩阵.

下面将白中治等学者提出的关于非对称正定线性方程组的 HSS (Hermite/skew-Hermite Splitting) 迭代法应用于求解上述 KKT 方程组 (5.80).

选取参数  $\alpha > 0$ , 将矩阵  $\mathbf{B}$  分裂成

$$\mathbf{B} = (\alpha\mathbf{I} + \mathbf{H}) - (\alpha\mathbf{I} - \mathbf{S}) = (\alpha\mathbf{I} + \mathbf{S}) - (\alpha\mathbf{I} - \mathbf{H}),$$

式中:

$$\mathbf{H} = \frac{1}{2}(\mathbf{B} + \mathbf{B}^T) = \begin{bmatrix} \mathbf{I} & \mathbf{O} \\ \mathbf{O} & \mathbf{O} \end{bmatrix}, \quad \mathbf{S} = \frac{1}{2}(\mathbf{B} - \mathbf{B}^T) = \begin{bmatrix} \mathbf{O} & \mathbf{A} \\ -\mathbf{A}^T & \mathbf{O} \end{bmatrix}.$$





则针对 KKT 方程组 (5.80) 的 HSS 迭代格式为

$$\begin{cases} (\alpha \mathbf{I} + \mathbf{H}) \mathbf{z}^{(k+\frac{1}{2})} = (\alpha \mathbf{I} - \mathbf{S}) \mathbf{z}^{(k)} + \mathbf{f}, \\ (\alpha \mathbf{I} + \mathbf{S}) \mathbf{z}^{(k+1)} = (\alpha \mathbf{I} - \mathbf{H}) \mathbf{z}^{(k+\frac{1}{2})} + \mathbf{f}. \end{cases} \quad (5.81)$$

更详细地, 即

$$\begin{cases} \begin{bmatrix} (\alpha + 1)\mathbf{I} & \mathbf{O} \\ \mathbf{O} & \alpha \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{r}^{(k+\frac{1}{2})} \\ \mathbf{x}^{(k+\frac{1}{2})} \end{bmatrix} = \begin{bmatrix} \alpha \mathbf{I} & -\mathbf{A} \\ \mathbf{A}^T & \alpha \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{r}^{(k)} \\ \mathbf{x}^{(k)} \end{bmatrix} + \begin{bmatrix} \mathbf{b} \\ \mathbf{0} \end{bmatrix}, \\ \begin{bmatrix} \alpha \mathbf{I} & \mathbf{A} \\ -\mathbf{A}^T & \alpha \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{r}^{(k+1)} \\ \mathbf{x}^{(k+1)} \end{bmatrix} = \begin{bmatrix} (\alpha - 1)\mathbf{I} & \mathbf{O} \\ \mathbf{O} & \alpha \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{r}^{(k+\frac{1}{2})} \\ \mathbf{x}^{(k+\frac{1}{2})} \end{bmatrix} + \begin{bmatrix} \mathbf{b} \\ \mathbf{0} \end{bmatrix}. \end{cases} \quad (5.82)$$

应用 HSS 迭代法 (5.81) 时, 求解两个子问题可采用直接法或内迭代法进行计算. 此外, 不难发现, 迭代法 (5.81) 的迭代矩阵为

$$\mathcal{L}(\alpha) = (\alpha \mathbf{I} + \mathbf{S})^{-1}(\alpha \mathbf{I} - \mathbf{H})(\alpha \mathbf{I} + \mathbf{H})^{-1}(\alpha \mathbf{I} - \mathbf{S}). \quad (5.83)$$



Back

Close



收敛性定理如下.

**定理 5.7** 设  $\mathbf{A} \in \mathbb{R}_n^{m \times n}$ ,  $\sigma_k (k = 1, 2, \dots, n)$  为矩阵  $\mathbf{A}$  的 (正) 奇异值. 则 HSS 迭代法 (5.82) 的迭代矩阵  $\mathcal{L}(\alpha)$  有  $m - n$  重特征值为  $\frac{\alpha - 1}{\alpha + 1}$ , 和  $2n$  个特征值为

$$\frac{1}{(\alpha + 1)(\alpha^2 + \sigma_k^2)} \left[ \alpha(\alpha^2 - \sigma_k^2) \pm \sqrt{(\alpha^2 + \sigma_k^2)^2 - 4\alpha^4\sigma_k^2} \right], \quad k = 1, 2, \dots, n.$$

因此, 有

$$\rho(\mathcal{L}(\alpha)) < 1, \quad \forall \alpha > 0,$$

即 HSS 迭代收敛到 KKT 方程组 (5.79) 的准确解.

**证明** 由于

$$\alpha \mathbf{I} \pm \mathbf{H} = \begin{bmatrix} (\alpha \pm 1)\mathbf{I} & \mathbf{O} \\ \mathbf{O} & \alpha \mathbf{I} \end{bmatrix}, \quad \alpha \mathbf{I} \pm \mathbf{S} = \begin{bmatrix} \alpha \mathbf{I} & \pm \mathbf{A} \\ \mp \mathbf{A}^\top & \alpha \mathbf{I} \end{bmatrix},$$



Back

Close

且有

$$\alpha \mathbf{I} + \mathbf{S} = \begin{bmatrix} \mathbf{I} & \mathbf{O} \\ -\alpha^{-1} \mathbf{A}^T & \mathbf{I} \end{bmatrix} \begin{bmatrix} \alpha \mathbf{I} & \mathbf{A} \\ \mathbf{O} & \mathbf{S}(\alpha) \end{bmatrix},$$

这里  $\mathbf{S}(\alpha) = \alpha \mathbf{I} + \frac{1}{\alpha} \mathbf{A}^T \mathbf{A}$ . 直接计算, 得

$$\mathcal{L}(\alpha) = \begin{bmatrix} \mathcal{L}_1(\alpha) & \mathcal{L}_2(\alpha) \\ \mathcal{L}_3(\alpha) & \mathcal{L}_4(\alpha) \end{bmatrix},$$

式中:

$$\begin{aligned} \mathcal{L}_1(\alpha) &= \frac{\alpha - 1}{\alpha + 1} \mathbf{I} - \frac{2}{\alpha + 1} \mathbf{A} \mathbf{S}(\alpha)^{-1} \mathbf{A}^T, & \mathcal{L}_2(\alpha) &= -\frac{2\alpha}{\alpha + 1} \mathbf{A} \mathbf{S}(\alpha)^{-1}, \\ \mathcal{L}_3(\alpha) &= \frac{2\alpha}{\alpha + 1} \mathbf{S}(\alpha)^{-1} \mathbf{A}^T, & \mathcal{L}_4(\alpha) &= -\frac{\alpha - 1}{\alpha + 1} \mathbf{I} + \frac{2\alpha^2}{\alpha + 1} \mathbf{S}(\alpha)^{-1}. \end{aligned}$$







设矩阵  $A$  的奇异值分解为

$$A = U \begin{bmatrix} \Sigma \\ O \end{bmatrix} V^T, \quad \Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_n),$$

式中:  $U \in \mathbb{R}^{m \times m}$ ,  $V \in \mathbb{R}^{n \times n}$  为正交矩阵. 于是有

$$S(\alpha) = \alpha I + \frac{1}{\alpha} V \begin{bmatrix} \Sigma & O \end{bmatrix} U^T U \begin{bmatrix} \Sigma \\ O \end{bmatrix} V^T = V \left( \alpha I + \frac{1}{\alpha} \Sigma^2 \right) V^T,$$

及

$$\mathcal{L}_1(\alpha) = U \begin{bmatrix} \frac{\alpha-1}{\alpha+1} I - \frac{2}{\alpha+1} \left( \alpha I + \frac{1}{\alpha} \Sigma^2 \right)^{-1} \Sigma^2 & O \\ O & \frac{\alpha-1}{\alpha+1} I \end{bmatrix} U^T,$$
$$\mathcal{L}_2(\alpha) = U \begin{bmatrix} -\frac{2\alpha}{\alpha+1} \Sigma \left( \alpha I + \frac{1}{\alpha} \Sigma^2 \right)^{-1} \\ O \end{bmatrix} V^T,$$



Back

Close



$$\mathcal{L}_3(\alpha) = \mathbf{V} \begin{bmatrix} \frac{2\alpha}{\alpha+1} \boldsymbol{\Sigma} (\alpha \mathbf{I} + \frac{1}{\alpha} \boldsymbol{\Sigma}^2)^{-1}, & \mathbf{O} \end{bmatrix} \mathbf{U}^T,$$

$$\mathcal{L}_4(\alpha) = \mathbf{V} \begin{bmatrix} -\frac{\alpha-1}{\alpha+1} \mathbf{I} + \frac{2\alpha^2}{\alpha+1} (\alpha \mathbf{I} + \frac{1}{\alpha} \boldsymbol{\Sigma}^2)^{-1} \end{bmatrix} \mathbf{V}^T.$$

令

$$\mathbf{Q} = \begin{bmatrix} \mathbf{U} & \mathbf{O} \\ \mathbf{O} & \mathbf{V} \end{bmatrix},$$

则  $\mathcal{L}(\alpha)$  经过正交相似变换  $\tilde{\mathcal{L}}(\alpha) = \mathbf{Q}^T \mathcal{L}(\alpha) \mathbf{Q}$  后, 化为

$$\tilde{\mathcal{L}}(\alpha) = \begin{bmatrix} \frac{\alpha-1}{\alpha+1} \mathbf{I} - \frac{2}{\alpha+1} (\alpha \mathbf{I} + \frac{1}{\alpha} \boldsymbol{\Sigma}^2)^{-1} \boldsymbol{\Sigma}^2 & \mathbf{O} & -\frac{2\alpha}{\alpha+1} \boldsymbol{\Sigma} (\alpha \mathbf{I} + \frac{1}{\alpha} \boldsymbol{\Sigma}^2)^{-1} \\ \mathbf{O} & \frac{\alpha-1}{\alpha+1} \mathbf{I} & \mathbf{O} \\ \frac{2\alpha}{\alpha+1} \boldsymbol{\Sigma} (\alpha \mathbf{I} + \frac{1}{\alpha} \boldsymbol{\Sigma}^2)^{-1} & \mathbf{O} & -\frac{\alpha-1}{\alpha+1} \mathbf{I} + \frac{2\alpha^2}{\alpha+1} (\alpha \mathbf{I} + \frac{1}{\alpha} \boldsymbol{\Sigma}^2)^{-1} \end{bmatrix},$$

从而可得  $\mathcal{L}(\alpha)$  有  $m - n$  重特征值  $\frac{\alpha-1}{\alpha+1}$  (显然其绝对值  $< 1$ ), 和



## 矩阵



91/96

$$\begin{aligned}\mathcal{L}_k(\alpha) &= \begin{bmatrix} \frac{\alpha-1}{\alpha+1} - \frac{2}{\alpha+1} \left(\alpha + \frac{1}{\alpha} \sigma_k^2\right)^{-1} \sigma_k^2 & -\frac{2\alpha}{\alpha+1} \sigma_k \left(\alpha + \frac{1}{\alpha} \sigma_k^2\right)^{-1} \\ \frac{2\alpha}{\alpha+1} \sigma_k \left(\alpha + \frac{1}{\alpha} \sigma_k^2\right)^{-1} & -\frac{\alpha-1}{\alpha+1} + \frac{2\alpha^2}{\alpha+1} \left(\alpha + \frac{1}{\alpha} \sigma_k^2\right)^{-1} \end{bmatrix} \\ &= \frac{1}{(\alpha+1)(\alpha^2 + \sigma_k^2)} \begin{bmatrix} (\alpha-1)\alpha^2 - (\alpha+1)\sigma_k^2 & -2\alpha^2 \sigma_k \\ 2\alpha^2 \sigma_k & (\alpha+1)\alpha^2 - (\alpha-1)\sigma_k^2 \end{bmatrix}\end{aligned}$$

的特征值,  $k = 1, 2, \dots, n$ . 而二阶矩阵  $\mathcal{L}_k(\alpha)$  的特征方程为

$$\left(\lambda - \frac{(\alpha-1)\alpha^2 - (\alpha+1)\sigma_k^2}{(\alpha+1)(\alpha^2 + \sigma_k^2)}\right) \left(\lambda - \frac{(\alpha+1)\alpha^2 - (\alpha-1)\sigma_k^2}{(\alpha+1)(\alpha^2 + \sigma_k^2)}\right) + \frac{4\alpha^4 \sigma_k^2}{(\alpha+1)^2 (\alpha^2 + \sigma_k^2)^2} = 0,$$

化简, 得

$$\lambda^2 - \frac{2\alpha(\alpha^2 - \sigma_k^2)}{(\alpha+1)(\alpha^2 + \sigma_k^2)} \lambda + \frac{\alpha-1}{\alpha+1} = 0. \quad (5.84)$$

它的两个根为

$$\lambda_{1,2}^{(k)} = \frac{\alpha(\alpha^2 - \sigma_k^2) \pm \sqrt{(\alpha^2 + \sigma_k^2)^2 - 4\alpha^4 \sigma_k^2}}{(\alpha+1)(\alpha^2 + \sigma_k^2)}. \quad (5.85)$$



Back

Close



不难验证, 当  $\alpha^2 + \sigma_k^2 > 2\alpha^2\sigma_k$  时, 有

$$\begin{aligned} |\lambda_{1,2}^{(k)}| &\leq \frac{1}{(\alpha+1)(\alpha^2+\sigma_k^2)} \left[ \alpha|\alpha^2 - \sigma_k^2| + \sqrt{(\alpha^2 + \sigma_k^2)^2 - 4\alpha^4\sigma_k^2} \right] \\ &= \frac{\alpha}{\alpha+1} \left[ \frac{|\alpha^2 - \sigma_k^2|}{\alpha^2 + \sigma_k^2} + \sqrt{\frac{1}{\alpha^2} - \frac{4\alpha^2\sigma_k^2}{(\alpha^2 + \sigma_k^2)^2}} \right] \\ &< \frac{\alpha}{\alpha+1} \left( 1 + \frac{1}{\alpha} \right) = 1. \end{aligned}$$

当  $\alpha^2 + \sigma_k^2 = 2\alpha^2\sigma_k$  时, 有

$$|\lambda_{1,2}^{(k)}| = \frac{\alpha|\alpha^2 - \sigma_k^2|}{(\alpha+1)(\alpha^2 + \sigma_k^2)} \leq \frac{\alpha}{\alpha+1} < 1.$$

当  $\alpha^2 + \sigma_k^2 < 2\alpha^2\sigma_k$  时,  $\lambda_{1,2}^{(k)}$  为一对共轭复根, 此时有

$$|\lambda_{1,2}^{(k)}| = \sqrt{\lambda_1^{(k)} \lambda_2^{(k)}} = \frac{|\alpha - 1|}{\alpha + 1} < 1.$$

综合上述,  $\rho(\mathcal{L}(\alpha)) < 1, \forall \alpha > 0$ . 证毕.

□



Back

Close



此外, 还可以讨论 HSS 迭代法 (5.81) 中的最优参数  $\alpha$  的选取, 详细的分析过程可参考文献 [22], 其结论如下.

**定理 5.8** 设  $\mathbf{A} \in \mathbb{R}^{m \times n}$  列满秩,  $\alpha > 0$  是给定的常数. 若  $\sigma_k (k = 1, 2, \dots, n)$  是矩阵  $\mathbf{A}$  的正奇异值,  $\sigma_{\min} = \min_{1 \leq k \leq n} \{\sigma_k\}$ ,  $\sigma_{\max} = \max_{1 \leq k \leq n} \{\sigma_k\}$ , 则解线性方程组 (5.80) 的 HSS 迭代法的最优参数  $\alpha$  为

$$\alpha^* = \arg \min_{\alpha > 0} \rho(\mathcal{L}(\alpha)) = \sqrt{\sigma_{\min} \sigma_{\max}},$$

并且

$$\rho(\mathcal{L}(\alpha^*)) = \frac{\sigma_{\max} - \sigma_{\min}}{\sigma_{\max} + \sigma_{\min}}.$$

下面考虑迭代法 (5.82) 的执行. 这一算法的计算量主要集中在求解第 2 个子方程组, 因为其系数矩阵是一个分块的反对称矩阵. 但由于其对角块的特殊性, 可以将其降阶处理. 具体迭代格式



Back

Close

如下:

$$\begin{cases} \mathbf{r}^{(k+\frac{1}{2})} = \frac{1}{\alpha+1}(\alpha\mathbf{r}^{(k)} - \mathbf{A}\mathbf{x}^{(k)} + \mathbf{b}), \\ \mathbf{x}^{(k+\frac{1}{2})} = \mathbf{x}^{(k)} + \frac{1}{\alpha}\mathbf{A}^T\mathbf{r}^{(k)}, \\ (\alpha\mathbf{I} + \frac{1}{\alpha}\mathbf{A}\mathbf{A}^T)\mathbf{r}^{(k+1)} = (\alpha-1)\mathbf{r}^{(k+\frac{1}{2})} - \mathbf{A}\mathbf{x}^{(k+\frac{1}{2})} + \mathbf{b}, \\ \mathbf{x}^{(k+1)} = \mathbf{x}^{(k+\frac{1}{2})} + \frac{1}{\alpha}\mathbf{A}^T\mathbf{r}^{(k+1)}. \end{cases} \quad (5.86)$$

迭代格式 (5.86) 的主要工作量集中在第 3 式, 即求解以  $\alpha\mathbf{I} + \frac{1}{\alpha}\mathbf{A}\mathbf{A}^T$  为系数矩阵的方程组. 但由于该矩阵是对称正定的, 故可使用共轭梯度法进行非精确求解, 相应的迭代格式称为非精确 HSS 迭代法 (简记为 IHSS).

IHSS 迭代格式的 MATLAB 程序如下:

```
function [x,fval,k,time]=kkt_ihss(A,b,alpha,x,tol,max_it)
```

```
%IHSS算法求解KKT方程 $\mathbf{r}=\mathbf{b}-\mathbf{A}\mathbf{x}$ ,  $\mathbf{A}'\mathbf{r}=\mathbf{0}$ 
```





95/96

```
if nargin<6, max_it=1000; end
if nargin<5, tol=1.e-6; end
if nargin<4, x=zeros(size(A,2),1); end
tic; m=size(A,1); r=b-A*x;
s=A'*r; nr=norm(s); k=0;
B=alpha*eye(m)+A*A'/alpha;
while (k<=max_it)
    k=k+1;
    r=(alpha*r-A*x+b)/(alpha+1);
    x=x+s/alpha;
    c=(alpha-1)*r-A*x+b;
    r=eq_cg(B,c); %CG法求解子问题
    s=A'*r; x=x+s/alpha;
```



Back

Close



```
    if (norm(s)/nr<tol), break; end  
end  
fval=norm(r);  
time=toc;
```

例 5.8 利用 HSS 迭代法的 MATLAB 程序, 计算例 5.6 中的最小二乘问题  $\min \|\mathbf{b} - \mathbf{A}\mathbf{x}\|_2$  的极小解, 并与 CG 迭代法进行比较 (取初始点为零向量, 参数  $\alpha = 6.0$ , 容许误差  $\varepsilon = 10^{-10}$ ).

解 编写 MATLAB 脚本文件 ex58.m, 并在命令窗口运行之, 得到数值结果如表 5.2 所示.

表 5.2 IHSS, HSS 与 CG 方法的数值结果

算法	迭代次数	CPU时间	极小解	极小值
IHSS	741	0.0003	$(-0.0303, 0.0171, 2.4508, 1.2953)^T$	0.9959
HSS	743	0.0159	$(-0.0303, 0.0171, 2.4508, 1.2953)^T$	0.9959
CG	5	0.0031	$(-0.0309, 0.0171, 2.4509, 1.2954)^T$	0.9959



Back

Close